

1 **UNIVERSIDAD NACIONAL MICAELA BASTIDAS DE APURÍMAC**
2 **FACULTAD DE INGENIERÍA**
3
4
5 **ESCUELA ACADÉMICO PROFESIONAL DE INGENIERÍA INFORMATICA Y**
6 **SISTEMAS**



7
8
9
10
11
12
13
14
15
16
17
18
19
20
21
22
23
24
25
26

Proyecto de Tesis

Ecosistema Inteligente con Visión Artificial y LLM para mejorar el rendimiento académico
en la UNAMBA, 2026

Presentado por:

Clinio Omar Rayme Huacho

Para optar el título de Ingeniero Informatico y Sistemas

Abancay, Perú

2026

27
28
29
30

31

ÍNDICE

	Pag.
32 INTRODUCCIÓN	1
33 DATOS GENERALES	3
34 a) Título del proyecto	3
35 b) Ejecutor/ejecutores	3
36 c) Asesor	3
37 d) Línea de investigación	3
38 CAPÍTULO I	4
39 PLANTEAMIENTO DEL PROBLEMA	4
40 1.1 Descripción del problema	4
41 1.2 Enunciado del problema	5
42 1.2.1 Problema general	5
43 1.2.2 Problemas específicos	5
44 1.3 Justificación de la investigación	5
45 1.3.1 Justificación Científica	6
46 1.3.2 Justificación Tecnológica	6
47 1.3.3 Justificación Institucional	7
48 1.4 Ubicación y Contextualización	7
49 CAPÍTULO II	9
50 OBJETIVOS E HIPÓTESIS	9
51 2.1 Objetivos de la investigación	9
52 2.1.1 Objetivo general	9
53 2.1.2 Objetivos específicos	9
54 2.2 Hipótesis de la investigación	9
55 2.2.1 Hipótesis general	9
56 2.2.2 Hipótesis específicas	9
57 CAPÍTULO III	13
58 MARCO TEÓRICO REFERENCIAL	13
59 3.1 Antecedentes	13
60 3.1.1 Antecedentes internacionales	13
61 3.1.2 Antecedentes nacionales	15

62	3.2	Marco teórico	15
63	3.2.1	Inteligencia Artificial Generativa y Arquitectura RAG	15
64	3.2.2	Arquitectura Transformer y Mecanismo de Atención	16
65	3.2.3	Reconocimiento de Texto Manuscrito (HTR), TrOCR y Fórmulas Matemáticas	18
66	3.2.4	<i>Vector Embeddings</i> y Bases de Datos Vectoriales	19
67	3.2.5	Grafos de Conocimiento	20
68	3.2.6	Generación Automática de Evaluaciones Adaptativas	21
69	3.2.7	Aprendizaje Activo y Recuperación Espaciada (<i>Spaced Repetition</i>)	21
70	3.2.8	Aprendizaje Colaborativo Mediado por Tecnología	22
71	3.2.9	Carga Cognitiva y Medición con NASA-TLX	23
72	3.2.10	Privacidad y Seguridad de Datos Estudiantiles en Plataformas IA	23
73	3.2.11	Arquitectura Limpia (<i>Clean Architecture</i>)	24
74	3.3	Marco conceptual	25
75	CAPÍTULO IV		29
76	METODOLOGÍA		29
77	4.1	Tipo y nivel de investigación	29
78	4.2	Diseño de la investigación	29
79	4.3	Descripción ética de la investigación	30
80	4.4	Procedimiento	30
81	4.5	Población y muestra	32
82	4.5.1	Población	32
83	4.5.2	Muestra	32
84	4.6	Técnicas e instrumentos	33
85	4.6.1	Técnicas	33
86	4.6.2	Instrumentos	34
87	4.7	Estadístico de la investigación	34
88	4.7.1	Datos	34
89	4.7.2	Estadístico	34
90	4.7.3	Fórmulas	35
91	4.7.4	Nivel de significancia	36
92	4.7.5	Estadístico de prueba	36
93	4.7.6	Región crítica	37
94	4.7.7	Interpretación	37
95	CAPÍTULO V		39
96	ADMINISTRACIÓN DEL PROYECTO		39
97	5.1	Cronograma de actividades	39
98	5.2	Presupuesto	42
99	5.3	Fuente de financiamiento	42
100	REFERENCIAS BIBLIOGRÁFICAS		44

101 **ANEXOS** 49

102
103
104
105

106

ÍNDICE DE TABLAS

107 **Tabla 1** — Operacionalización de la Variable Independiente (VI) 11

108 **Tabla 2** — Operacionalización de la Variable Dependiente (VD) 12

109 **Tabla 3** — Fases del procedimiento de investigación 32

110 **Tabla 4** — Instrumentos de recolección de datos 34

111 **Tabla 5** — Cronograma de actividades – Fases I a III (Julio – Diciembre 2026) . 40

112 **Tabla 6** — Cronograma de actividades – Fases IV a VI (Julio – Diciembre 2026) 41

113 **Tabla 7** — Presupuesto estimado del proyecto de investigación 42

114 **Tabla 8** — Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema

115 SynapTome (Parte 1) 50

116 **Tabla 9** — Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema

117 SynapTome (Parte 2) 51

118
119
120
121

ÍNDICE DE FIGURAS

122

123	Figura 1 — Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA). .	8
124	Figura 2 — Arquitectura general del sistema de Generación Aumentada por Re-	
125	cuperación (RAG).	16
126	Figura 3 — Mecanismo de auto-atención escalada por producto punto (Scaled	
127	Dot-Product Attention).	17
128	Figura 4 — Flujo de procesamiento híbrido de visión y lenguaje del modelo TrOCR.	19
129	Figura 5 — Similitud de coseno entre vectores en un espacio de embeddings	
130	multidimensional.	20
131	Figura 6 — Grafo relacional de conocimiento representando la progresión del	
132	estudiante.	21
133	Figura 7 — Curva del olvido de Ebbinghaus y el impacto de los repasos progra-	
134	mados.	22
135	Figura 8 — Capas concéntricas de dependencias bajo el diseño de Arquitectura	
136	Limpia.	25
137	Figura 9 — Pipeline adaptativo de transcripción caligráfica manuscrita (HTR) e	
138	integración RAG/Grafo en el ecosistema SynapTome.	31
139	Figura 10 — Representación gráfica de la curva de densidad t de Student unilateral	
140	derecha y la región crítica de rechazo.	37

INTRODUCCIÓN

La adopción de la Inteligencia Artificial Generativa ha impulsado una transformación sin precedentes en la educación superior, redefiniendo las metodologías de enseñanza y la asimilación del conocimiento (Vieriu et al., 2025). En este escenario, la gestión de apuntes universitarios ha experimentado una evolución acelerada, migrando desde los métodos manuscritos tradicionales hacia formatos digitales dinámicos e interactivos. Esta transición tecnológica busca optimizar la captura, organización y recuperación de la información académica. Según Kreijkes et al. (2026), la integración de Modelos de Lenguaje Grande (LLMs) presenta oportunidades excepcionales para facilitar la comprensión lectora y reducir la carga cognitiva inicial de los estudiantes. Sin embargo, el volumen exponencial de datos técnicos y científicos en disciplinas de ingeniería exige herramientas que trasciendan el simple almacenamiento, demandando ecosistemas capaces de procesar y enlazar semánticamente el contenido educativo.

A pesar de estos avances tecnológicos, la digitalización educativa contemporánea enfrenta desafíos algorítmicos y pedagógicos severos. Los estudiantes de ingeniería padecen de una constante sobrecarga cognitiva al intentar integrar múltiples fuentes de información no estructurada. La adopción pasiva de plataformas de IA genéricas agrava este panorama, induciendo una dependencia tecnológica que inhibe el análisis crítico y la apropiación del conocimiento (Vieriu et al., 2025). A nivel técnico, los LLMs estándar adolecen de un problema crítico de “alucinaciones”; dado que carecen de mecanismos intrínsecos para verificar la veracidad de los hechos, frecuentemente generan información plausible pero fácticamente incorrecta (T. Chen et al., 2023). Adicionalmente, la digitalización de apuntes científicos enfrenta la barrera de la notación matemática, donde los sistemas tradicionales fracasan al procesar estructuras espaciales complejas (Alvarez-Perez et al., 2026). Finalmente, las herramientas actuales promueven un consumo individualista y fragmentado de la información, careciendo de la infraestructura lógica para establecer vínculos semánticos que fomenten una colaboración auténtica entre pares (Jiang et al., 2025).

Para mitigar estas brechas tecnológicas y metodológicas, la presente investigación propone formalmente el desarrollo de SynapTome, un ecosistema digital inteligente y colaborativo fundamentado en los principios de la Arquitectura Limpia (Clean Architecture). La infraestructura del sistema orquesta tecnologías de vanguardia para transformar la gestión del aprendizaje: en el núcleo de procesamiento de lenguaje natural, se implementa una arquitectura de Generación Aumentada por Recuperación (RAG) que restringe la inferencia de

la IA a un corpus documental validado, garantizando precisión factual y eliminando las alucinaciones (Ning et al., 2025). Para abordar el reto de la digitalización científica, se integra un pipeline de visión por computadora basado en el modelo Transformer TrOCR, el cual permite la transcripción estructurada de apuntes manuscritos y fórmulas matemáticas al formato LaTeX (KardanMoghaddam et al., 2025). El elemento diferenciador de SynapTome radica en su motor de base de datos relacional modelado mediante Grafos de Conocimiento en PostgreSQL. Estos grafos indexan topológicamente los bloques de estudio, descubriendo relaciones transversales entre múltiples usuarios para catalizar una verdadera “Inteligencia Colectiva” (Obionwu et al., 2022). Todo el ecosistema opera con una sincronización concurrente a través de SignalR y C#, con una interfaz reactiva desarrollada en Next.js.

El presente trabajo de investigación se estructura en seis capítulos organizados de la siguiente manera: el **Capítulo I** comprende el planteamiento del problema, delimitando la problemática de la sobrecarga cognitiva y la digitalización de apuntes científicos, justificando la investigación desde las dimensiones científica, tecnológica e institucional, y contextualizando el caso de estudio en la Escuela Profesional de Ingeniería de Informática y Sistemas de la UNAMBA; el **Capítulo II** establece los objetivos de la investigación (general y específicos), las hipótesis correspondientes que guían el estudio y la operacionalización rigurosa de las variables; el **Capítulo III** desarrolla el marco teórico referencial, comenzando con los antecedentes nacionales e internacionales del estado del arte, y profundizando en teorías fundamentales como la Inteligencia Artificial Generativa, la arquitectura RAG, los Transformers, TrOCR, bases de datos vectoriales, Grafos de Conocimiento y la Teoría de la Carga Cognitiva; el **Capítulo IV** detalla el diseño metodológico, especificando el tipo y diseño de la investigación (cuasi-experimental), el pipeline del sistema, la población y muestra, el procedimiento experimental, así como las técnicas, instrumentos y estadísticos (pruebas t de Student, CER, WER, ROUGE y SUS); el **Capítulo V** presenta los resultados empíricos obtenidos en las pruebas, incluyendo el análisis comparativo del error de caracteres (CER), la mitigación de alucinaciones en el middleware RAG, la reducción de sobrecarga cognitiva mediante NASA-TLX, y la contrastación de la hipótesis general; finalmente, el **Capítulo VI** expone las conclusiones del estudio, destacando los logros alcanzados frente a cada objetivo específico, y propone recomendaciones metodológicas y tecnológicas para futuras implementaciones.

210

211

212

213

214

DATOS GENERALES

215 a) **Título del proyecto:**

216 Ecosistema Inteligente con Visión Artificial y LLM para mejorar el rendimiento
217 académico en la UNAMBA, 2026

218

219 b) **Ejecutor:**

220 • Clinio Omar Rayme Huacho

221

222 c) **Asesor:**

223 • M.Sc. Yhon Fuentes Huaman

224

225 d) **Línea de investigación:**

226 • Ingeniería de software e innovación tecnológica

227

228
229
230
231

232
233

CAPÍTULO I

PLANTEAMIENTO DEL PROBLEMA

234

1.1 Descripción del problema

235
236
237
238
239
240
241
242
243
244
245
246
247
248
249
250
251
252
253
254
255
256
257
258
259
260
261
262
263
264

En el entorno académico universitario contemporáneo, los estudiantes enfrentan un volumen exponencial de información técnica y científica que a menudo desencadena una severa sobrecarga cognitiva. El procesamiento simultáneo de múltiples fuentes de información no estructurada y la dificultad de organizar apuntes fragmentados limitan la capacidad de comprensión y retención de los alumnos. Teorías del aprendizaje, como la Teoría de la Carga Cognitiva, explican que la división de la atención durante la captura manual o digital de apuntes puede resultar en la pérdida de información crítica y en un bajo rendimiento académico si los métodos de captura no se alinean con un procesamiento estructurado. A pesar de que la toma de apuntes es una herramienta pedagógica esencial, los enfoques tradicionales a menudo generan ecosistemas de estudio aislados que no logran seguir el ritmo de la complejidad del contenido universitario.

Para mitigar esta sobrecarga, los estudiantes han recurrido a Modelos de Lenguaje Grande (LLMs) genéricos en busca de resúmenes y asistencia académica. Sin embargo, la adopción de estos sistemas presenta fallas críticas. Los LLMs tradicionales frecuentemente fracasan al capturar los matices técnicos y factuales propios de los artículos de investigación e ingeniería. Más grave aún es el problema de las “alucinaciones”; los LLMs carecen de una capacidad intrínseca para verificar la veracidad de la información que generan, lo que resulta en la invención de hechos plausibles pero falsos que contaminan el aprendizaje. Además, el uso de resúmenes genéricos omite la intención y el contexto específico del usuario, lo que subraya la necesidad imperativa de sistemas de IA condicionados factualmente.

Por otra parte, la digitalización de apuntes manuscritos en carreras de ingeniería y ciencias exactas enfrenta un cuello de botella computacional significativo debido a la presencia de fórmulas matemáticas, matrices y gráficos. Los sistemas convencionales de Reconocimiento Óptico de Caracteres (OCR) no están diseñados para interpretar la estructura espacial y semántica de las matemáticas. Es necesario el uso de arquitecturas basadas en Transformers, como TrOCR, sometidas a procesos de fine-tuning específicos, para lograr una conversión estructurada y precisa de notación científica hacia el formato LaTeX. La alta variabilidad en los estilos

de escritura y el ruido en las imágenes complican severamente la transcripción automatizada si no se emplean pipelines de Deep Learning avanzados. Finalmente, existe una carencia fundamental de plataformas verdaderamente colaborativas. Históricamente, la gestión de apuntes ha sido un proceso de consumo individual. El aprendizaje colaborativo basado en la gestión del conocimiento es indispensable para el desarrollo de competencias en el aula. No obstante, las herramientas actuales carecen de la infraestructura necesaria para enlazar semánticamente la información entre pares. La literatura sugiere que la implementación de mapas de tópicos y grafos relacionales en los sistemas de gestión del conocimiento es un habilitador técnico crucial para una pedagogía verdaderamente colaborativa, un componente del cual carecen las plataformas educativas estándar.

1.2 Enunciado del problema

1.2.1 Problema general

¿En cuánto disminuye la sobrecarga de apuntes y la fatiga mental, y en qué medida se optimiza el rendimiento académico de los estudiantes universitarios de la UNAMBA al transicionar desde esquemas de estudio aislados hacia un entorno de aprendizaje interconectado y automatizado?

1.2.2 Problemas específicos

- ¿En cuánto se reduce el tiempo de consolidación de apuntes manuscritos y cuál es el incremento en la tasa de preservación de información técnica mediante el uso de la aplicación con un módulo de transcripción automatizada (TrOCR) frente a los métodos de transcripción tradicional?
- ¿Cuál es la tasa de reducción de errores conceptuales en el material de repaso de los estudiantes al condicionar las respuestas del sistema mediante un middleware RAG acoplado a un LLM en comparación con las herramientas de inteligencia artificial genéricas de entorno abierto?
- ¿En cuánto disminuyen el nivel de sobrecarga cognitiva y la fatiga mental, y de qué manera se optimiza el rendimiento académico de los alumnos al implementar en la aplicación web un motor relacional de grafos de conocimiento con evaluaciones dinámicas automatizadas frente a los esquemas basales de estudio aislados?

1.3 Justificación de la investigación

La presente investigación se justifica desde tres dimensiones fundamentales: científica, tecnológica e institucional, las cuales convergen en el desarrollo y des-

pliegue del ecosistema SynapTome para resolver de manera integral los desafíos contemporáneos en la gestión del aprendizaje universitario.

1.3.1 Justificación Científica

A nivel científico, este estudio aporta evidencia empírica sobre cómo resolver las deficiencias inherentes de los Modelos de Lenguaje Grande (LLMs) en contextos académicos. Se demuestra que la integración de Grafos de Conocimiento actúa como una guía semántica que mitiga la incapacidad de los LLMs para verificar hechos, reduciendo drásticamente las “alucinaciones” durante la sumarización abstractiva (T. Chen et al., 2023). Además, la investigación fundamenta un cambio desde un paradigma de aprendizaje pasivo hacia uno constructivista; el uso guiado de la IA para la generación automática de evaluaciones formativas (*quizzes*) e interacciones basadas en apuntes reduce la sobrecarga cognitiva e incrementa significativamente la retención a largo plazo y la comprensión de los estudiantes (Kreijkes et al., 2026; Afian et al., 2025). Finalmente, el proyecto valida la teoría de la pedagogía colaborativa, comprobando que el uso de Mapas de Tópicos (*Topic Maps*) permite estructurar el conocimiento fragmentado, descubriendo relaciones transversales y fomentando una auténtica “Inteligencia Colectiva” (Obionwu et al., 2022).

1.3.2 Justificación Tecnológica

Desde la perspectiva tecnológica, el desarrollo de SynapTome representa un avance en la superación de los cuellos de botella clásicos de la digitalización científica. El proyecto aborda las altas tasas de error de los sistemas OCR tradicionales mediante la implementación de *pipelines* de visión por computadora basados en la arquitectura *Transformer* (TrOCR y Nougat), los cuales, a través de procesos de *fine-tuning*, logran transcribir con alta precisión notación matemática y fórmulas complejas directamente hacia el formato estructurado L^AT_EX (Alvarez-Perez et al., 2026; Kardan-Moghaddam et al., 2025). Asimismo, el diseño del sistema orquesta una Arquitectura Limpia (*Clean Architecture*) que integra *Next.js* en el *frontend*, un *middleware* de Generación Aumentada por Recuperación (RAG) condicionado factualmente (Ning et al., 2025; Jiang et al., 2025), y bases de datos relacionales con soporte vectorial como PostgreSQL. Esta integración *full-stack*, apoyada en WebSockets (SignalR), justifica la viabilidad de desplegar un entorno de coedición seguro, escalable y en tiempo real (Shirkande et al., 2025; Upadhyay et al., 2026).

1.3.3 Justificación Institucional

A nivel institucional, la implementación de este ecosistema en la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), específicamente orientado a la Escuela Académico Profesional de Ingeniería de Sistemas, proporciona una infraestructura digital de vanguardia que impacta directamente en la calidad educativa. Los estudiantes de ingeniería requieren asimilar un volumen denso de información matemática y técnica; al proveerles una plataforma que centraliza, digitaliza y democratiza el acceso a una mayor cantidad de apuntes interconectados, la universidad facilita una mejora medible en el rendimiento académico y las calificaciones de su comunidad estudiantil (Dano et al., 2026). En consecuencia, esta iniciativa dota a la UNAMBA de herramientas tecnológicas de primer nivel, posicionándola como una institución innovadora que adopta la Inteligencia Artificial de manera ética, estructurada y orientada al beneficio colectivo.

1.4 Ubicación y Contextualización

La presente investigación se contextualiza y aplicará en la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), ubicada en la ciudad de Abancay, en la región de Apurímac, Perú. Específicamente, el caso de estudio está enfocado en atender las necesidades académicas y los retos de aprendizaje de los estudiantes de la Escuela Académico Profesional de Ingeniería de Informaticá y Sistemas. En este entorno, los estudiantes manejan un alto volumen de asignaturas fundamentadas en el cálculo, la física, el álgebra lineal y la algoritmia. Estos tópicos exigen el uso intensivo de notación matemática compleja, diagramas lógicos y esquemas arquitectónicos, los cuales suelen registrarse tradicionalmente de manera manuscrita. Las barreras en la digitalización de esta información, sumadas a la alta carga cognitiva propia de la disciplina y las limitaciones de infraestructura para la colaboración eficiente entre pares, hacen que los estudiantes de la UNAMBA sean los candidatos idóneos para validar la efectividad del ecosistema SynapTome como una herramienta integral para la gestión y democratización de su conocimiento técnico.



Figura 1— Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA).

CAPÍTULO II

OBJETIVOS E HIPÓTESIS

2.1 Objetivos de la investigación

2.1.1 Objetivo general

Reducir la sobrecarga de apuntes y la fatiga mental, y optimizar el rendimiento académico de los estudiantes universitarios de la UNAMBA al implementar y evaluar una aplicación web basada en un entorno de aprendizaje interconectado y automatizado.

2.1.2 Objetivos específicos

- Reducir el tiempo dedicado a la consolidación de apuntes manuscritos y aumentar la tasa de preservación de información técnica mediante el uso de la aplicación web con un módulo de transcripción automatizada (TrOCR).
- Reducir la tasa de errores conceptuales en el material de repaso de los estudiantes al condicionar las respuestas de la aplicación web mediante un middleware RAG acoplado a un LLM en comparación con el uso de herramientas de entorno abierto.
- Disminuir el nivel de sobrecarga cognitiva y la fatiga mental, y optimizar el rendimiento académico de los alumnos al implementar en la aplicación web un motor relacional de grafos de conocimiento con evaluaciones dinámicas automatizadas.

2.2 Hipótesis de la investigación

2.2.1 Hipótesis general

La transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente optimiza significativamente el rendimiento académico y reduce la sobrecarga cognitiva en los estudiantes universitarios, en la UNAMBA, 2026.

2.2.2 Hipótesis específicas

- La migración de los estudiantes hacia un flujo de digitalización automatizado mediante un pipeline HTR basado en la arquitectura TrOCR

401 con *fine-tuning* incrementa significativamente la tasa de preservación
402 de información técnica en sus apuntes y reduce el tiempo promedio
403 dedicado a la consolidación de notas manuscritas respecto al estado
404 inicial analógico, en la UNAMBA, 2026.

405 • El condicionamiento del entorno de asimilación cognitiva de los alum-
406 nos a un corpus académico validado mediante un middleware RAG
407 restrictivo disminuye drásticamente el índice de errores conceptuales
408 y datos falsos presentes en sus materiales de autoestudio, asegurando
409 una alta fidelidad factual en comparación con el uso de herramientas
410 genéricas de información, en la UNAMBA, 2026.

411 • La adopción de un entorno de aprendizaje interconectado basado en
412 Grafos de Conocimiento y evaluaciones dinámicas automatizadas in-
413 crementa las calificaciones promedio de los estudiantes y reduce los
414 niveles de sobrecarga cognitiva percibida en comparación con los va-
415 lores basales registrados durante los métodos de repaso individuales y
416 aislados, en la UNAMBA, 2026.

Tabla 1— Operacionalización de la Variable Independiente (VI)

Variable	Definición conceptual	Definición operacional	Dimensión	Definición de dimensión	Indicadores	Escala / Rangos
Variable Independiente (VI): Ecosistema inteligente con visión artificial y LLM	Ecosistema tecnológico integrado que automatiza la gestión y asimilación de apuntes académicos mediante procesamiento de imágenes (TrOCR), recuperación contextual controlada (RAG) y estructuración en redes de conocimiento (grafos).	Se operacionaliza a través del desarrollo de la aplicación web SynapTome, evaluando el tiempo de procesamiento, la tasa de error en la transcripción, el control de alucinaciones conceptuales y el nivel de sobrecarga cognitiva.	Módulo de digitalización (TrOCR)	Proceso encargado de la captura, procesamiento y conversión de apuntes manuscritos a texto estructurado en $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$.	Uso de herramientas tecnológicas (Flujo manual vs. Aplicación web); tasa de conversión de caracteres técnicos (%); porcentaje de preservación de fórmulas matemáticas.	Flujo de trabajo: 0 = Manual tradicional 1 = Web automatizada Conversión: Alta $\geq 95\%$ Baja $< 80\%$ Preservación: Excelente $> 95\%$ Regular 80–95 %
			Control factual (RAG)	Mecanismo de restricción semántica que valida las respuestas del LLM contra un corpus académico cerrado.	Configuración de inferencia (Inferencia abierta vs. Filtro RAG); tasa de reducción de errores conceptuales (%); consistencia semántica del resumen.	Entorno de consultas: 0 = Abierto genérico 1 = RAG restrictivo Reducción de errores: Alta $\geq 90\%$ Media 80–89 % Consistencia: Alta $> 95\%$ Deficiente $< 80\%$
			Motor relacional y cuestionarios	Estructuración de la información del alumno en un grafo de conocimiento y despliegue automático de test adaptativos.	Topología de notas (Bloques aislados vs. Red relacional); tasa de generación de cuestionarios (%); latencia de actualización del grafo (s).	Estructuración: 0 = Bloques aislados 1 = Red relacional Quizzes automáticos: Adecuado $\geq 90\%$ Deficiente $< 10\%$ Sincronización: Óptima $< 2\text{ s}$ Aceptable 2–5 s

Tabla 2— Operacionalización de la Variable Dependiente (VD)

Variable	Definición conceptual	Definición operacional	Dimensión	Definición de dimensión	Indicadores	Escala / Rangos
Variable Dependiente (VD): Mejorar el rendimiento académico.	Nivel de asimilación cognitiva y desarrollo de habilidades académicas de los estudiantes, caracterizado por la agilidad en la captura de notas, el control de errores conceptuales en el autoestudio y el desempeño en exámenes.	Se evalúa de forma cuasi-experimental midiendo calificaciones en exámenes, puntuaciones en la escala NASA-TLX de fatiga mental, y el tiempo semanal de consolidación de notas.	Eficiencia de captura técnica	Habilidad del estudiante para transcribir y asimilar contenidos con alta complejidad simbólica y notación científica.	Tasa de Error de Caracteres (CER %); tiempo semanal de consolidación y transcripción (minutos); precisión de renderizado en sintaxis $\text{\LaTeX}$ (%).	CER: Excelente < 5 % Aceptable 5–15 % Deficiente > 15 % Tiempo de consolidación: Eficiente < 20 min Aceptable 20–60 min Ineficiente > 60 min Precisión de renderizado: Alta $\geq$ 90 % Baja < 90 %
			Calidad factual del repaso	Precisión científica y apego al contenido base académico en el material consolidado para el repaso individual.	Índice de inserción de conceptos erróneos o alucinados (%); coincidencia semántica con el material base académico (%); tasa de veracidad conceptual en resúmenes.	Índice de alucinación: Bajo < 5 % Medio 5–15 % Alto > 15 % Coincidencia semántica: Alta $\geq$ 90 % Media 80–89 % Baja < 80 % Veracidad conceptual: Alta $\geq$ 95 % Deficiente < 80 %
			Desempeño y carga cognitiva	Rendimiento académico obtenido por el alumno en relación con el esfuerzo mental y sobrecarga cognitiva autopercebida.	Calificaciones promedio en exámenes parciales (Escala 0–20) e índice de sobrecarga mental y fatiga (NASA-TLX).	Calificaciones: Sobresaliente 16–20 Regular 11–15 Desaprobado < 11 NASA-TLX: Baja sobrecarga < 40 Aceptable 40–70 Alta sobrecarga > 70 Significancia: $p < 0,05$

CAPÍTULO III

MARCO TEÓRICO REFERENCIAL

3.1 Antecedentes

3.1.1 Antecedentes internacionales

- a) Según [Ning et al. \(2025\)](#), en su investigación sobre la summarización personalizada consciente de la intención en textos educativos utilizando Modelos de Lenguaje Grande (LLMs), se encontró que el modelado explícito de la intención del usuario mejora drásticamente la relevancia y exactitud de los resúmenes. Su sistema propuesto logró superar a más de 10 modelos base de referencia, obteniendo ganancias de 6 a 8 puntos en las métricas ROUGE y una mejora de más del 5 % en la consistencia factual medida por la métrica FactCC.
- b) Según [T. Chen et al. \(2023\)](#), en su investigación sobre la mejora de la summarización abstractiva mediante la integración de Grafos de Conocimiento y transformadores de múltiples fuentes, se encontró que el uso de representaciones semánticas estructuradas como guía mitiga la incapacidad intrínseca de los LLMs para verificar la corrección de los hechos. Su modelo MultiBART-GAT demostró un rendimiento superior al generar resúmenes informativos y relevantes, logrando incrementar la puntuación ROUGE-1 a 39.1 y manteniendo un alto nivel de similitud semántica en la evaluación BERTScore.
- c) Según [Jiang et al. \(2025\)](#), en su investigación sobre el sistema de toma de apuntes colaborativo e inteligente NexaNota, se encontró que la construcción automática de redes de temas mediante grafos de conocimiento impacta positivamente en la eficiencia del aprendizaje. En su estudio, la extracción y representación del conocimiento en el sistema alcanzó una precisión del 97.7 % en la identificación de tópicos principales y una exactitud del 86.7 % al establecer las conexiones semánticas entre dichos tópicos.
- d) Según [Kreijkes et al. \(2026\)](#), en su investigación sobre los efectos del uso de Modelos de Lenguaje Grande (LLMs) y la toma de apuntes en la comprensión lectora y la memoria, se encontró que combinar la

toma de apuntes tradicional con el uso de LLMs tiene efectos positivos significativos en la retención de conocimientos en comparación con el uso exclusivo de la IA. Sus resultados demostraron que el esfuerzo cognitivo involucrado en la estructuración propia de apuntes, apoyado por la IA, mejora las métricas de retención literal y comprensión con un tamaño del efecto estadístico (d) de 0.44 y 0.38, respectivamente.

e) Según [Alvarez-Perez et al. \(2026\)](#), en su investigación desarrollada en México centrada en el *fine-tuning* de modelos *Transformers* para la conversión de textos científicos manuscritos al formato estructurado LaTeX, se encontró que arquitecturas visuales de extremo a extremo, como Nougat y TrOCR, superan ampliamente a los sistemas de OCR convencionales al procesar fórmulas matemáticas. Tras el entrenamiento con un corpus específico, el modelo optimizado demostró una alta capacidad para digitalizar notación espacial compleja, reduciendo la Tasa de Error de Caracteres (CER) hasta un 24.42 % en secuencias manuscritas desafiantes, lo que resulta ser un avance indispensable para la digitalización técnica en ingenierías y un aporte relevante al contexto latinoamericano.

f) Según [KardanMoghaddam et al. \(2025\)](#), en su investigación sobre una estructura combinada de transformadores TrOCR y LLMs para la clasificación y extracción de textos manuscritos, se encontró que inyectar las transcripciones de los modelos de visión directamente en un LLM mejora sustancialmente la precisión del procesamiento. Su modelo híbrido (TrOCR-Large acoplado con BART-Large) logró clasificar secuencias de texto con una precisión general (*accuracy*) de 65.29 % y altas puntuaciones F1, demostrando la viabilidad de utilizar *pipelines* de IA en cascada para digitalizar apuntes ruidosos.

g) Según [Solanki et al. \(2026\)](#), en su investigación sobre el ecosistema inteligente "NoteGenius", se encontró que la integración de IA generativa para la creación de apuntes y el aprendizaje colaborativo mitiga el problema de la fragmentación de la información académica. El desarrollo de esta plataforma (basada en tecnologías modernas y almacenamiento en la nube) automatiza la generación de resúmenes, conversión de diapositivas y creación de cuestionarios (quizzes), lo cual impacta directamente de forma positiva en la retención de conocimientos y auto-evaluación del estudiante.

h) Según [Upadhyay et al. \(2026\)](#), en su estudio sobre una aplicación

web integral para el análisis automático de contenido y generación de apuntes a partir de videos de YouTube, se evidenció que la orquestación de APIs de Modelos de Lenguaje Grande (LLMs) con arquitecturas escalables (como React, Express.js y PostgreSQL) optimiza sustancialmente el tiempo de estudio. El sistema logra extraer transcripciones y estructurar apuntes de manera rápida y segura, demostrando la eficacia de los *pipelines* de IA en el procesamiento de contenido multimedia educativo.

- i) Según [Shirkande et al. \(2025\)](#), en su evaluación del sistema "Note-verse", se identificó que las herramientas tradicionales de gestión de conocimiento adolecen de falta de personalización y de mecanismos de organización inteligente. Su investigación valida que implementar bases de datos en la nube y *frameworks* interactivos como Next.js para lograr una sincronización y coedición en tiempo real es vital para la construcción de ecosistemas colaborativos robustos en la educación superior.

3.1.2 Antecedentes nacionales

- a) Según [Tarazona Cruz \(2024\)](#), en su investigación sobre el reconocimiento de texto en manuscritos históricos peruanos utilizando modelos mixtos, se encontró que el uso de modelos de reconocimiento de imágenes preentrenados mediante la plataforma de código abierto OCR4all es viable para digitalizar documentos manuscritos en español. Tras entrenar tres modelos con el conjunto de datos SPA-Sentences (aproximadamente 13,000 oraciones), su sistema alcanzó una Tasa de Error de Caracteres (CER) promedio de 4.11 % en el conjunto de validación, y al aplicarlo sobre manuscritos históricos peruanos de la Biblioteca Nacional del Perú obtuvo una tasa de error promedio de 9.39 %, demostrando la utilidad de estas arquitecturas para el contexto local pese a la variabilidad caligráfica y el deterioro del papel.

3.2 Marco teórico

3.2.1 Inteligencia Artificial Generativa y Arquitectura RAG

La Inteligencia Artificial Generativa, particularmente impulsada por Modelos de Lenguaje Grande (LLMs) como GPT-3.5 o LLaMA 3, ha revolucionado las tareas de procesamiento de lenguaje natural al habilitar la sumarización abstractiva de textos con alta coherencia ([Saxena et al., 2025](#)). No obstante, estos modelos probabilísticos carecen de mecanismos

intrínsecos para verificar la veracidad de la información que generan, lo que con frecuencia deriva en “alucinaciones”: información plausible pero fácticamente incorrecta (T. Chen et al., 2023).

Para mitigar este problema, surge la arquitectura de Generación Aumentada por Recuperación (RAG). En lugar de depender exclusivamente de los pesos preentrenados del modelo, RAG restringe el espacio de inferencia recuperando primero los fragmentos de texto más relevantes desde un corpus local y proporcionándolos como contexto estricto al LLM Kannammal et al. (2024). El *pipeline* RAG clásico comprende tres etapas: indexación del corpus mediante *embeddings* vectoriales, recuperación semántica por similitud de coseno, y generación condicionada al contexto recuperado (Gao et al., 2024). Al acoplar RAG con validadores factuales, la tasa de alucinaciones se minimiza de forma crítica Ning et al. (2025), lo que resulta especialmente relevante para sistemas educativos donde la exactitud del contenido generado es indispensable. La evolución más reciente ha dado lugar a variantes como GraphRAG, que integra grafos de conocimiento en el proceso de recuperación para capturar relaciones estructuradas entre conceptos, superando las limitaciones de la recuperación puramente vectorial (Klesel et al., 2025).




Figura 2— Arquitectura general del sistema de Generación Aumentada por Recuperación (RAG).

3.2.2 Arquitectura Transformer y Mecanismo de Atención

El fundamento técnico de los LLMs y de los modelos de visión empleados en el presente proyecto reside en la arquitectura Transformer, introducida por Vaswani et al. (2017) en el trabajo seminal “Attention is All You Need”. A diferencia de las arquitecturas recurrentes (RNN/LSTM) que procesan secuencias de forma estrictamente secuencial, el Transformer opera mediante un mecanismo de *auto-atención* (*Self-Attention*) que calcula, en paralelo, la relevancia relativa de cada posición de la secuencia

respecto a todas las demás. Formalmente, la atención escalada de producto punto se define como:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (1)$$

donde

Q, K, V representan las matrices de *queries*, *keys* y *values* proyectadas;

d_k es la dimensión de las *keys*, cuya raíz cuadrada actúa como factor de escala para estabilizar los gradientes (Vaswani et al., 2017).

La extensión multi-cabeza (*Multi-Head Attention*) ejecuta múltiples operaciones de atención en paralelo sobre distintos subespacios de representación, permitiendo al modelo capturar simultáneamente dependencias sintácticas, semánticas y de largo alcance en el texto (Vaswani et al., 2017).




Figura 3— Mecanismo de auto-atención escalada por producto punto (Scaled Dot-Product Attention).

Esta arquitectura fue posteriormente adaptada al dominio de la visión por computadora mediante el Vision Transformer (ViT), que divide una imagen en parches (*patches*) de tamaño fijo, los proyecta linealmente

y los procesa como una secuencia de tokens, habilitando la captura de dependencias globales entre regiones de la imagen (M. Li et al., 2023). Es precisamente esta sinergia entre un codificador de visión basado en ViT y un decodificador de lenguaje autorregresivo la que subyace al modelo TrOCR, pilar tecnológico del módulo de transcripción de SynapTome.

3.2.3 Reconocimiento de Texto Manuscrito (HTR), TrOCR y Fórmulas Matemáticas

El Reconocimiento Óptico de Caracteres (OCR) tradicional se fundamenta en múltiples módulos independientes: preprocesamiento, segmentación, extracción de características mediante CNN y postprocesamiento, lo que genera una alta propagación de errores y una notable ineficiencia frente a caligrafía compleja (B. Zhang, 2026). Los sistemas CNN-RNN presentan además limitaciones al procesar texto manuscrito con alta variabilidad caligráfica, pues su campo receptivo local impide capturar dependencias de largo alcance entre caracteres (M. Li et al., 2023).

En contraparte, TrOCR unifica estas tareas en una arquitectura única de extremo a extremo. Emplea un codificador de visión preentrenado (BEiT o DeiT) para extraer características visuales de la imagen en parches, y un decodificador de lenguaje (RoBERTa) que genera el texto de manera autorregresiva M. Li et al. (2023). El modelo TrOCR_{LARGE} alcanza una Tasa de Error de Caracteres (CER) de apenas 2,89 % en el *benchmark* IAM, superando a todos los modelos CNN-RNN previos (Sharma et al., 2025).

Una dimensión especialmente crítica para SynapTome es el Reconocimiento de Expresiones Matemáticas Manuscritas (HMER, por sus siglas en inglés). A diferencia del texto corriente, las fórmulas matemáticas presentan una estructura bidimensional compleja: superíndices, subíndices, fracciones, integrales y símbolos especiales cuya disposición espacial es parte integrante de su significado. Los modelos encoder-decoder basados en Transformers, como UniMERNet, abordan esta complejidad mediante la generación directa de código $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ a partir de la imagen de la fórmula, logrando reconocer con alta precisión tanto expresiones impresas como manuscritas en escenarios reales (Alvarez-Perez et al., 2026). El conjunto de datos MathWriting, que provee anotaciones $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ para fórmulas manuscritas en línea (*online*) y fuera de línea (*offline*), constituye actualmente el referente de evaluación para estos modelos (Alvarez-Perez et al., 2026). En el contexto peruano, arquitecturas preentrenadas de esta familia

han demostrado ser viables incluso para manuscritos con alta variabilidad caligráfica (Tarazona Cruz, 2024).




Figura 4— Flujo de procesamiento híbrido de visión y lenguaje del modelo TrOCR.

3.2.4 Vector Embeddings y Bases de Datos Vectoriales

Los *embeddings* vectoriales son representaciones numéricas de alta dimensión que codifican el significado semántico de fragmentos de texto, imágenes u otros tipos de datos. La propiedad fundamental de estos vectores es que la proximidad geométrica en el espacio vectorial refleja similitud semántica: fragmentos con significado afín producen vectores cercanos, independientemente de si comparten vocabulario exacto (Gao et al., 2024). Este principio constituye la base técnica de la recuperación semántica en los sistemas RAG: al codificar tanto los fragmentos del corpus como la consulta del usuario en el mismo espacio vectorial, es posible recuperar los k fragmentos más relevantes mediante una búsqueda de vecinos más cercanos (k -NN search).

Para la persistencia y consulta eficiente de estos vectores en el contexto de SynapTome, la extensión `pgvector` para PostgreSQL representa la solución arquitectónica óptima. Esta extensión permite almacenar vectores de alta dimensión directamente en tablas relacionales y ejecutar búsquedas de similitud mediante los operadores de distancia coseno, euclídea o producto punto, combinando las capacidades de búsqueda semántica con las garantías ACID y las operaciones relacionales estándar de SQL (Afian et al., 2025). La indexación mediante estructuras HNSW (*Hierarchical Navigable Small World*) permite escalar estas búsquedas a millones de vectores con latencias de consulta inferiores a 10 ms, manteniendo una alta tasa de recuperación (*recall*) (Upadhyay et al., 2026). Esta arquitectura unificada — datos relacionales y vectores en una sola base de datos — simplifica significativamente la infraestructura del sistema y elimina la necesidad de sincronizar datos entre una base de datos relacional y un almacén vectorial independiente.




Figura 5— Similitud de coseno entre vectores en un espacio de embeddings multidimensional.

3.2.5 Grafos de Conocimiento

Los Grafos de Conocimiento son estructuras matemáticas que representan la información como una red semántica dirigida, conformada por nodos (entidades o tópicos) y aristas (relaciones). Esta topología permite capturar el contexto global y las relaciones transversales dentro de un corpus documental, sirviendo como esqueleto para la extracción de características y el aprendizaje representacional [T. Chen et al. \(2023\)](#). Una revisión sistemática reciente identifica que su principal aporte en educación reside en la capacidad de modelar la progresión del conocimiento del estudiante a lo largo del tiempo, conectando conceptos de distintas asignaturas y niveles cognitivos ([Abu-Salih et al., 2024](#)). En este sentido, permiten representar el estado de aprendizaje de cada alumno como una red dinámica de nodos de competencia, facilitando la personalización de rutas de estudio y la identificación de brechas conceptuales ([Soumya et al., 2025](#)).

En el contexto de sistemas de gestión del aprendizaje, estos mapas de tópicos transforman el contenido aislado en recursos enlazados, impulsando la “Inteligencia Colectiva” ([Obionwu et al., 2022](#)). La integración de grafos de conocimiento con arquitecturas RAG —denominada Graph-RAG— representa el estado del arte en recuperación semántica educativa: al estructurar el corpus de apuntes como un grafo, el sistema puede recorrer relaciones semánticas para recuperar fragmentos contextualmente relevantes que la búsqueda vectorial clásica no identificaría ([J. Li et al., 2025](#)). Para su implementación en el *backend*, PostgreSQL con pgvector garantiza la integridad, el indexado veloz y el almacenamiento seguro de los metadatos y vectores de las entidades semánticas ([Afian et al., 2025](#); [Upadhyay et al., 2026](#)).




Figura 6— Grafo relacional de conocimiento representando la progresión del estudiante.

3.2.6 Generación Automática de Evaluaciones Adaptativas

La generación automática de cuestionarios a partir del contenido de apuntes constituye una de las aplicaciones más directas de los LLMs en educación. Los sistemas basados en IA son capaces de producir ítems alineados con la Taxonomía de Bloom —desde preguntas de recordación hasta ítems de evaluación y creación— a partir de fragmentos de texto, reduciendo significativamente la carga docente (Lodovico Molina et al., 2025). Herramientas como QuizWiz demuestran que los LLMs integrados en plataformas educativas pueden generar cuestionarios personalizados y adaptativos en tiempo real, ajustando la dificultad al nivel de dominio actual del estudiante (Farah et al., 2024).

Los grafos de conocimiento desempeñan un rol instrumental en esta dinámica: al estructurar los apuntes como una red de conceptos relacionados, el sistema selecciona de forma dirigida los nodos temáticos sobre los cuales generar preguntas, garantizando cobertura curricular equilibrada y evitando redundancia (L. Zhang et al., 2026). Esta sinergia entre grafos de conocimiento y generación automática de evaluaciones constituye el núcleo de la variable independiente 3 del presente proyecto.

3.2.7 Aprendizaje Activo y Recuperación Espaciada (*Spaced Repetition*)

La Teoría de la Recuperación Espaciada (*Spaced Repetition*) se fundamenta en la curva del olvido de Ebbinghaus, que describe cómo la tasa de retención decae exponencialmente con el tiempo en ausencia de revisiones. La estrategia consiste en programar las revisiones de un concepto justo antes del momento en que será olvidado, maximizando la consolidación

en la memoria a largo plazo mediante el denominado *efecto de espaciado* (Huang, 2025). La práctica de recuperación activa (*Active Recall*) complementa esta estrategia: en lugar de releer pasivamente el material, el estudiante intenta recordar activamente la información, lo que fortalece las trazas mnémicas de forma significativamente más efectiva que la revisión pasiva; estudios recientes demuestran que los estudiantes que practican recuperación activa superan en más de un 50 % en pruebas diferidas a quienes solo releen el material (Huang, 2025).

Los sistemas de repetición espaciada modernos han evolucionado desde modelos de intervalo fijo —como el sistema Leitner— hacia algoritmos adaptativos basados en datos, como FSR5 (*Free Spaced Repetition Scheduler*), que estima dinámicamente el intervalo óptimo de revisión para cada ítem según el historial de respuestas del estudiante (Torres et al., 2025). La integración de LLMs en estos sistemas permite generar automáticamente las tarjetas de estudio (*flashcards*) a partir del contenido de los apuntes digitalizados, cerrando el ciclo entre transcripción, estructuración y refuerzo del aprendizaje (Torres et al., 2025). En el contexto de SynapTome, este módulo se articula directamente con el motor de grafos de conocimiento: los nodos con menor frecuencia de revisión o menor puntuación de dominio activan automáticamente la generación de nuevas instancias de práctica de recuperación.




Figura 7— Curva del olvido de Ebbinghaus y el impacto de los repasos programados.

3.2.8 Aprendizaje Colaborativo Mediado por Tecnología

El aprendizaje colaborativo, entendido como el proceso mediante el cual los estudiantes construyen conocimiento de forma conjunta a través del intercambio de recursos, ha sido ampliamente validado como estrategia que

mejora la retención y el desempeño académico (Kasirye, 2023). Una revisión sistemática de 148 artículos publicados entre 2021 y 2024 concluye que las herramientas de IA mejoran la personalización, la comunicación entre pares y el andamiaje del rendimiento, al tiempo que promueven entornos colaborativos mediante soporte de aprendizaje cooperativo (Msambwa et al., 2025). Sin embargo, la evidencia también advierte sobre una tensión emergente: el exceso de asistencia de IA en tareas de toma de notas puede reducir el compromiso cognitivo activo del estudiante (Tankelevitch et al., 2025), lo que sugiere que SynapTome debe calibrar el nivel de automatización para preservar el procesamiento profundo de la información.

3.2.9 Carga Cognitiva y Medición con NASA-TLX

La Teoría de la Carga Cognitiva postula que la memoria de trabajo humana posee una capacidad limitada para procesar información simultáneamente, y que el diseño de entornos de aprendizaje debe minimizar la carga extrínseca para maximizar los recursos cognitivos disponibles (Hart et al., 1988). Para la cuantificación objetiva de esta carga, el instrumento NASA Task Load Index (NASA-TLX) constituye el estándar de referencia más ampliamente adoptado. Evalúa seis dimensiones: Demanda Mental, Demanda Física, Demanda Temporal, Rendimiento, Esfuerzo y Frustración, obteniendo un índice global ponderado (Hart et al., 1988). Su validez ha sido reconfirmada recientemente en contextos de interacción humano-computadora (Babaei et al., 2025). En estudios con estudiantes universitarios, la Demanda Temporal y la Demanda Mental emergen como las dimensiones de mayor puntuación, con correlaciones significativas entre ambas ($\rho = 0,58$, $p < 0,001$), subrayando la relevancia de diseñar sistemas que reduzcan simultáneamente la presión temporal y el esfuerzo mental (Cahyadi et al., 2026).

3.2.10 Privacidad y Seguridad de Datos Estudiantiles en Plataformas IA

El despliegue de plataformas educativas potenciadas por IA implica la recopilación y procesamiento de datos estudiantiles altamente sensibles: registros académicos, patrones de comportamiento, historial de consultas y contenido de apuntes personales. La gestión ética y segura de estos datos es un imperativo técnico y legal que condiciona el diseño arquitectónico de SynapTome (Lněnička et al., 2024). En el ámbito normativo internacional, dos marcos regulatorios delimitan las obligaciones de las plataformas educativas: la Ley de Privacidad y Derechos Educativos de la Familia

(FERPA, por sus siglas en inglés), vigente en contextos anglosajones, y el Reglamento General de Protección de Datos (GDPR) de la Unión Europea, cuyo alcance extraterritorial puede afectar a cualquier plataforma que procese datos de ciudadanos europeos (Lněnička et al., 2024). Ambos marcos exigen el principio de *minimización de datos* —recopilar únicamente los datos estrictamente necesarios—, el consentimiento informado, y la implementación de salvaguardas técnicas como cifrado en reposo y en tránsito, control de acceso basado en roles (RBAC) y registros de auditoría. Adicionalmente, la Ley de Inteligencia Artificial de la Unión Europea (EU AI Act) clasifica los sistemas de IA utilizados en educación como sistemas de “alto riesgo”, lo que impone obligaciones adicionales de transparencia, explicabilidad y evaluación de impacto sobre la privacidad (DPIA) antes de su despliegue (Lněnička et al., 2024). En el diseño de SynapTome, estas consideraciones se traducen en la adopción de Arquitectura Limpia con separación estricta entre la capa de datos y los servicios de IA, el cifrado de los *embeddings* vectoriales almacenados en PostgreSQL, y la implementación de políticas de retención de datos que permitan la eliminación completa del historial de un estudiante a solicitud expresa.

3.2.11 Arquitectura Limpia (*Clean Architecture*)

La Arquitectura Limpia es un patrón de diseño de software que promueve la separación estricta de responsabilidades mediante un sistema de capas concéntricas, aislando la lógica de negocio y las reglas del dominio de los *frameworks*, interfaces de usuario o bases de datos Martín (2017). Su principio central, la Regla de Dependencia, establece que los módulos de alto nivel no deben depender de los de bajo nivel, sino que ambos deben depender de abstracciones (Martin, 2017).

En el desarrollo de plataformas educativas integrales, mantener un *backend* escalable y modular bajo este enfoque resulta indispensable para soportar *pipelines* intensivos de IA Upadhyay et al. (2026) y Solanki et al. (2026). Su aplicación en ecosistemas basados en C# y ASP.NET Core permite construir APIs RESTful robustas donde los controladores son totalmente independientes de los servicios de infraestructura como PostgreSQL o los motores de LLM, asegurando que la integración de nuevas tecnologías de IA no afecte el núcleo lógico del sistema (Afian et al., 2025).




Figura 8— Capas concéntricas de dependencias bajo el diseño de Arquitectura Limpia.

3.3 Marco conceptual

El marco conceptual establece los límites de comprensión y de definición de los componentes clave del ecosistema de software inteligente *SynapTome*. Este marco unifica las bases operativas de la inteligencia artificial generativa, el procesamiento del lenguaje natural, la ingeniería de software y las metodologías pedagógicas que sustentan la investigación:

- a) **LLM (Large Language Model / Modelo de Lenguaje Grande):** Red neuronal profunda de gran escala, fundamentada en la arquitectura Transformer, entrenada mediante corpus de datos masivos para modelar distribuciones probabilísticas de palabras y secuencias lingüísticas. Su rol en *SynapTome* comprende el análisis semántico de los apuntes transcritos, la generación automática de resúmenes explicativos y la estructuración de evaluaciones formativas de opción múltiple (Vaswani et al., 2017; KardanMoghaddam et al., 2025). No obstante, al ser modelos generativos puramente probabilísticos, adolecen del problema de alucinación cuando carecen de un contexto riguroso y acotado.
- b) **RAG (Retrieval-Augmented Generation / Generación Aumentada por Recuperación):** Arquitectura híbrida de procesamiento que restringe y guía el espacio de inferencia de un LLM mediante la inyección contextual de fragmentos informáticos pertinentes extraídos de un corpus cerrado y de autoridad (como textos de referencia provistos por el docente) (Kannammal et al., 2024). RAG opera transformando la consulta del usuario en un vector semántico, localizando los pasajes correspondientes con mayor similitud de

coseno, y presentándolos al LLM como base de datos irrefutable para la formulación de respuestas factualmente válidas, lo que reduce las tasas de error a niveles asintóticos seguros para la educación superior.

- c) **TrOCR (Transformer-based Optical Character Recognition / Reconocimiento de Texto basado en Transformers):** Modelo de visión y procesamiento del lenguaje natural de extremo a extremo que realiza la transcripción HTR (*Handwritten Text Recognition*) abstrayéndose de segmentaciones previas de líneas o caracteres. TrOCR consta de un codificador visual (Vision Transformer o ViT) que extrae un mapa de características desde la imagen del apunte manuscrito, y un decodificador autorregresivo (BART o RoBERTa) que traduce secuencialmente estas características visuales en texto plano y sintaxis algebraica estándar de $\text{\LaTeX}$ (B. Zhang, 2026; M. Li et al., 2023).
- d) **Grafo de Conocimiento (Knowledge Graph):** Red semántica dirigida que modela el conocimiento de forma relacional mediante una topología compuesta por nodos (que representan tópicos, conceptos o fórmulas del plan de estudios de ingeniería) y aristas etiquetadas (que especifican la dirección y tipo de relación conceptual, como .es requisito de.º complementa a”) (T. Chen et al., 2023). Permite a los estudiantes navegar intuitivamente a través de las interconexiones cognitivas y estructurar rutas de estudio lógicas.
- e) **Topic Maps (Mapas de Tópicos):** Estándar formal (ISO/IEC 13250) diseñado para representar estructuras semánticas y organizar colecciones de información multimedia mediante un modelo abstracto de tres pilares: tópicos (conceptos), asociaciones (relaciones multilaterales entre los tópicos) y ocurrencias (enlaces directos a recursos de información externos, tales como fragmentos de PDF o videos explicativos) (Obionwu et al., 2022; Jiang et al., 2025).
- f) **Incrustaciones Vectoriales (Vector Embeddings):** Representaciones matemáticas de fragmentos conceptuales o semánticos dentro de un espacio vectorial continuo de alta dimensión (típicamente entre 384 y 1536 dimensiones). Estas representaciones se obtienen mediante modelos preentrenados donde la cercanía métrica (similitud de coseno) indica correspondencia conceptual directa, permitiendo búsquedas semánticas altamente precisas que superan la indexación tradicional de palabras clave (Klesel et al., 2025).
- g) **Ajuste Fino (Fine-tuning):** Proceso de entrenamiento secundario mediante el cual un modelo de red neuronal previamente entrenado en un corpus de datos masivos genéricos es reentrenado con un conjunto de datos altamente

especializado (por ejemplo, caligrafía matemática manuscrita de estudiantes locales) con el fin de optimizar y ajustar sus pesos sin perder su capacidad de abstracción de bajo nivel, maximizando la precisión de la transcripción a $\text{\LaTeX}$ ([Alvarez-Perez et al., 2026](#)).

- h) **CER y WER (Character/Word Error Rate / Tasa de Error de Caracteres y Palabras):** Métricas experimentales que evalúan la precisión de las transcripciones de texto mediante la distancia de edición de Levenshtein, que cuantifica el número mínimo de operaciones de inserción, eliminación o sustitución necesarias para transformar el texto predicho por el modelo en la referencia humana correcta, dividida por el total de elementos de la cadena patrón ([Al-Hitawi et al., 2026](#)).
- i) **ROUGE y BERTScore:** Métricas complementarias de evaluación de síntesis de texto: ROUGE mide la coincidencia física de n-gramas entre la salida generada y el resumen patrón, en tanto que BERTScore calcula la similitud del coseno entre los embeddings contextuales generados por un transformador (como BERT) de ambas cadenas, valorando la equivalencia conceptual y la fidelidad de las ideas sin forzar coincidencia sintáctica exacta ([Saxena et al., 2025](#)).
- j) **Clean Architecture (Arquitectura Limpia):** Patrón de diseño de software centrado en el dominio que organiza los componentes del sistema en círculos concéntricos regidos por la regla de dependencia unidireccional (las capas externas conocen a las internas, pero las internas nunca conocen a las externas). Esto aísla las reglas de negocio críticas del sistema (Casos de Uso y Entidades) de factores volátiles como bases de datos, APIs de modelos de lenguaje o frameworks de frontend ([Martin, 2017](#)).
- k) **SignalR y WebSockets:** Tecnologías de comunicación bidireccional y dúplex completo que facilitan el intercambio asíncrono y en tiempo real de datos ligeros entre el servidor y los clientes conectados, eliminando la necesidad de realizar peticiones de sondeo continuas (*polling*) y habilitando la coedición de apuntes y la sincronización concurrente de las dinámicas colaborativas estudiantiles ([Shirkande et al., 2025](#)).
- l) **JWT (JSON Web Token):** Estándar abierto compacto (RFC 7519) que encapsula de forma segura claims de identidad de los usuarios mediante una estructura firmada digitalmente compuesta por una cabecera, una carga útil codificada en Base64 y una firma criptográfica hash que garantiza la autenticidad y evita la suplantación de identidad en llamadas REST APIs ([Jones et al., 2015](#)).

- 874 m) **PostgreSQL y Extensiones Especializadas:** Sistema relacional de gestión
875 de bases de datos objeto-relacional que, mediante el uso de extensiones
876 de bajo nivel como pgvector y modelados relacionales avanzados de gra-
877 fos, unifica el almacenamiento transaccional tradicional de calificaciones
878 con la persistencia relacional-semántica de las redes académicas de estudio
879 ([Upadhyay et al., 2026](#)).
- 880 n) **Carga Cognitiva (Teoría de Sweller):** Modelo psicopedagógico que des-
881 cribe el esfuerzo del procesamiento mental requerido por la memoria de
882 trabajo humana para asimilar contenidos educativos nuevos. Divide este
883 esfuerzo en tres categorías: carga intrínseca (dificultad inherente al tema),
884 carga extrínseca (esfuerzo innecesario debido al formato o desorganización
885 de la instrucción) y carga germánica (esfuerzo constructivo dedicado a crear
886 esquemas cognitivos estables) ([Hart et al., 1988](#)).
- 887 ñ) **Repeticón Espaciada (Spaced Repetition):** Técnica de aprendizaje acti-
888 vo que contrarresta los efectos de la curva de decaimiento del olvido de
889 Ebbinghaus distribuyendo los repases de fichas y cuestionarios de autoeva-
890 luación en intervalos de tiempo crecientes y programados automáticamente
891 por algoritmos adaptativos para consolidar la información en la memoria a
892 largo plazo ([Kreijkes et al., 2026](#)).

893
894
895
896

897
898

CAPÍTULO IV METODOLOGÍA

899

4.1 Tipo y nivel de investigación

900
901
902
903
904
905
906
907
908
909
910
911
912

La presente investigación se clasifica por su propósito como Tecnológica Aplicada, dado que busca resolver un problema práctico y concreto: la sobrecarga cognitiva y la desorganización de apuntes en el entorno universitario, mediante el desarrollo de una solución de software (SynapTome). Por su alcance y profundidad, el estudio corresponde a un nivel explicativo-experimental (específicamente, un diseño cuasi-experimental). Este nivel permite no solo describir el ecosistema desarrollado, sino también determinar las relaciones de causa y efecto que la Variable Independiente (el ecosistema basado en RAG, TrOCR y Grafos de Conocimiento) ejerce sobre la Variable Dependiente (la retención de conocimientos y el rendimiento académico). Como señalan [Kreijkes et al. \(2026\)](#), el uso de diseños experimentales en entornos educativos es fundamental para cuantificar de manera objetiva los efectos de las herramientas basadas en LLMs sobre la comprensión lectora y la memoria de los estudiantes.

913

4.2 Diseño de la investigación

914
915
916

Para abordar la complejidad del ecosistema SynapTome, el diseño metodológico se divide en dos vertientes complementarias: un diseño de ingeniería de software y un diseño de validación académica.

917
918
919
920
921
922
923

- Diseño de Ingeniería de Software: Se emplea la metodología ágil Scrum. Según [Afian et al. \(2025\)](#), las metodologías ágiles soportan el desarrollo iterativo, la retroalimentación continua y la adaptabilidad, características esenciales para el desarrollo de plataformas de tutoría impulsadas por inteligencia artificial. El desarrollo se estructura en sprints que abarcan la planificación, el diseño, la implementación del backend y los pipelines de IA, y las pruebas continuas de las funciones.

924
925
926
927

- Diseño de Evaluación (Validación): Se utiliza un diseño de tipo pre-test / post-test con un grupo cuasi-experimental. Se mide el desempeño académico (retención de conocimientos) de los estudiantes antes de la adopción del ecosistema SynapTome y, tras un periodo de uso continuo de la herramienta,

928 se aplica un post-test para evaluar el impacto real generado por la plataforma
929 interactiva en la retención del conocimiento.

930 **4.3 Descripción ética de la investigación**

931 El desarrollo y despliegue del ecosistema SynapTome se adhiere a estrictos
932 estándares de ética y privacidad de la información (Kreijkes et al., 2026; Dano
933 et al., 2026). Antes de iniciar las pruebas, se obtiene un consentimiento informado
934 por escrito de los estudiantes de la UNAMBA, garantizando que su participación
935 sea voluntaria y que tengan el derecho de retirarse del estudio en cualquier mo-
936 mento.

937 A nivel técnico, el tratamiento de los datos personales y el contenido de los apun-
938 tes manuscritos subidos por los usuarios se gestiona con políticas de seguridad de
939 grado industrial. Para asegurar la protección de los datos en tránsito y en reposo, la
940 arquitectura implementa autenticación segura mediante tokens JWT (JSON Web
941 Tokens) en los endpoints de la API, mientras que toda la información persistente,
942 incluidas las métricas de evaluación y los grafos relacionales, es resguardada en
943 una base de datos PostgreSQL aplicando el encriptado adecuado, evitando el acce-
944 so no autorizado y manteniendo la confidencialidad de la información académica
945 y personal (Upadhyay et al., 2026).

946 **4.4 Procedimiento**

947 El procedimiento general de la investigación comprende cinco fases sistemáticas,
948 desde el levantamiento de requisitos hasta la evaluación del sistema "SynapTome.^{en}
949 un entorno real con estudiantes de Ingeniería de Sistemas de la UNAMBA.

950 Como parte fundamental de la fase de integración tecnológica, se diseñó e im-
951 plementó un pipeline de procesamiento asíncrono desacoplado para operativizar
952 la transformación de los apuntes manuscritos analógicos a formato digital de alta
953 fidelidad. Este flujo de trabajo actúa directamente sobre la eficiencia de captura
954 de información y se detalla a continuación:

- 955 1. **Preprocesamiento y normalización de imagen:** Se realiza la captura fo-
956 tográfica del apunte manuscrito por parte del estudiante. La imagen es envia-
957 da al servidor donde se aplican filtros de binarización adaptativa de Sauvola,
958 corrección de inclinación (*deskewing*) y reducción de ruido gaussiano para
959 optimizar el contraste de los trazos de tinta.
- 960 2. **Inferencia autorregresiva (TrOCR):** La imagen normalizada segmentada
961 en bloques de interés matemático se procesa mediante la arquitectura de
962 aprendizaje profundo TrOCR. El codificador visual de tipo Vision Trans-
963 former (ViT) genera los mapas de características latentes que representan

los trazos caligráficos. Posteriormente, el decodificador de lenguaje decodifica estos vectores en secuencias de caracteres que representan fórmulas en sintaxis $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ válida y texto plano.

3. **Sanitización semántica y post-procesamiento:** Se aplica un analizador sintáctico (*parser*) desarrollado para corregir errores comunes de balanceo de llaves, delimitadores matemáticos y etiquetas algebraicas, garantizando que el código de renderizado sea completamente válido y almacenable en PostgreSQL como un nodo estructurado.

Este pipeline de IA se ilustra en la Figura 9.




Figura 9— Pipeline adaptativo de transcripción caligráfica manuscrita (HTR) e integración RAG/Grafo en el ecosistema SynapTome.

Las actividades específicas, tecnologías empleadas y entregables documentados para cada una de las fases de la investigación se detallan en la Tabla 3.

Tabla 3— Fases del procedimiento de investigación

Fase	Actividades	Herramientas / Tecnologías	Entregable
1. Levantamiento de requisitos y diseño	Identificación de las necesidades de digitalización y colaboración de los estudiantes; diseño de la arquitectura del ecosistema (modelo relacional y lógica de grafos de conocimiento) (Afian et al., 2025)	Diagramas UML, modelo entidad-relación, PostgreSQL	Documento de requisitos y diagrama de arquitectura
2. Desarrollo (Backend y Frontend)	Construcción del núcleo del sistema bajo Clean Architecture: orquestación de la lógica de negocio e integración con APIs de IA en el backend, y desarrollo de una interfaz reactiva y colaborativa en el frontend (Martin, 2017; Afian et al., 2025)	C# / ASP.NET Core, Next.js, React, PostgreSQL	Prototipo funcional (módulos CRUD y autenticación JWT)
3. Integración de RAG y TrOCR	Implementación del middleware RAG para acoplar la recuperación de vectores semánticos con los LLMs; fine-tuning de la arquitectura TrOCR con corpus matemático y manuscrito para adaptar el modelo al dominio (Kannammal et al., 2024; B. Zhang, 2026; Alvarez-Perez et al., 2026)	Bases de datos vectoriales, TrOCR, LLM (API), Python para fine-tuning	Pipeline de IA integrado (módulo OCR + módulo RAG)
4. Pruebas alfa y beta	Pruebas de caja negra, pruebas unitarias automatizadas y pruebas preliminares con un grupo reducido de usuarios para depurar errores de concurrencia y validar la Sincronización: Óptima < 2 s Aceptable 2–5 s (Shirkande et al., 2025)	SignalR (WebSockets), frameworks de testing (xUnit / Jest)	Reporte de pruebas y correcciones
5. Evaluación en entorno real	Despliegue de SynapTome para la muestra de estudiantes de la UNAMBA; ejecución de pre-test y post-test; recolección de datos de rendimiento y métricas del sistema	Cuestionarios digitales, panel de métricas del sistema	Base de datos de resultados (pre/post-test)

4.5 Población y muestra

4.5.1 Población

La población objetivo de la presente investigación está conformada por los estudiantes matriculados en la Escuela Profesional de Ingeniería de Informática y Sistemas de la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), quienes cursan asignaturas de alta carga cognitiva y densidad matemática en el semestre académico correspondiente. La población censal estimada para las asignaturas de ciencias básicas y especializadas (tales como Cálculo, Álgebra Lineal y Física) es de aproximadamente $N = 120$ alumnos distribuidos en diferentes ciclos académicos.

4.5.2 Muestra

Para determinar el tamaño representativo de la muestra bajo condiciones de población finita, se empleó la fórmula estándar de muestreo aleatorio simple para estimar proporciones en poblaciones conocidas:

$$n = \frac{N \cdot Z^2 \cdot p \cdot q}{d^2 \cdot (N - 1) + Z^2 \cdot p \cdot q} \quad (2)$$

donde

n es el tamaño de la muestra requerida;
 N es el tamaño de la población conocida ($N = 120$);
 Z es el nivel de confianza estándar ($Z = 1,96$ para un nivel de confianza del 95 %);
 p es la probabilidad esperada de éxito ($p = 0,50$, asumiendo máxima heterogeneidad);
 q es la probabilidad de fracaso ($q = 1 - p = 0,50$);
 d es la precisión o margen de error admisible ($d = 0,05$).

Reemplazando los valores en la ecuación:

$$n = \frac{120 \cdot (1,96)^2 \cdot 0,50 \cdot 0,50}{(0,05)^2 \cdot (120 - 1) + (1,96)^2 \cdot 0,50 \cdot 0,50} \approx 92 \quad (3)$$

donde

n es el resultado del cálculo que define la muestra representativa mínima.

Dado el carácter tecnológico y la factibilidad del estudio en laboratorios de cómputo, se seleccionó una muestra no probabilística por conveniencia de 30 estudiantes que cumplieran con los criterios de inclusión: estar matriculados regularmente, tener disponibilidad horaria para interactuar con la plataforma SynapTome y estar cursando asignaturas técnicas simultáneamente (Kreijkes et al., 2026).

4.6 Técnicas e instrumentos

Para medir de manera rigurosa la eficacia algorítmica del sistema y el nivel de aceptación por parte de los usuarios, se emplean técnicas mixtas (cuantitativas y cualitativas), combinando la evaluación experimental del rendimiento de los modelos de IA con la percepción subjetiva de los estudiantes.

4.6.1 Técnicas

- **Análisis documental:** Revisión de antecedentes, literatura técnica y datasets de referencia (por ejemplo, SPA-Sentences) para establecer las líneas base de comparación de los modelos de OCR/HTR y sumariación (Tarazona Cruz, 2024).
- **Experimentación:** Ejecución controlada del pipeline TrOCR y del módulo RAG sobre un conjunto de apuntes manuscritos y resúmenes generados, registrando los resultados de manera cuantitativa (Al-Hitawi et al., 2026).

- **Encuesta:** Aplicación de cuestionarios estructurados a los estudiantes participantes para recoger su percepción sobre la usabilidad, utilidad y satisfacción con SynapTome ([Afian et al., 2025](#); [Dano et al., 2026](#)).

4.6.2 Instrumentos

La Tabla 4 detalla los instrumentos empleados para cada técnica, indicando la variable que mide y la escala o métrica utilizada.

Tabla 4— Instrumentos de recolección de datos

Instrumento	Variable / Dimensión que mide	Escala / Métrica	Fuente
Ficha de registro de transcripción OCR	Eficiencia de captura técnica (preservación de información manuscrita)	Tasa de Error de Caracteres (CER %) y $\LaTeX$ válido	(Al-Hitawi et al., 2026)
Ficha de evaluación de fidelidad conceptual	Calidad factual del repaso (reducción de errores conceptuales en notas)	Índice de alucinación (%) y coherencia de resúmenes	(Saxena et al., 2025 ; Ning et al., 2025)
Cuestionario NASA-TLX (Carga Mental)	Sobrecarga cognitiva y fatiga mental del estudiante en su autoestudio	Escala ordinal de carga de trabajo (0–100 ptos)	(Hart et al., 1988)
Cuestionario de usabilidad (SUS)	Eficiencia operativa del sistema	Puntuación normalizada SUS (0–100)	(Afian et al., 2025)
Evaluación Pre-test / Post-test de retención	Rendimiento académico e incremento de la fijación conceptual a largo plazo	Calificación cuantitativa (Escala vigesimal 0–20)	(Kreijkes et al., 2026)

4.7 Estadístico de la investigación

La contrastación de las hipótesis y la validación de la eficacia técnica del sistema SynapTome requieren un marco estadístico formal estructurado en función de los datos recolectados.

4.7.1 Datos

Los datos experimentales recolectados constan de variables cuantitativas continuas distribuidas en:

- Calificaciones obtenidas por los estudiantes en las evaluaciones de retención conceptual (escala vigesimal de 0 a 20) antes (pre-test) y después (post-test) de interactuar con el ecosistema.
- Tiempos semanales de transcripción y consolidación de apuntes (minutos).
- Índices porcentuales de error de caracteres (CER) y palabras (WER).
- Puntajes ordinales de carga mental subjetiva de trabajo (NASA-TLX) y usabilidad del sistema (SUS).

4.7.2 Estadístico

Se justifica el uso de la prueba paramétrica **T de Student para muestras relacionadas (pares)**, dado que se evalúa el rendimiento del mismo grupo

de estudiantes (diseño de pre-test / post-test) antes y después de aplicar el estímulo (el uso de la plataforma SynapTome). Esta prueba asume que las diferencias entre los pares siguen una distribución aproximadamente normal.

4.7.3 Fórmulas

Todas las ecuaciones matemáticas empleadas en el análisis de datos se definen formalmente a continuación:

4.7.3.1 Tasa de Error de Caracteres (CER):

Mide la precisión del reconocimiento caligráfico mediante la distancia de edición de Levenshtein:

$$CER = \frac{S + D + I}{N} \quad (4)$$

donde

S es el número de sustituciones de caracteres requeridas;

D es el número de eliminaciones de caracteres requeridas;

I es el número de inserciones de caracteres requeridas;

N es el número total de caracteres en la cadena de referencia.

4.7.3.2 Tasa de Error de Palabras (WER):

$$WER = \frac{S_w + D_w + I_w}{N_w} \quad (5)$$

donde

S_w es el número de sustituciones de palabras requeridas;

D_w es el número de eliminaciones de palabras requeridas;

I_w es el número de inserciones de palabras requeridas;

N_w es el número total de palabras en la cadena de referencia.

4.7.3.3 Métrica de Superposición ROUGE-N:

Evalúa la coincidencia exacta de n-gramas en la síntesis conceptual:

$$\text{ROUGE-N} = \frac{\sum_{S \in \{\text{Referencias}\}} \sum_{\text{gram}_n \in S} \text{Count}_{\text{match}}(\text{gram}_n)}{\sum_{S \in \{\text{Referencias}\}} \sum_{\text{gram}_n \in S} \text{Count}(\text{gram}_n)} \quad (6)$$

donde

$\text{Count}_{\text{match}}$ es el número de n-gramas coincidentes entre el resumen del sistema y la referencia;

Count es el número total de n-gramas en la referencia.

4.7.3.4 Fórmula de Usabilidad del Sistema (SUS):

$$\text{SUS} = 2,5 \times \sum_{i=1}^{10} x'_i \quad (7)$$

donde

x'_i es la puntuación corregida para el ítem i , restando 1 si es impar o restando a 5 si es par.

4.7.3.5 Magnitud del Efecto (d de Cohen):

$$d = \frac{\bar{d}}{s_d} \quad (8)$$

donde

$\bar{d}$ es la media de las diferencias individuales pre/post;

s_d es la desviación estándar muestral de las diferencias observadas.

4.7.4 Nivel de significancia

El nivel de significancia se fija en $\alpha = 0,05$ (nivel de confianza del 95 %).

Este valor determina la probabilidad máxima de rechazar erróneamente la hipótesis nula.

4.7.5 Estadístico de prueba

La hipótesis de investigación establece que la implementación de SynapTome incrementa significativamente el rendimiento académico de los estudiantes frente al método convencional. Por ende, la prueba de hipótesis

es unilateral derecha:

$$H_0 : \mu_{\text{post}} \leq \mu_{\text{pre}} \quad \text{vs} \quad H_1 : \mu_{\text{post}} > \mu_{\text{pre}} \quad (9)$$

El estadístico de prueba t calculado se define como:

$$t = \frac{\bar{d}}{s_d / \sqrt{n}} \quad (10)$$

donde

- t es el valor del estadístico de prueba calculado;
- $\bar{d}$ es el promedio muestral de las diferencias observadas;
- s_d es la desviación estándar muestral de las diferencias;
- n es el tamaño total de la muestra analizada.

4.7.6 Región crítica

Para un nivel de significancia de $\alpha = 0,05$ y grados de libertad $gl = n - 1 = 2$ (bajo métricas de validación general), se define el valor límite $t_{\text{crítico}} = 2,92$. La región de rechazo de la hipótesis nula se encuentra en la cola derecha de la distribución.

La Figura 10 ilustra la representación gráfica de la región crítica teórica para una prueba unilateral derecha:




Figura 10— Representación gráfica de la curva de densidad t de Student unilateral derecha y la región crítica de rechazo.

4.7.7 Interpretación

El criterio de decisión estadística consiste en comparar el estadístico calculado $t_{\text{calculado}}$ frente al valor de umbral $t_{\text{crítico}}$:

- 1086
- 1087
- 1088
- 1089
- 1090
- 1091
- 1092
- Si $t_{\text{calculado}} > 2,92$, el estadístico muestral cae dentro de la región de rechazo, por lo que se rechaza la hipótesis nula H_0 en favor de la hipótesis alternativa H_1 , concluyendo que el uso de SynapTome incrementa el rendimiento académico y disminuye la carga cognitiva de forma de manera estadísticamente significativa.
 - Si $t_{\text{calculado}} \leq 2,92$, no existe evidencia estadística suficiente para rechazar H_0 .

1093
1094
1095
1096
1097

1098
1099

CAPÍTULO V

ADMINISTRACIÓN DEL PROYECTO

1100
1101
1102
1103
1104
1105

5.1 Cronograma de actividades

El proyecto de investigación se desarrollará durante el año académico 2026, organizado en seis fases secuenciales, con una duración total de seis meses. Las Tablas 5 y 6 presentan la distribución temporal de las actividades por fase, desde la planificación y revisión bibliográfica hasta la evaluación final del sistema y el análisis estadístico de los resultados.

Tabla 5— Cronograma de actividades – Fases I a III (Julio – Diciembre 2026)

Fases y Actividades (2026)	Jul				Ago				Sep				Oct				Nov				Dic			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Fase I: Planificación y revisión bibliográfica																								
1. Revisión sistemática de literatura y antecedentes	X	X																						
2. Elaboración y aprobación del proyecto de tesis	X	X																						
3. Coordinación institucional con la UNAMBA			X	X																				
4. Diseño preliminar de la arquitectura (BD relacional y grafos)			X	X																				
Fase II: Diseño y desarrollo del backend																								
5. Levantamiento de requisitos funcionales y no funcionales					X																			
6. Diseño de BD (PostgreSQL) y modelado de grafos					X	X																		
7. Desarrollo del backend (ASP.NET Core, Clean Architecture, JWT)						X	X	X																
8. Diseño de interfaces (mockups) de SynapTome					X	X																		
Fase III: Desarrollo del frontend y colaboración en tiempo real																								
9. Desarrollo del frontend (Next.js / React)									X	X	X													
10. Integración de SignalR (colaboración en tiempo real)										X	X	X												
11. Pruebas unitarias de los módulos CRUD											X	X												

Tabla 6— Cronograma de actividades – Fases IV a VI (Julio – Diciembre 2026)

Fases y Actividades (2026)	Jul				Ago				Sep				Oct				Nov				Dic			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Fase IV: Integración de los módulos de IA (RAG y TrOCR)																								
12. Implementación del middleware RAG													X	X										
13. Fine-tuning de TrOCR (corpus matemático y manuscrito)													X	X	X									
14. Integración del pipeline IA (RAG + TrOCR) al backend															X	X								
Fase V: Pruebas del sistema y pre-test																								
15. Pruebas de caja negra y depuración																	X	X						
16. Pruebas alfa y beta con usuarios																		X	X					
17. Aplicación del pre-test (muestra UNAMBA)																			X	X				
18. Despliegue de SynapTome (evaluación real)																				X				
Fase VI: Evaluación final y análisis de resultados																								
19. Implementación y uso real con la muestra																					X	X		
20. Aplicación del post-test (SUS / UAT)																						X	X	
21. Análisis estadístico (T-Student, <i>d</i> de Cohen)																							X	
22. Redacción de resultados y conclusiones																							X	X
23. Revisión final y entrega de tesis																								X

5.2 Presupuesto

La Tabla 7 presenta el presupuesto estimado para el desarrollo del proyecto de investigación, organizado por categorías de gasto. Las principales herramientas de software (Visual Studio, .NET SDK, Next.js y Jamovi) se utilizarán bajo licencias gratuitas u *open source*, mientras que los principales costos corresponden al consumo de APIs de modelos de lenguaje, al hosting del sistema y a la aplicación de instrumentos a la muestra de estudiantes.

Tabla 7— Presupuesto estimado del proyecto de investigación

N.º	Descripción	Cantidad	P. unitario (S/)	Total (S/)
Hardware				
1	Laptop de desarrollo (equipo ya disponible)	1	0,00	0,00
2	Tablet con lápiz óptico para pruebas de digitalización de apuntes (TrOCR)	1	850,00	850,00
3	Cuadernos y materiales para conformar el corpus de apuntes manuscritos	1	50,00	50,00
Software y servicios en la nube				
4	Visual Studio Community / .NET SDK (licencia gratuita — <i>open source</i>)	1	0,00	0,00
5	Créditos de API de LLM (Anthropic / OpenAI) para RAG y summarización	6 meses	80,00	480,00
6	Hosting del backend (Azure App Service / Railway, plan básico)	6 meses	35,00	210,00
7	Base de datos PostgreSQL en la nube (Supabase / Neon, plan gratuito)	6 meses	0,00	0,00
8	Dominio web (.com)	1	45,00	45,00
9	Jamovi / JASP (software estadístico, licencia gratuita)	1	0,00	0,00
Recursos humanos y servicios				
10	Impresión y aplicación de cuestionarios (SUS, UAT, pre-test y post-test)	120	1,00	120,00
11	Movilidad para coordinación institucional con la UNAMBA	6 salidas	15,00	90,00
12	Material de oficina (papel, lapiceros, impresiones generales)	1	100,00	100,00
TOTAL GENERAL				S/ 1 945,00

5.3 Fuente de financiamiento

El presente proyecto de investigación será financiado íntegramente con recursos propios del investigador. La mayor parte de las herramientas de software utilizadas

1116 (Visual Studio, .NET SDK, Next.js, React y Jamovi) son de acceso gratuito o de
1117 código abierto, mientras que los servicios en la nube (créditos de API de LLM,
1118 hosting y base de datos) se mantienen dentro de planes básicos o niveles gratuitos,
1119 lo que reduce significativamente los costos del proyecto.

1120
1121
1122
1123

REFERENCIAS BIBLIOGRÁFICAS

1125

1126 ABU-SALIH, Bilal y ALOTAIBI, Salihah, 2024. A Systematic Literature Review of Know-
1127 ledge Graph Construction and Application in Education. *Heliyon*. Vol. 10, n.º 3, e25383.
1128 Disp. desde DOI: [10.1016/j.heliyon.2024.e25383](https://doi.org/10.1016/j.heliyon.2024.e25383).

1129

1130 AFIAN, M. et al., 2025. Real-Time Collaborative Systems and Cloud-Based Architectural
1131 Frameworks for Academic Knowledge Management. *Journal of Systems and Software Engi-
1132 neering Applications*. Vol. 42, n.º 2, págs. 115-128. Disp. desde DOI: [10.1016/j.jssea.
1133 2024.10.012](https://doi.org/10.1016/j.jssea.2024.10.012).

1134

1135 ALVAREZ-PEREZ, Rodrigo y BARRÓN-FERNANDEZ, Ricardo, 2026. Fine tuning Trans-
1136 formers models for converting handwritten scientific texts into LaTeX format. *International
1137 Journal of Combinatorial Optimization Problems and Informatics*. Vol. 17, n.º 2, págs. 38-54.

1138

1139 BABAEI, Ebrahim; DINGLER, Tilman; TAG, Benjamin y VELLOSO, Eduardo, 2025.
1140 Should We Use the NASA-TLX in HCI? A Review of Theoretical and Methodological
1141 Issues Around Mental Workload Measurement. *International Journal of Human-Computer
1142 Studies*. Vol. 201, pág. 103515. Disp. desde DOI: [10.1016/j.ijhcs.2025.103515](https://doi.org/10.1016/j.ijhcs.2025.103515).

1143

1144 CAHYADI, A. et al., 2026. Cognitive Load During Student-Created Virtual Worlds: A
1145 NASA-TLX Assessment Using Spatial.io. *Multimodal Technologies and Interaction*. Vol. 5,
1146 n.º 2, pág. 22. Disp. desde DOI: [10.3390/mti5020022](https://doi.org/10.3390/mti5020022).

1147

1148 CHEN, Tong; WANG, Xuwei; YUE, Tianwei; BAI, Xiaoyu; LE, Cindy X. y WANG, Wen-
1149 ping, 2023. Enhancing Abstractive Summarization with Extracted Knowledge Graphs and
1150 Multi-Source Transformers. *Applied Sciences*. Vol. 13, n.º 7753.

1151

1152 DANO, Marydil Anne L.; BANDONG, Samantha Nicole Y.; CABALHUG, Mae Kyla Brig-
1153 gette P.; CARACA, Shyra Beth L.; DONGUINES, Henrey Daniel M.; ELPEDEZ, Edmark
1154 Iren B.; LAJERA, Sophia Nicole C.; LAZARRAGA, Michael Joseph P.; PUCHERO, Ju-
1155 dee Anthonette D.; RADO, John Laurence K.; CUI-TORING, Kimberly N. y TORING,

- 1156 Eugene E., 2026. Digital Note Taking, Traditional Handwritten Notes, and Academic Perfor-
1157 mance Among University Students. *Journal of Advanced Studies in Aviation, Aerospace, and*
1158 *Management*. Vol. 1, n.º 4.
1159
- 1160 FARAH, Joëlle et al., 2024. QuizWiz: Integrating Generative Artificial Intelligence in an
1161 Online Study Tool. En: *Proceedings of the 2024 7th International Conference on Big Data*
1162 *and Education (ICBDE)*. ACM. Disp. desde doi: [10.1145/3704289.3704296](https://doi.org/10.1145/3704289.3704296).
1163
- 1164 GAO, Yunfan; XIONG, Yun; GAO, Xinyu; JIA, Kangxiang; PAN, Jinliang; BI, Yuxi; DAI, Yi;
1165 SUN, Jiawei; GUO, Qianyu; WANG, Meng y WANG, Haofen, 2024. Retrieval-Augmented
1166 Generation for Large Language Models: A Survey. *arXiv preprint*. arXiv:2312.10997.
1167
- 1168 HART, Sandra G. y STAVELAND, Lowell E., 1988. Development of NASA-TLX (Task Load
1169 Index): Results of Empirical and Theoretical Research. *Advances in Psychology*. Vol. 52,
1170 págs. 139-183. Disp. desde doi: [10.1016/S0166-4115\(08\)62386-9](https://doi.org/10.1016/S0166-4115(08)62386-9).
1171
- 1172 AL-HITAWI, Mohammed A.S. y GYÖNGYÖSSY, N. M., 2026. Enhancing Transformer-
1173 Based Language Models for Hungarian Handwritten Text Recognition. *F1000Research*.
1174 Vol. 15, n.º 181.
1175
- 1176 HUANG, Ming, 2025. Spaced Repetition and Retrieval Practice: Efficient Learning Mecha-
1177 nisms from a Cognitive Psychology Perspective and Their Empowerment by AI. *International*
1178 *Journal of Asian Social Science Research*. Vol. 2, n.º 6, págs. 31-37.
1179
- 1180 JIANG, Mi; GAO, Junran; PAN, Zeyu; WU, Yue y WANG, Zile, 2025. NexaNota: An AI-
1181 Powered Smart Linked Lecture Note-Taking System Leveraging Large Language Models.
1182 En: *2025 International Conference on Big Data and Informatization Education (ICBDIE)*.
1183 ACM.
1184
- 1185 JONES, Michael B.; BRADLEY, John y SAKIMURA, Nat, 2015. *JSON Web Token (JWT)*
1186 [RFC 7519, IETF]. Disponible también desde: [https://www.rfc-editor.org/rfc/](https://www.rfc-editor.org/rfc/rfc7519)
1187 [rfc7519](https://www.rfc-editor.org/rfc/rfc7519).
1188
- 1189 KANNAMMAL, K. E.; BHARATH KUMAR, M. S.; DHARANI DARAN, G.; KAVIN
1190 KRISHNA, S.; KAMALI, S. y MAAJIDA, A., 2024. NoteFlow AI. *International Journal of*
1191 *Scientific Research in Engineering and Management (IJSREM)*.
1192
- 1193 KARDANMOGHADDAM, Hossein; AKBARIMAJD, Adel; RANJBARPOUR, Moham-
1194 mad; NOOSHYAR, Mahdi y JAMALI, Shahram, 2025. A Structure Based on TrOCR Trans-

former and Large Language Model for Classification of Handwritten Texts. *Facta Universitatis, Series: Electronics and Energetics*. Vol. 38, n.º 4, págs. 697-714.

KASIRYE, Fred, 2023. Collaborative Learning and Higher Education. *Globalization and Business*. N.º 15.

KLESEL, Michael y WITTMANN, H. F., 2025. Retrieval-Augmented Generation (RAG). *Business & Information Systems Engineering*. Vol. 67, n.º 4, págs. 551-561. Disp. desde DOI: [10.1007/s12599-025-00934-4](https://doi.org/10.1007/s12599-025-00934-4).

KREIJKES, Pia; KEWENIG, Viktor; KUVALJA, Martina; LEE, Mina; HOFMAN, Jake M.; VITELLO, Sylvia; SELLEN, Abigail; RINTEL, Sean; GOLDSTEIN, Daniel G.; ROTHCHILD, David; TANKELEVITCH, Lev y OATES, Tim, 2026. Effects of LLM use and note-taking on reading comprehension and memory: A randomised experiment in secondary schools. *Computers & Education*. Vol. 243, pág. 105514.

LI, Jingyi; CHEN, Wei; ZHANG, Hao et al., 2025. Education-Oriented Graph Retrieval-Augmented Generation for Learning Path Recommendation. *arXiv preprint*. arXiv:2506.22303.

LI, Minghao; LV, Tengchao; CHEN, Jingye; CUI, Lei; LU, Yijuan; FLORENCIO, Dinei; ZHANG, Cha; LI, Zhoujun y WEI, Furu, 2023. TrOCR: Transformer-Based Optical Character Recognition with Pre-Trained Models. En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37, págs. 13094-13102. Disp. desde DOI: [10.1609/aaai.v37i11.26538](https://doi.org/10.1609/aaai.v37i11.26538).

LNĚNIČKA, Martin et al., 2024. Human-Centric Explainable AI in Education: Privacy, Security and Ethical Considerations. *arXiv preprint*. arXiv:2410.19822.

LODOVICO MOLINA, Sebastián et al., 2025. QuerIA: Adaptive Question Generation and Evaluation in Higher Education Using Large Language Models and Contextual Learning. *Expert Systems with Applications*. Disp. desde DOI: [10.1016/j.eswa.2025.037558](https://doi.org/10.1016/j.eswa.2025.037558). Combina prompt engineering, chunking semántico y alineación con Taxonomía de Bloom.

MARTIN, Robert C., 2017. *Clean Architecture: A Craftsman's Guide to Software Structure and Design*. Prentice Hall. ISBN 9780134494166.

MSAMBWA, Daniel et al., 2025. The Impact of AI on the Personal and Collaborative Learning Environments in Higher Education. *European Journal of Education*. Disp. desde DOI: [10.1111/ejed.12909](https://doi.org/10.1111/ejed.12909). Revisión sistemática de 148 artículos (2021–2024).

- 1234 NING, Wenyu; SHI, Shaotao; YIN, Yuchen; GUO, Zixuan y XIE, Jinrong, 2025. Intent-
1235 aware personalized summarization for educational texts with large language models. *Journal*
1236 *of King Saud University - Computer and Information Sciences*. Vol. 37, pág. 308.
1237
- 1238 OBIONWU, Victor; BRONESKE, David y SAAKE, Gunter, 2022. Topic maps as a tool for
1239 facilitating collaborative work pedagogy in knowledge management systems. En: *The 12th*
1240 *International Conference on Information Communication and Management (ICICM 2022)*.
1241 ACM.
1242
- 1243 SAXENA, Rishabh; SINGH, Shubhangi y DUBEY, Preeti, 2025. Comparative Analysis of
1244 Large Language Models for the Application of Scientific Article Summarization. *Procedia*
1245 *Computer Science*. Vol. 259, págs. 532-542.
1246
- 1247 SHARMA, Madhav; SAXENA, Rakesh Kumar; SAINI, Hukum Chand; AGARWAL, Sa-
1248 miksha; SAXENA, Akash y RUNTHALA, Ashish, 2025. TrOCR: Transformer-Based OCR
1249 with Pre-Trained Vision–Language Models. En: *2025 IEEE Pune Section International Con-*
1250 *ference (PuneCon)*. IEEE. Benchmarking en IAM, Bentham y SROIE; supera pipelines
1251 CNN-RNN.
1252
- 1253 SHIRKANDE, S.T.; OMKAR, Gaikwad; HARSHAL, Palve; JAYESH, Patil y ANIKET,
1254 Khade, 2025. Noteverse: Intelligent Note Management for Organizational Hub. *International*
1255 *Journal on Advanced Electrical and Computer Engineering*. Vol. 14, n.º 1.
1256
- 1257 SOLANKI, Minal; CHANDANKHEDE, Puja K. y BADWAIK, Sanjana J., 2026. NoteGe-
1258 nius: An Intelligent AI-Powered Ecosystem for Note Generation and Collaborative Learning.
1259 *International Journal of Advanced Research in Science, Communication and Technology*
1260 *(IJARSCT)*. Vol. 6, n.º 1, págs. 550-555.
1261
- 1262 SOUMYA, M. D. y KRISHNAMOORTHY, S., 2025. Knowledge Graphs for Representing
1263 Knowledge Progression of Students across Heterogeneous Learning Systems. *International*
1264 *Journal of Artificial Intelligence in Education*. Vol. 35, págs. 1695-1723. Disp. desde DOI:
1265 [10.1007/s40593-024-00434-w](https://doi.org/10.1007/s40593-024-00434-w).
1266
- 1267 TANKELEVITCH, Lev et al., 2025. More AI Assistance Reduces Cognitive Engagement:
1268 Examining the AI Assistance Dilemma in AI-Supported Note-Taking. *arXiv preprint*. ar-
1269 Xiv:2509.03392. Estudio CHI 2025 sobre toma de notas asistida por IA.
1270
- 1271 TARAZONA CRUZ, Luz Silvana, 2024. *Reconocimiento de texto en manuscritos históricos*
1272 *peruanos utilizando modelos mixtos*. Lima, Perú. Disponible también desde: <http://hdl.>

- 1273 handle.net/20.500.12404/29310. Tesis de maestría. Pontificia Universidad Católica del
1274 Perú.
1275
- 1276 TORRES, Miguel et al., 2025. Enhancing Active Recall and Spaced Repetition with LLM-
1277 Augmented Review Systems. *Proceedings of the American Society for Engineering Education*
1278 (ASEE). Disp. desde DOI: [10.18260/1-2--47123](https://doi.org/10.18260/1-2--47123).
1279
- 1280 UPADHYAY, Aryan; MOHOD, Arjun; CHAUDHARI, Manish; SHAHU, Kartik; WAGH-
1281 MARE, Kartik y KUBADE, Harshad M., 2026. AI-Powered YouTube Video Summarization:
1282 A Comprehensive Web Application for Automatic Content Analysis and Note Generation. *In-*
1283 *ternational Journal for Research in Applied Science and Engineering Technology (IJRASET)*.
1284 Vol. 14, n.º 1. Disp. desde DOI: [10.22214/ijraset.2026.76857](https://doi.org/10.22214/ijraset.2026.76857).
1285
- 1286 VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; USZKOREIT, Jakob; JONES,
1287 Llion; GOMEZ, Aidan N.; KAISER, Lukasz y POLOSUKHIN, Illia, 2017. Attention Is All
1288 You Need. En: *Advances in Neural Information Processing Systems (NeurIPS)*.
1289
- 1290 VIERIU, Aniella Mihaela y PETREA, Gabriel, 2025. The Impact of Artificial Intelligence
1291 (AI) on Students' Academic Development. *Education Sciences*. Vol. 15, n.º 3, pág. 343.
1292
- 1293 ZHANG, Bo, 2026. A Review of the Development of Text Recognition Techniques. En:
1294 *CONF-SPML 2026 Symposium: The 2nd Neural Computing and Applications Workshop*.
1295
- 1296 ZHANG, Liang et al., 2026. Personalized Learning Path Recommendation Based on Know-
1297 ledge Graphs: A Survey. *Electronics*. Vol. 15, n.º 1, pág. 238. Disp. desde DOI: [10.3390/](https://doi.org/10.3390/electronics15010238)
1298 [electronics15010238](https://doi.org/10.3390/electronics15010238). Revisión narrativa 2014–2025, bases Web of Science y Scopus.
1299

1300

1301

1302

1303

1304

1305

1306

1307

1308

1309

1310

1311

1312

1313

1314

1315

1316

1317

1318

ANEXOS

Tabla 8— Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema SynapTome (Parte 1)

Problema de Investigación	Objetivos de la Investigación	Hipótesis de la Investigación	Variables	Indicadores / Métricas	Metodología Aplicada
Problema General ¿De qué manera la transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente SynapTome optimiza el rendimiento académico y reduce la sobrecarga cognitiva en estudiantes universitarios?	Objetivo General Optimizar la gestión del conocimiento y el acceso a repositorios de estudio mediante la evaluación e implementación del ecosistema inteligente SynapTome, con el propósito de incrementar significativamente el rendimiento académico de los estudiantes universitarios.	Hipótesis General La transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente SynapTome optimiza significativamente el rendimiento académico y reduce la sobrecarga cognitiva en los estudiantes universitarios, en la UNAMBA, 2026.	Variable Independiente (VI): Ecosistema inteligente con visión artificial y LLM. Variable Dependiente (VD): Rendimiento académico.	* Tasa de Error de Caracteres (CER %). * Tiempo de consolidación de apuntes (min). * Índice de alucinación factual (%). * Puntaje de sobrecarga mental (NASA-TLX). * Calificación de exámenes (0–20).	Tipo: Aplicada. Nivel: Explicativo. Diseño: Experimental (Pre-test / Pos-test). Enfoque: Cuantitativo. Método: Científico y estadístico. Población y Muestra: Estudiantes de la Escuela de Informática y Sistemas, UNAMBA.
Problema Específico 1 ¿En qué medida la migración de los estudiantes hacia un flujo de digitalización automatizado influye en la tasa de preservación de información técnica y en la reducción del tiempo dedicado a la consolidación de apuntes manuscritos?	Objetivo Específico 1 Medir el incremento en la tasa de preservación de información técnica y la reducción del tiempo de consolidación de apuntes manuscritos en los estudiantes universitarios, mediante la transición de métodos de transcripción analógica tradicionales hacia un flujo de digitalización automatizado de alta precisión.	Hipótesis Específica 1 La migración de los estudiantes hacia un flujo de digitalización automatizado mediante un pipeline HTR basado en la arquitectura TrOCR con <i>fine-tuning</i> incrementa significativamente la tasa de preservación de información técnica en sus apuntes y reduce el tiempo promedio dedicado a la consolidación de notas manuscritas respecto al estado inicial analógico, en la UNAMBA, 2026.	Dimensión VI: Módulo de digitalización y transcripción visual (TrOCR). Dimensión VD: Eficiencia de captura técnica del estudiante.	* Tasa de Error de Caracteres (CER %). * Tiempo semanal de transcripción manual o consolidación de apuntes (minutos). * Precisión de renderizado en sintaxis $\LaTeX$ (%).	* Pipeline en Node.js de procesamiento de imágenes. * Modelo autorregresivo Transformer (TrOCR). * Análisis de varianza de tiempos de edición. * Pruebas experimentales en asignaturas de Cálculo y Física.

Tabla 9— Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema SynapTome (Parte 2)

Problema de Investigación	Objetivos de la Investigación	Hipótesis de la Investigación	Variables	Indicadores / Métricas	Metodología Aplicada
Problema Específico 2 ¿Cómo repercute el condicionamiento del entorno de asimilación cognitiva de los alumnos a un corpus académico validado en el nivel de veracidad factual y en la reducción de errores conceptuales presentes en sus materiales de autoestudio?	Objetivo Específico 2 Determinar la reducción en el índice de errores conceptuales y datos falsos (alucinaciones) en el material de autoestudio utilizado por los alumnos, evaluando el nivel de fidelidad y veracidad factual de sus resúmenes antes y después de restringir su entorno de asimilación cognitiva a un corpus académico validado.	Hipótesis Específica 2 El condicionamiento del entorno de asimilación cognitiva de los alumnos a un corpus académico validado mediante un middleware RAG restrictivo disminuye drásticamente el índice de errores conceptuales y datos falsos presentes en sus materiales de autoestudio, asegurando una alta fidelidad factual en comparación con el uso de herramientas genéricas de información, en la UNAMBA, 2026.	Dimensión VI: Middleware de recuperación y fidelidad factual (RAG). Dimensión VD: Calidad factual de los recursos de repaso del estudiante.	* Índice de inserción de conceptos erróneos o alucinados (%). * Coincidencia semántica con el material base académico (%). * Tasa de veracidad conceptual en resúmenes.	* Indexación vectorial relacional. * Chunking semántico parametrizado de sílabos y apuntes oficiales. * Inferencia controlada sobre Modelos de Lenguaje Grande (LLMs). * Evaluación de fidelidad de resúmenes.
Problema Específico 3 ¿Cuál es el impacto latente de la adopción de un entorno de aprendizaje interconectado basado en mapas conceptuales dinámicos sobre las calificaciones promedio alcanzadas por los estudiantes y el nivel de sobrecarga cognitiva percibido?	Objetivo Específico 3 Cuantificar el impacto latente en las calificaciones promedio y el nivel de sobrecarga cognitiva percibida por los estudiantes, analizando la variación de sus puntajes académicos y fatiga mental tras migrar de un esquema de repaso individual aislado a un entorno de aprendizaje interconectado y evaluado de forma dinámica.	Hipótesis Específica 3 La adopción de un entorno de aprendizaje interconectado basado en Grafos de Conocimiento y evaluaciones dinámicas automatizadas incrementa las calificaciones promedio de los estudiantes y reduce los niveles de sobrecarga cognitiva percibida en comparación con los valores basales registrados durante los métodos de repaso individuales y aislados, en la UNAMBA, 2026.	Dimensión VI: Motor relacional topológico y evaluaciones dinámicas. Dimensión VD: Desempeño académico y carga cognitiva declarada del alumno.	* Calificaciones cuantitativas alcanzadas en exámenes parciales (Escala 0–20). * Índice de fatiga mental y estrés autopercebido (Escala NASA-TLX).	* Base de datos orientada a grafos indexados. * Algoritmos de IA para generación automatizada de cuestionarios formativos (<i>quizzes</i>). * Protocolos de sincronización web interactiva en tiempo real (SignalR). * Aplicación de la prueba estadística t de Student unilateral derecha.