

1
2
3
4
5
6

7
8
9
10
11
12
13
14
15
16
17
18
19
20
21
22
23
24
25
26

UNIVERSIDAD NACIONAL MICAELA BASTIDAS DE APURÍMAC

FACULTAD DE INGENIERÍA

**ESCUELA ACADÉMICO PROFESIONAL DE INGENIERÍA INFORMATICA Y
SISTEMAS**



Proyecto de Tesis

Ecosistema Inteligente con Visión Artificial y LLM para mejorar el aprendizaje colaborativo y el rendimiento académico en la UNAMBA, 2026

Presentado por:

Clinio Omar Rayme Huacho

Para optar el título de Ingeniero Informatico y Sistemas

Abancay, Perú

2026

27
28
29
30

31

ÍNDICE

	Pag.
32 INTRODUCCIÓN	1
33 DATOS GENERALES	3
34 a) Título del proyecto:	3
35 b) Ejecutor/ejecutores:	3
36 c) Coasesor (si hubiese):	3
37 d) Línea de investigación:	3
38 CAPÍTULO I	4
39 PLANTEAMIENTO DEL PROBLEMA	4
40 1.1 Descripción del problema	4
41 1.2 Enunciado del problema	5
42 1.2.1 Problema general	5
43 1.2.2 Problemas específicos	5
44 1.3 Justificación de la investigación	6
45 1.3.1 Justificación Científica	6
46 1.3.2 Justificación Tecnológica	6
47 1.3.3 Justificación Institucional	7
48 1.4 Ubicación y Contextualización	7
49 CAPÍTULO II	9
50 OBJETIVOS E HIPÓTESIS	9
51 2.1 Objetivos de la investigación	9
52 2.1.1 Objetivo general	9
53 2.1.2 Objetivos específicos	9
54 2.2 Hipótesis de la investigación	9
55 2.2.1 Hipótesis general	9
56 2.2.2 Hipótesis específicas	10
57 CAPÍTULO III	12
58 MARCO TEÓRICO REFERENCIAL	12
59 3.1 Antecedentes	12
60 3.1.1 Antecedentes internacionales	12
61 3.1.2 Antecedentes nacionales	14

62	3.2	Marco teórico	14
63	3.2.1	Inteligencia Artificial Generativa y Arquitectura RAG	14
64	3.2.2	Arquitectura Transformer y Mecanismo de Atención	15
65	3.2.3	Reconocimiento de Texto Manuscrito (HTR), TrOCR y Fórmulas Matemáticas	17
66	3.2.4	<i>Vector Embeddings</i> y Bases de Datos Vectoriales	18
67	3.2.5	Grafos de Conocimiento	19
68	3.2.6	Generación Automática de Evaluaciones Adaptativas	20
69	3.2.7	Aprendizaje Activo y Recuperación Espaciada (<i>Spaced Repetition</i>)	20
70	3.2.8	Aprendizaje Colaborativo Mediado por Tecnología	21
71	3.2.9	Carga Cognitiva y Medición con NASA-TLX	22
72	3.2.10	Privacidad y Seguridad de Datos Estudiantiles en Plataformas IA	22
73	3.2.11	Arquitectura Limpia (<i>Clean Architecture</i>)	23
74	3.3	Marco conceptual	24
75	CAPÍTULO IV		26
76	METODOLOGÍA		26
77	4.1	Tipo y nivel de investigación	26
78	4.2	Diseño de la investigación	26
79	4.3	Pipeline del sistema	27
80	4.4	Descripción ética de la investigación	27
81	4.5	Población y muestra	28
82	4.6	Procedimiento	28
83	4.7	Técnicas e instrumentos	29
84	4.7.1	Técnicas	29
85	4.7.2	Instrumentos	30
86	4.8	Estadístico de la investigación	30
87	CAPÍTULO V		32
88	ADMINISTRACIÓN DEL PROYECTO		32
89	5.1	Cronograma de actividades	32
90	5.2	Presupuesto	35
91	5.3	Fuente de financiamiento	35
92	REFERENCIAS BIBLIOGRÁFICAS		37
93	ANEXOS		38

94
95
96
97

98

ÍNDICE DE TABLAS

99	Tabla 1 — Operacionalización de las variables de investigación	11
100	Tabla 2 — Fases del procedimiento de investigación	29
101	Tabla 3 — Instrumentos de recolección de datos	30
102	Tabla 4 — Cronograma de actividades – Fases I a III (Julio – Diciembre 2026) .	33
103	Tabla 5 — Cronograma de actividades – Fases IV a VI (Julio – Diciembre 2026)	34
104	Tabla 6 — Presupuesto estimado del proyecto de investigación	35
105	Tabla 7 — Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema	
106	SynapTome	39

107
108
109
110

111

ÍNDICE DE FIGURAS

112	Figura 1 — Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA). .	8
113	Figura 2 — Arquitectura general del sistema de Generación Aumentada por Re-	
114	cuperación (RAG).	15
115	Figura 3 — Mecanismo de auto-atención escalada por producto punto (Scaled	
116	Dot-Product Attention).	16
117	Figura 4 — Flujo de procesamiento híbrido de visión y lenguaje del modelo TrOCR.	18
118	Figura 5 — Similitud de coseno entre vectores en un espacio de embeddings	
119	multidimensional.	19
120	Figura 6 — Grafo relacional de conocimiento representando la progresión del	
121	estudiante.	20
122	Figura 7 — Curva del olvido de Ebbinghaus y el impacto de los repasos progra-	
123	mados.	21
124	Figura 8 — Capas concéntricas de dependencias bajo el diseño de Arquitectura	
125	Limpia.	24
126	Figura 9 — Descripción clara del contenido de la imagen enfocada en el impacto	
127	o flujo del estudiante.	27

INTRODUCCIÓN

La adopción de la Inteligencia Artificial Generativa ha impulsado una transformación sin precedentes en la educación superior, redefiniendo las metodologías de enseñanza y la asimilación del conocimiento (Vieriu2025). En este escenario, la gestión de apuntes universitarios ha experimentado una evolución acelerada, migrando desde los métodos manuscritos tradicionales hacia formatos digitales dinámicos e interactivos. Esta transición tecnológica busca optimizar la captura, organización y recuperación de la información académica. Según Kreijkes2026, la integración de Modelos de Lenguaje Grande (LLMs) presenta oportunidades excepcionales para facilitar la comprensión lectora y reducir la carga cognitiva inicial de los estudiantes. Sin embargo, el volumen exponencial de datos técnicos y científicos en disciplinas de ingeniería exige herramientas que trasciendan el simple almacenamiento, demandando ecosistemas capaces de procesar y enlazar semánticamente el contenido educativo.

A pesar de estos avances tecnológicos, la digitalización educativa contemporánea enfrenta desafíos algorítmicos y pedagógicos severos. Los estudiantes de ingeniería padecen de una constante sobrecarga cognitiva al intentar integrar múltiples fuentes de información no estructurada. La adopción pasiva de plataformas de IA genéricas agrava este panorama, induciendo una dependencia tecnológica que inhibe el análisis crítico y la apropiación del conocimiento (Vieriu2025). A nivel técnico, los LLMs estándar adolecen de un problema crítico de “alucinaciones”; dado que carecen de mecanismos intrínsecos para verificar la veracidad de los hechos, frecuentemente generan información plausible pero fácticamente incorrecta (Chen2023). Adicionalmente, la digitalización de apuntes científicos enfrenta la barrera de la notación matemática, donde los sistemas tradicionales fracasan al procesar estructuras espaciales complejas (AlvarezPerez2026). Finalmente, las herramientas actuales promueven un consumo individualista y fragmentado de la información, careciendo de la infraestructura lógica para establecer vínculos semánticos que fomenten una colaboración auténtica entre pares (Jiang2025).

Para mitigar estas brechas tecnológicas y metodológicas, la presente investigación propone formalmente el desarrollo de SynapTome, un ecosistema digital inteligente y colaborativo fundamentado en los principios de la Arquitectura Limpia (Clean Architecture). La infraestructura del sistema orquesta tecnologías de vanguardia para transformar la gestión del aprendizaje: en el núcleo de procesamiento de lenguaje natural, se implementa una arquitectura de Generación Aumentada por Recuperación (RAG) que restringe la inferencia de la IA

a un corpus documental validado, garantizando precisión factual y eliminando las alucinaciones (Ning2025). Para abordar el reto de la digitalización científica, se integra un pipeline de visión por computadora basado en el modelo Transformer TrOCR, el cual permite la transcripción estructurada de apuntes manuscritos y fórmulas matemáticas al formato LaTeX (KardanMoghaddam2025). El elemento diferenciador de SynapTome radica en su motor de base de datos relacional modelado mediante Grafos de Conocimiento en PostgreSQL. Estos grafos indexan topológicamente los bloques de estudio, descubriendo relaciones transversales entre múltiples usuarios para catalizar una verdadera Inteligencia Colectiva” (Obionwu2022). Todo el ecosistema opera con una sincronización concurrente a través de SignalR y C#, con una interfaz reactiva desarrollada en Next.js.

El presente trabajo de investigación se estructura en seis capítulos organizados de la siguiente manera: el **Capítulo I** comprende el planteamiento del problema, delimitando la problemática de la sobrecarga cognitiva y la digitalización de apuntes científicos, justificando la investigación desde las dimensiones científica, tecnológica e institucional, y contextualizando el caso de estudio en la Escuela Profesional de Ingeniería de Informática y Sistemas de la UNAMBA; el **Capítulo II** establece los objetivos de la investigación (general y específicos), las hipótesis correspondientes que guían el estudio y la operacionalización rigurosa de las variables; el **Capítulo III** desarrolla el marco teórico referencial, comenzando con los antecedentes nacionales e internacionales del estado del arte, y profundizando en teorías fundamentales como la Inteligencia Artificial Generativa, la arquitectura RAG, los Transformers, TrOCR, bases de datos vectoriales, Grafos de Conocimiento y la Teoría de la Carga Cognitiva; el **Capítulo IV** detalla el diseño metodológico, especificando el tipo y diseño de la investigación (cuasi-experimental), el pipeline del sistema, la población y muestra, el procedimiento experimental, así como las técnicas, instrumentos y estadísticos (pruebas t de Student, CER, WER, ROUGE y SUS); el **Capítulo V** presenta los resultados empíricos obtenidos en las pruebas, incluyendo el análisis comparativo del error de caracteres (CER), la mitigación de alucinaciones en el middleware RAG, la reducción de sobrecarga cognitiva mediante NASA-TLX, y la contrastación de la hipótesis general; finalmente, el **Capítulo VI** expone las conclusiones del estudio, destacando los logros alcanzados frente a cada objetivo específico, y propone recomendaciones metodológicas y tecnológicas para futuras implementaciones.

197

198

199

200

201

DATOS GENERALES

202 a) **Título del proyecto:**

203 Ecosistema Inteligente con Visión Artificial y LLM para mejorar el Aprendizaje Cola-
204 borativo en la UNAMBA, 2026

205

206 b) **Ejecutor:**

207 • Clinio Omar Rayme Huacho

208

209 c) **Asesor:**

210 • M.Sc. Yhon Fuentes Huaman

211

212 d) **Línea de investigación:**

213 • Ingeniería de software e innovación tecnológica

214

215
216
217
218

219
220

CAPÍTULO I

PLANTEAMIENTO DEL PROBLEMA

221

1.1 Descripción del problema

222
223
224
225
226
227
228
229
230
231
232
233
234
235
236
237
238
239
240
241
242
243
244
245
246
247
248
249
250
251

En el entorno académico universitario contemporáneo, los estudiantes enfrentan un volumen exponencial de información técnica y científica que a menudo desencadena una severa sobrecarga cognitiva. El procesamiento simultáneo de múltiples fuentes de información no estructurada y la dificultad de organizar apuntes fragmentados limitan la capacidad de comprensión y retención de los alumnos. Teorías del aprendizaje, como la Teoría de la Carga Cognitiva, explican que la división de la atención durante la captura manual o digital de apuntes puede resultar en la pérdida de información crítica y en un bajo rendimiento académico si los métodos de captura no se alinean con un procesamiento estructurado. A pesar de que la toma de apuntes es una herramienta pedagógica esencial, los enfoques tradicionales a menudo generan ecosistemas de estudio aislados que no logran seguir el ritmo de la complejidad del contenido universitario.

Para mitigar esta sobrecarga, los estudiantes han recurrido a Modelos de Lenguaje Grande (LLMs) genéricos en busca de resúmenes y asistencia académica. Sin embargo, la adopción de estos sistemas presenta fallas críticas. Los LLMs tradicionales frecuentemente fracasan al capturar los matices técnicos y factuales propios de los artículos de investigación e ingeniería. Más grave aún es el problema de las “alucinaciones”; los LLMs carecen de una capacidad intrínseca para verificar la veracidad de la información que generan, lo que resulta en la invención de hechos plausibles pero falsos que contaminan el aprendizaje. Además, el uso de resúmenes genéricos omite la intención y el contexto específico del usuario, lo que subraya la necesidad imperativa de sistemas de IA condicionados factualmente.

Por otra parte, la digitalización de apuntes manuscritos en carreras de ingeniería y ciencias exactas enfrenta un cuello de botella computacional significativo debido a la presencia de fórmulas matemáticas, matrices y gráficos. Los sistemas convencionales de Reconocimiento Óptico de Caracteres (OCR) no están diseñados para interpretar la estructura espacial y semántica de las matemáticas. Es necesario el uso de arquitecturas basadas en Transformers, como TrOCR, sometidas a procesos de fine-tuning específicos, para lograr una conversión estructurada y precisa de notación científica hacia el formato LaTeX. La alta variabilidad en los estilos

de escritura y el ruido en las imágenes complican severamente la transcripción automatizada si no se emplean pipelines de Deep Learning avanzados. Finalmente, existe una carencia fundamental de plataformas verdaderamente colaborativas. Históricamente, la gestión de apuntes ha sido un proceso de consumo individual. El aprendizaje colaborativo basado en la gestión del conocimiento es indispensable para el desarrollo de competencias en el aula. No obstante, las herramientas actuales carecen de la infraestructura necesaria para enlazar semánticamente la información entre pares. La literatura sugiere que la implementación de mapas de tópicos y grafos relacionales en los sistemas de gestión del conocimiento es un habilitador técnico crucial para una pedagogía verdaderamente colaborativa, un componente del cual carecen las plataformas educativas estándar.

1.2 Enunciado del problema

1.2.1 Problema general

¿En cuánto disminuye la sobrecarga de apuntes y la fatiga mental, y en qué medida se optimizan el aprendizaje colaborativo y el rendimiento académico de los estudiantes universitarios de la UNAMBA al transicionar desde esquemas de estudio aislados hacia un entorno de aprendizaje interconectado y automatizado?

1.2.2 Problemas específicos

- ¿En cuánto se reduce el tiempo de consolidación de apuntes manuscritos y cuál es el incremento en la tasa de preservación de información técnica mediante el uso de la aplicación con un módulo de transcripción automatizada (TrOCR) frente a los métodos de transcripción tradicional?
- ¿Cuál es la tasa de reducción de errores conceptuales en el material de repaso de los estudiantes al condicionar las respuestas del sistema mediante un middleware RAG acoplado a un LLM en comparación con las herramientas de inteligencia artificial genéricas de entorno abierto?
- ¿En cuánto disminuyen el nivel de sobrecarga cognitiva y la fatiga mental, y de qué manera se optimizan el aprendizaje colaborativo y el rendimiento académico de los alumnos al implementar en la aplicación web un motor relacional de grafos de conocimiento con evaluaciones dinámicas automatizadas frente a los esquemas basales de estudio aislados?

1.3 Justificación de la investigación

La presente investigación se justifica desde tres dimensiones fundamentales: científica, tecnológica e institucional, las cuales convergen en el desarrollo y despliegue del ecosistema SynapTome para resolver de manera integral los desafíos contemporáneos en la gestión del aprendizaje universitario.

1.3.1 Justificación Científica

A nivel científico, este estudio aporta evidencia empírica sobre cómo resolver las deficiencias inherentes de los Modelos de Lenguaje Grande (LLMs) en contextos académicos. Se demuestra que la integración de Grafos de Conocimiento actúa como una guía semántica que mitiga la incapacidad de los LLMs para verificar hechos, reduciendo drásticamente las “alucinaciones” durante la sumarización abstractiva (Chen2023). Además, la investigación fundamenta un cambio desde un paradigma de aprendizaje pasivo hacia uno constructivista; el uso guiado de la IA para la generación automática de evaluaciones formativas (*quizzes*) e interacciones basadas en apuntes reduce la sobrecarga cognitiva e incrementa significativamente la retención a largo plazo y la comprensión de los estudiantes (Kreijkes2026; Afian2025). Finalmente, el proyecto valida la teoría de la pedagogía colaborativa, comprobando que el uso de Mapas de Tópicos (*Topic Maps*) permite estructurar el conocimiento fragmentado, descubriendo relaciones transversales y fomentando una auténtica “Inteligencia Colectiva” (Obionwu2022).

1.3.2 Justificación Tecnológica

Desde la perspectiva tecnológica, el desarrollo de SynapTome representa un avance en la superación de los cuellos de botella clásicos de la digitalización científica. El proyecto aborda las altas tasas de error de los sistemas OCR tradicionales mediante la implementación de *pipelines* de visión por computadora basados en la arquitectura *Transformer* (TrOCR y Nougat), los cuales, a través de procesos de *fine-tuning*, logran transcribir con alta precisión notación matemática y fórmulas complejas directamente hacia el formato estructurado $\text{\LaTeX}$ (AlvarezPerez2026; KardanMoghaddam2025). Asimismo, el diseño del sistema orquesta una Arquitectura Limpia (*Clean Architecture*) que integra *Next.js* en el *frontend*, un *middleware* de Generación Aumentada por Recuperación (RAG) condicionado factualmente (Ning2025; Jiang2025), y bases de datos relacionales con soporte vectorial como PostgreSQL. Esta integración *full-stack*, apoyada en WebSockets (SignalR), justifica la viabilidad

de desplegar un entorno de coedición seguro, escalable y en tiempo real (Shirkande2025; Upadhyay2026).

1.3.3 Justificación Institucional

A nivel institucional, la implementación de este ecosistema en la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), específicamente orientado a la Escuela Académico Profesional de Ingeniería de Sistemas, proporciona una infraestructura digital de vanguardia que impacta directamente en la calidad educativa. Los estudiantes de ingeniería requieren asimilar un volumen denso de información matemática y técnica; al proveerles una plataforma que centraliza, digitaliza y democratiza el acceso a una mayor cantidad de apuntes interconectados, la universidad facilita una mejora medible en el rendimiento académico y las calificaciones de su comunidad estudiantil (Dano2026). En consecuencia, esta iniciativa dota a la UNAMBA de herramientas tecnológicas de primer nivel, posicionándola como una institución innovadora que adopta la Inteligencia Artificial de manera ética, estructurada y orientada al beneficio colectivo.

1.4 Ubicación y Contextualización

La presente investigación se contextualiza y aplicará en la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), ubicada en la ciudad de Abancay, en la región de Apurímac, Perú. Específicamente, el caso de estudio está enfocado en atender las necesidades académicas y los retos de aprendizaje de los estudiantes de la Escuela Académico Profesional de Ingeniería de Informaticá y Sistemas. En este entorno, los estudiantes manejan un alto volumen de asignaturas fundamentadas en el cálculo, la física, el álgebra lineal y la algoritmia. Estos tópicos exigen el uso intensivo de notación matemática compleja, diagramas lógicos y esquemas arquitectónicos, los cuales suelen registrarse tradicionalmente de manera manuscrita. Las barreras en la digitalización de esta información, sumadas a la alta carga cognitiva propia de la disciplina y las limitaciones de infraestructura para la colaboración eficiente entre pares, hacen que los estudiantes de la UNAMBA sean los candidatos idóneos para validar la efectividad del ecosistema SynapTome como una herramienta integral para la gestión y democratización de su conocimiento técnico.



Figura 1— Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA).

355
356
357
358

359
360

CAPÍTULO II

OBJETIVOS E HIPÓTESIS

2.1 Objetivos de la investigación

2.1.1 Objetivo general

363 Reducir la sobrecarga de apuntes y la fatiga mental, y optimizar el apren-
364 dizaje colaborativo y el rendimiento académico de los estudiantes uni-
365 versitarios de la UNAMBA al implementar y evaluar una aplicación web
366 basada en un entorno de aprendizaje interconectado y automatizado.

2.1.2 Objetivos específicos

- 368 • Reducir el tiempo dedicado a la consolidación de apuntes manuscritos
369 y aumentar la tasa de preservación de información técnica mediante el
370 uso de la aplicación web con un módulo de transcripción automatizada
371 (TrOCR).
- 372 • Reducir la tasa de errores conceptuales en el material de repaso de los
373 estudiantes al condicionar las respuestas de la aplicación web mediante
374 un middleware RAG acoplado a un LLM en comparación con el uso de
375 herramientas de entorno abierto.
- 376 • Disminuir el nivel de sobrecarga cognitiva y la fatiga mental, y optimizar
377 el aprendizaje colaborativo y el rendimiento académico de los alumnos
378 al implementar en la aplicación web un motor relacional de grafos de
379 conocimiento con evaluaciones dinámicas automatizadas.

2.2 Hipótesis de la investigación

2.2.1 Hipótesis general

382 La implementación de la aplicación web basada en un entorno de apren-
383 dizaje interconectado y automatizado permite reducir la sobrecarga de
384 apuntes y la fatiga mental, y optimizar el aprendizaje colaborativo e in-
385 crementar el rendimiento académico de los estudiantes universitarios de
386 la UNAMBA.

2.2.2 Hipótesis específicas

- El uso de la aplicación web con un módulo de transcripción automatizada (TrOCR) permite reducir el tiempo dedicado a la consolidación de apuntes manuscritos y aumentar la tasa de preservación de información técnica, en comparación con los métodos de transcripción tradicional.
- El condicionamiento de las respuestas de la aplicación web mediante un middleware RAG acoplado a un LLM permite reducir la tasa de errores conceptuales en el material de repaso de los estudiantes, en comparación con el uso de herramientas de entorno abierto.
- La implementación de un motor relacional de grafos de conocimiento con evaluaciones dinámicas automatizadas en la aplicación web permite disminuir el nivel de sobrecarga cognitiva y la fatiga mental, y optimizar el aprendizaje colaborativo y el rendimiento académico de los alumnos.

Tabla 1— Operacionalización de las variables de investigación

Variable	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Escala / Rangos
Variable Independiente (VI): Ecosistema inteligente con visión artificial y LLM	Componente tecnológico basado en arquitecturas Transformers con <i>fine-tuning</i> encargado de la conversión automatizada de apuntes físicos y notación científica hacia texto estructurado en la aplicación web.	Se evalúa registrando el tipo de flujo de trabajo implementado por el alumno y calculando el porcentaje de preservación exacta de caracteres técnicos tras el procesamiento visual de imágenes de cuadernos.	Transmisión y digitalización técnica de apuntes.	Uso de herramientas tecnológicas (Flujo manual tradicional vs. Aplicación web automatizada); tasa de conversión de caracteres técnicos (%); porcentaje de preservación de fórmulas matemáticas.	Flujo de trabajo: 0 = Manual tradicional 1 = Web automatizada Conversión: Alta $\geq 95\%$ Baja $< 80\%$ Preservación: Excelente $> 95\%$ Regular 80–95 %
	Mecanismo de procesamiento de lenguaje natural acoplado a un LLM que limita y restringe el espacio de inferencia computacional a un corpus de documentos académicos validados por la plataforma web.	Se mide verificando el grado de restricción del entorno de consultas del sistema y calculando la reducción porcentual de datos falsos o alucinaciones en los materiales de repaso generados.	Control factual de contenido sintético.	Configuración del entorno de inferencia (Inferencia abierta genérica vs. Filtro RAG restrictivo); tasa de reducción de errores conceptuales (%); consistencia semántica del resumen.	Entorno de consultas: 0 = Abierto genérico 1 = RAG restrictivo Reducción de errores: Alta $\geq 90\%$ Media 80–89 % Consistencia: Alta $> 95\%$ Deficiente $< 80\%$
	Estructuración de apuntes estudiantiles en forma de red semántica mediante Grafos de Conocimiento y algoritmos de IA orientados al despliegue automático de cuestionarios formativos dinámicos.	Se determina identificando la topología de interconexión del repositorio del alumno y calculando la tasa porcentual de generación desatendida de cuestionarios adaptativos en la interfaz web.	Interconexión semántica y evaluación formativa.	Topología de estructuración de notas (Bloques aislados tradicionales vs. Red relacional interconectada); tasa de generación automatizada de quizzes (%); latencia de actualización del grafo (seg).	Estructuración: 0 = Bloques aislados 1 = Red relacional Quizzes automáticos: Adecuado $\geq 90\%$ Deficiente $< 10\%$ Sincronización: Óptima < 2 seg Aceptable 2–5 seg
Variable Dependiente (VD): Aprendizaje colaborativo y rendimiento académico.	Proceso de adquisición de conocimientos que integra el trabajo conjunto de los estudiantes, optimizado por la reducción de la sobrecarga de apuntes y la fatiga mental, y evidenciado por la mejora en el rendimiento académico y la cooperación interactiva.	Se mide cuantitativamente comparando los registros de tiempo (minutos), la variación numérica de puntajes en la escala estandarizada NASA-TLX, las calificaciones en exámenes parciales y la frecuencia de intercambio colaborativo.	Eficiencia temporal; Carga cognitiva percibida; Desempeño académico y cooperación.	Tiempo semanal de consolidación de apuntes (min); nivel de sobrecarga cognitiva (puntos en escala NASA-TLX); calificaciones promedio en exámenes parciales; frecuencia de intercambio colaborativo (ítems/semana).	Tiempo de consolidación: Eficiente < 20 min Ineficiente > 90 min NASA-TLX: Baja sobrecarga < 40 Alta sobrecarga > 70 Calificaciones: Sobresaliente 16–20 Regular 11–15 Desaprobado < 11 Intercambio colaborativo: Alto > 15 ítems Bajo < 5 ítems Significancia: $p < 0,05$

CAPÍTULO III

MARCO TEÓRICO REFERENCIAL

3.1 Antecedentes

3.1.1 Antecedentes internacionales

- a) Según **Ning2025**, en su investigación sobre la sumarización personalizada consciente de la intención en textos educativos utilizando Modelos de Lenguaje Grande (LLMs), se encontró que el modelado explícito de la intención del usuario mejora drásticamente la relevancia y exactitud de los resúmenes. Su sistema propuesto logró superar a más de 10 modelos base de referencia, obteniendo ganancias de 6 a 8 puntos en las métricas ROUGE y una mejora de más del 5 % en la consistencia factual medida por la métrica FactCC.
- b) Según **Chen2023**, en su investigación sobre la mejora de la sumarización abstractiva mediante la integración de Grafos de Conocimiento y transformadores de múltiples fuentes, se encontró que el uso de representaciones semánticas estructuradas como guía mitiga la incapacidad intrínseca de los LLMs para verificar la corrección de los hechos. Su modelo MultiBART-GAT demostró un rendimiento superior al generar resúmenes informativos y relevantes, logrando incrementar la puntuación ROUGE-1 a 39.1 y manteniendo un alto nivel de similitud semántica en la evaluación BERTScore.
- c) Según **Jiang2025**, en su investigación sobre el sistema de toma de apuntes colaborativo e inteligente NexaNota, se encontró que la construcción automática de redes de temas mediante grafos de conocimiento impacta positivamente en la eficiencia del aprendizaje. En su estudio, la extracción y representación del conocimiento en el sistema alcanzó una precisión del 97.7 % en la identificación de tópicos principales y una exactitud del 86.7 % al establecer las conexiones semánticas entre dichos tópicos.
- d) Según **Kreijkes2026**, en su investigación sobre los efectos del uso de Modelos de Lenguaje Grande (LLMs) y la toma de apuntes en la comprensión lectora y la memoria, se encontró que combinar la toma

de apuntes tradicional con el uso de LLMs tiene efectos positivos significativos en la retención de conocimientos en comparación con el uso exclusivo de la IA. Sus resultados demostraron que el esfuerzo cognitivo involucrado en la estructuración propia de apuntes, apoyado por la IA, mejora las métricas de retención literal y comprensión con un tamaño del efecto estadístico (d) de 0.44 y 0.38, respectivamente.

e) Según **AlvarezPerez2026**, en su investigación desarrollada en México centrada en el *fine-tuning* de modelos *Transformers* para la conversión de textos científicos manuscritos al formato estructurado LaTeX, se encontró que arquitecturas visuales de extremo a extremo, como Nougat y TrOCR, superan ampliamente a los sistemas de OCR convencionales al procesar fórmulas matemáticas. Tras el entrenamiento con un corpus específico, el modelo optimizado demostró una alta capacidad para digitalizar notación espacial compleja, reduciendo la Tasa de Error de Caracteres (CER) hasta un 24.42 % en secuencias manuscritas desafiantes, lo que resulta ser un avance indispensable para la digitalización técnica en ingenierías y un aporte relevante al contexto latinoamericano.

f) Según **KardanMoghaddam2025**, en su investigación sobre una estructura combinada de transformadores TrOCR y LLMs para la clasificación y extracción de textos manuscritos, se encontró que inyectar las transcripciones de los modelos de visión directamente en un LLM mejora sustancialmente la precisión del procesamiento. Su modelo híbrido (TrOCR-Large acoplado con BART-Large) logró clasificar secuencias de texto con una precisión general (*accuracy*) de 65.29 % y altas puntuaciones F1, demostrando la viabilidad de utilizar *pipelines* de IA en cascada para digitalizar apuntes ruidosos.

g) Según **Solanki2026**, en su investigación sobre el ecosistema inteligente "NoteGenius", se encontró que la integración de IA generativa para la creación de apuntes y el aprendizaje colaborativo mitiga el problema de la fragmentación de la información académica. El desarrollo de esta plataforma (basada en tecnologías modernas y almacenamiento en la nube) automatiza la generación de resúmenes, conversión de diapositivas y creación de cuestionarios (quizzes), lo cual impacta directamente de forma positiva en la retención de conocimientos y auto-evaluación del estudiante.

h) Según **Upadhyay2026**, en su estudio sobre una aplicación web inte-

gral para el análisis automático de contenido y generación de apuntes a partir de videos de YouTube, se evidenció que la orquestación de APIs de Modelos de Lenguaje Grande (LLMs) con arquitecturas escalables (como React, Express.js y PostgreSQL) optimiza sustancialmente el tiempo de estudio. El sistema logra extraer transcripciones y estructurar apuntes de manera rápida y segura, demostrando la eficacia de los *pipelines* de IA en el procesamiento de contenido multimedia educativo.

- i) Según **Shirkande2025**, en su evaluación del sistema "Noteverse", se identificó que las herramientas tradicionales de gestión de conocimiento adolecen de falta de personalización y de mecanismos de organización inteligente. Su investigación valida que implementar bases de datos en la nube y *frameworks* interactivos como Next.js para lograr una sincronización y coedición en tiempo real es vital para la construcción de ecosistemas colaborativos robustos en la educación superior.

3.1.2 Antecedentes nacionales

- a) Según **TarazonaCruz2024**, en su investigación sobre el reconocimiento de texto en manuscritos históricos peruanos utilizando modelos mixtos, se encontró que el uso de modelos de reconocimiento de imágenes preentrenados mediante la plataforma de código abierto OCR4all es viable para digitalizar documentos manuscritos en español. Tras entrenar tres modelos con el conjunto de datos SPA-Sentences (aproximadamente 13,000 oraciones), su sistema alcanzó una Tasa de Error de Caracteres (CER) promedio de 4.11 % en el conjunto de validación, y al aplicarlo sobre manuscritos históricos peruanos de la Biblioteca Nacional del Perú obtuvo una tasa de error promedio de 9.39 %, demostrando la utilidad de estas arquitecturas para el contexto local pese a la variabilidad caligráfica y el deterioro del papel.

3.2 Marco teórico

3.2.1 Inteligencia Artificial Generativa y Arquitectura RAG

La Inteligencia Artificial Generativa, particularmente impulsada por Modelos de Lenguaje Grande (LLMs) como GPT-3.5 o LLaMA 3, ha revolucionado las tareas de procesamiento de lenguaje natural al habilitar la sumarización abstractiva de textos con alta coherencia (**Saxena2025**). No obstante, estos modelos probabilísticos carecen de mecanismos intrínse-

cos para verificar la veracidad de la información que generan, lo que con frecuencia deriva en “alucinaciones”: información plausible pero fácticamente incorrecta (Chen2023).

Para mitigar este problema, surge la arquitectura de Generación Aumentada por Recuperación (RAG). En lugar de depender exclusivamente de los pesos preentrenados del modelo, RAG restringe el espacio de inferencia recuperando primero los fragmentos de texto más relevantes desde un corpus local y proporcionándolos como contexto estricto al LLM Kannammal2024. El *pipeline* RAG clásico comprende tres etapas: indexación del corpus mediante *embeddings* vectoriales, recuperación semántica por similitud de coseno, y generación condicionada al contexto recuperado (GaoRAGSurvey2024). Al acoplar RAG con validadores factuales, la tasa de alucinaciones se minimiza de forma crítica Ning2025, lo que resulta especialmente relevante para sistemas educativos donde la exactitud del contenido generado es indispensable. La evolución más reciente ha dado lugar a variantes como GraphRAG, que integra grafos de conocimiento en el proceso de recuperación para capturar relaciones estructuradas entre conceptos, superando las limitaciones de la recuperación puramente vectorial (KleselWittmannRAG2025).




Figura 2— Arquitectura general del sistema de Generación Aumentada por Recuperación (RAG).

3.2.2 Arquitectura Transformer y Mecanismo de Atención

El fundamento técnico de los LLMs y de los modelos de visión empleados en el presente proyecto reside en la arquitectura Transformer, introducida por Vaswani2017 en el trabajo seminal “Attention is All You Need”. A diferencia de las arquitecturas recurrentes (RNN/LSTM) que procesan secuencias de forma estrictamente secuencial, el Transformer opera mediante un mecanismo de *auto-atención* (*Self-Attention*) que calcula, en paralelo, la relevancia relativa de cada posición de la secuencia respecto a

todas las demás. Formalmente, la atención escalada de producto punto se define como:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (3.1)$$

donde Q , K y V representan las matrices de *queries*, *keys* y *values* proyectadas, y d_k es la dimensión de las *keys*, cuya raíz cuadrada actúa como factor de escala para estabilizar los gradientes (Vaswani2017). La extensión multi-cabeza (*Multi-Head Attention*) ejecuta múltiples operaciones de atención en paralelo sobre distintos subespacios de representación, permitiendo al modelo capturar simultáneamente dependencias sintácticas, semánticas y de largo alcance en el texto (Vaswani2017).




Figura 3— Mecanismo de auto-atención escalada por producto punto (Scaled Dot-Product Attention).

Esta arquitectura fue posteriormente adaptada al dominio de la visión por computadora mediante el Vision Transformer (ViT), que divide una imagen en parches (*patches*) de tamaño fijo, los proyecta linealmente y los procesa como una secuencia de tokens, habilitando la captura de dependencias globales entre regiones de la imagen (LiTrOCR2023). Es precisamente esta sinergia entre un codificador de visión basado en ViT

y un decodificador de lenguaje autorregresivo la que subyace al modelo TrOCR, pilar tecnológico del módulo de transcripción de SynapTome.

3.2.3 Reconocimiento de Texto Manuscrito (HTR), TrOCR y Fórmulas Matemáticas

El Reconocimiento Óptico de Caracteres (OCR) tradicional se fundamenta en múltiples módulos independientes: preprocesamiento, segmentación, extracción de características mediante CNN y postprocesamiento, lo que genera una alta propagación de errores y una notable ineficiencia frente a caligrafía compleja (Zhang2026). Los sistemas CNN-RNN presentan además limitaciones al procesar texto manuscrito con alta variabilidad caligráfica, pues su campo receptivo local impide capturar dependencias de largo alcance entre caracteres (LiTrOCR2023).

En contraparte, TrOCR unifica estas tareas en una arquitectura única de extremo a extremo. Emplea un codificador de visión preentrenado (BEiT o DeiT) para extraer características visuales de la imagen en parches, y un decodificador de lenguaje (RoBERTa) que genera el texto de manera autorregresiva LiTrOCR2023. El modelo TrOCR_{LARGE} alcanza una Tasa de Error de Caracteres (CER) de apenas 2,89 % en el *benchmark* IAM, superando a todos los modelos CNN-RNN previos (SharmaTrOCR2025). Una dimensión especialmente crítica para SynapTome es el Reconocimiento de Expresiones Matemáticas Manuscritas (HMER, por sus siglas en inglés). A diferencia del texto corriente, las fórmulas matemáticas presentan una estructura bidimensional compleja: superíndices, subíndices, fracciones, integrales y símbolos especiales cuya disposición espacial es parte integrante de su significado. Los modelos encoder-decoder basados en Transformers, como UniMERNet, abordan esta complejidad mediante la generación directa de código $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ a partir de la imagen de la fórmula, logrando reconocer con alta precisión tanto expresiones impresas como manuscritas en escenarios reales (AlvarezPerez2026). El conjunto de datos MathWriting, que provee anotaciones $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ para fórmulas manuscritas en línea (*online*) y fuera de línea (*offline*), constituye actualmente el referente de evaluación para estos modelos (AlvarezPerez2026). En el contexto peruano, arquitecturas preentrenadas de esta familia han demostrado ser viables incluso para manuscritos con alta variabilidad caligráfica (TarazonaCruz2024).




Figura 4— Flujo de procesamiento híbrido de visión y lenguaje del modelo TrOCR.

3.2.4 *Vector Embeddings* y Bases de Datos Vectoriales

Los *embeddings* vectoriales son representaciones numéricas de alta dimensión que codifican el significado semántico de fragmentos de texto, imágenes u otros tipos de datos. La propiedad fundamental de estos vectores es que la proximidad geométrica en el espacio vectorial refleja similitud semántica: fragmentos con significado afín producen vectores cercanos, independientemente de si comparten vocabulario exacto (GaoRAGSurvey2024). Este principio constituye la base técnica de la recuperación semántica en los sistemas RAG: al codificar tanto los fragmentos del corpus como la consulta del usuario en el mismo espacio vectorial, es posible recuperar los k fragmentos más relevantes mediante una búsqueda de vecinos más cercanos (k -NN search).

Para la persistencia y consulta eficiente de estos vectores en el contexto de SynapTome, la extensión `pgvector` para PostgreSQL representa la solución arquitectónica óptima. Esta extensión permite almacenar vectores de alta dimensión directamente en tablas relacionales y ejecutar búsquedas de similitud mediante los operadores de distancia coseno, euclídea o producto punto, combinando las capacidades de búsqueda semántica con las garantías ACID y las operaciones relacionales estándar de SQL (Afian2025). La indexación mediante estructuras HNSW (*Hierarchical Navigable Small World*) permite escalar estas búsquedas a millones de vectores con latencias de consulta inferiores a 10 ms, manteniendo una alta tasa de recuperación (*recall*) (Upadhyay2026). Esta arquitectura unificada — datos relacionales y vectores en una sola base de datos — simplifica significativamente la infraestructura del sistema y elimina la necesidad de sincronizar datos entre una base de datos relacional y un almacén vectorial independiente.




Figura 5— Similitud de coseno entre vectores en un espacio de embeddings multidimensional.

3.2.5 Grafos de Conocimiento

Los Grafos de Conocimiento son estructuras matemáticas que representan la información como una red semántica dirigida, conformada por nodos (entidades o tópicos) y aristas (relaciones). Esta topología permite capturar el contexto global y las relaciones transversales dentro de un corpus documental, sirviendo como esqueleto para la extracción de características y el aprendizaje representacional **Chen2023**. Una revisión sistemática reciente identifica que su principal aporte en educación reside en la capacidad de modelar la progresión del conocimiento del estudiante a lo largo del tiempo, conectando conceptos de distintas asignaturas y niveles cognitivos (**AbuSalih2024**). En este sentido, permiten representar el estado de aprendizaje de cada alumno como una red dinámica de nodos de competencia, facilitando la personalización de rutas de estudio y la identificación de brechas conceptuales (**SoumyaKrishnamoorthy2025**). En el contexto de sistemas de gestión del aprendizaje, estos mapas de tópicos transforman el contenido aislado en recursos enlazados, impulsando la “Inteligencia Colectiva” (**Obionwu2022**). La integración de grafos de conocimiento con arquitecturas RAG —denominada GraphRAG— representa el estado del arte en recuperación semántica educativa: al estructurar el corpus de apuntes como un grafo, el sistema puede recorrer relaciones semánticas para recuperar fragmentos contextualmente relevantes que la búsqueda vectorial clásica no identificaría (**EduGraphRAG2025**). Para su implementación en el *backend*, PostgreSQL con pgvector garantiza la integridad, el indexado veloz y el almacenamiento seguro de los metadatos y vectores de las entidades semánticas (**Afian2025; Upadhyay2026**).




Figura 6— Grafo relacional de conocimiento representando la progresión del estudiante.

3.2.6 Generación Automática de Evaluaciones Adaptativas

La generación automática de cuestionarios a partir del contenido de apuntes constituye una de las aplicaciones más directas de los LLMs en educación. Los sistemas basados en IA son capaces de producir ítems alineados con la Taxonomía de Bloom —desde preguntas de recordación hasta ítems de evaluación y creación— a partir de fragmentos de texto, reduciendo significativamente la carga docente (QuerIA2025). Herramientas como QuizWiz demuestran que los LLMs integrados en plataformas educativas pueden generar cuestionarios personalizados y adaptativos en tiempo real, ajustando la dificultad al nivel de dominio actual del estudiante (QuizWiz2024).

Los grafos de conocimiento desempeñan un rol instrumental en esta dinámica: al estructurar los apuntes como una red de conceptos relacionados, el sistema selecciona de forma dirigida los nodos temáticos sobre los cuales generar preguntas, garantizando cobertura curricular equilibrada y evitando redundancia (PersonalizedLearningKG2026). Esta sinergia entre grafos de conocimiento y generación automática de evaluaciones constituye el núcleo de la variable independiente 3 del presente proyecto.

3.2.7 Aprendizaje Activo y Recuperación Espaciada (*Spaced Repetition*)

La Teoría de la Recuperación Espaciada (*Spaced Repetition*) se fundamenta en la curva del olvido de Ebbinghaus, que describe cómo la tasa de retención decae exponencialmente con el tiempo en ausencia de revisiones. La estrategia consiste en programar las revisiones de un concepto justo antes del momento en que será olvidado, maximizando la consolidación

en la memoria a largo plazo mediante el denominado *efecto de espaciado* (Huang2025). La práctica de recuperación activa (*Active Recall*) complementa esta estrategia: en lugar de releer pasivamente el material, el estudiante intenta recordar activamente la información, lo que fortalece las trazas mnémicas de forma significativamente más efectiva que la revisión pasiva; estudios recientes demuestran que los estudiantes que practican recuperación activa superan en más de un 50 % en pruebas diferidas a quienes solo releen el material (Huang2025).

Los sistemas de repetición espaciada modernos han evolucionado desde modelos de intervalo fijo —como el sistema Leitner— hacia algoritmos adaptativos basados en datos, como FSR5 (*Free Spaced Repetition Scheduler*), que estima dinámicamente el intervalo óptimo de revisión para cada ítem según el historial de respuestas del estudiante (SpacedRepetitionLLM2025). La integración de LLMs en estos sistemas permite generar automáticamente las tarjetas de estudio (*flashcards*) a partir del contenido de los apuntes digitalizados, cerrando el ciclo entre transcripción, estructuración y refuerzo del aprendizaje (SpacedRepetitionLLM2025). En el contexto de SynapTome, este módulo se articula directamente con el motor de grafos de conocimiento: los nodos con menor frecuencia de revisión o menor puntuación de dominio activan automáticamente la generación de nuevas instancias de práctica de recuperación.




Figura 7— Curva del olvido de Ebbinghaus y el impacto de los repasos programados.

3.2.8 Aprendizaje Colaborativo Mediado por Tecnología

El aprendizaje colaborativo, entendido como el proceso mediante el cual los estudiantes construyen conocimiento de forma conjunta a través del intercambio de recursos, ha sido ampliamente validado como estrategia que mejora la retención y el desempeño académico (Kasirye2023). Una

revisión sistemática de 148 artículos publicados entre 2021 y 2024 concluye que las herramientas de IA mejoran la personalización, la comunicación entre pares y el andamiaje del rendimiento, al tiempo que promueven entornos colaborativos mediante soporte de aprendizaje cooperativo ([MsambwaAI2025](#)). Sin embargo, la evidencia también advierte sobre una tensión emergente: el exceso de asistencia de IA en tareas de toma de notas puede reducir el compromiso cognitivo activo del estudiante ([AINoteTakingCognition2025](#)), lo que sugiere que SynapTome debe calibrar el nivel de automatización para preservar el procesamiento profundo de la información.

3.2.9 Carga Cognitiva y Medición con NASA-TLX

La Teoría de la Carga Cognitiva postula que la memoria de trabajo humana posee una capacidad limitada para procesar información simultáneamente, y que el diseño de entornos de aprendizaje debe minimizar la carga extrínseca para maximizar los recursos cognitivos disponibles ([HartStaveland1988](#)). Para la cuantificación objetiva de esta carga, el instrumento NASA Task Load Index (NASA-TLX) constituye el estándar de referencia más ampliamente adoptado. Evalúa seis dimensiones: Demanda Mental, Demanda Física, Demanda Temporal, Rendimiento, Esfuerzo y Frustración, obteniendo un índice global ponderado ([HartStaveland1988](#)). Su validez ha sido reconfirmada recientemente en contextos de interacción humano-computadora ([NASATLXReviewHCI2025](#)). En estudios con estudiantes universitarios, la Demanda Temporal y la Demanda Mental emergen como las dimensiones de mayor puntuación, con correlaciones significativas entre ambas ($\rho = 0,58$, $p < 0,001$), subrayando la relevancia de diseñar sistemas que reduzcan simultáneamente la presión temporal y el esfuerzo mental ([Cahyadi2026](#)).

3.2.10 Privacidad y Seguridad de Datos Estudiantiles en Plataformas IA

El despliegue de plataformas educativas potenciadas por IA implica la recopilación y procesamiento de datos estudiantiles altamente sensibles: registros académicos, patrones de comportamiento, historial de consultas y contenido de apuntes personales. La gestión ética y segura de estos datos es un imperativo técnico y legal que condiciona el diseño arquitectónico de SynapTome ([XAIEducation2024](#)). En el ámbito normativo internacional, dos marcos regulatorios delimitan las obligaciones de las plataformas educativas: la Ley de Privacidad y Derechos Educativos de la Familia (FERPA, por sus siglas en inglés), vigente en contextos anglosajones, y

el Reglamento General de Protección de Datos (GDPR) de la Unión Europea, cuyo alcance extraterritorial puede afectar a cualquier plataforma que procese datos de ciudadanos europeos ([XAIEducation2024](#)). Ambos marcos exigen el principio de *minimización de datos* —recopilar únicamente los datos estrictamente necesarios—, el consentimiento informado, y la implementación de salvaguardas técnicas como cifrado en reposo y en tránsito, control de acceso basado en roles (RBAC) y registros de auditoría. Adicionalmente, la Ley de Inteligencia Artificial de la Unión Europea (EU AI Act) clasifica los sistemas de IA utilizados en educación como sistemas de “alto riesgo”, lo que impone obligaciones adicionales de transparencia, explicabilidad y evaluación de impacto sobre la privacidad (DPIA) antes de su despliegue ([XAIEducation2024](#)). En el diseño de SynapTome, estas consideraciones se traducen en la adopción de Arquitectura Limpia con separación estricta entre la capa de datos y los servicios de IA, el cifrado de los *embeddings* vectoriales almacenados en PostgreSQL, y la implementación de políticas de retención de datos que permitan la eliminación completa del historial de un estudiante a solicitud expresa.

3.2.11 Arquitectura Limpia (*Clean Architecture*)

La Arquitectura Limpia es un patrón de diseño de software que promueve la separación estricta de responsabilidades mediante un sistema de capas concéntricas, aislando la lógica de negocio y las reglas del dominio de los *frameworks*, interfaces de usuario o bases de datos **Martin2017**. Su principio central, la Regla de Dependencia, establece que los módulos de alto nivel no deben depender de los de bajo nivel, sino que ambos deben depender de abstracciones ([Martin2017](#)).

En el desarrollo de plataformas educativas integrales, mantener un *backend* escalable y modular bajo este enfoque resulta indispensable para soportar *pipelines* intensivos de IA **Upadhyay2026; Solanki2026**. Su aplicación en ecosistemas basados en C# y ASP.NET Core permite construir APIs RESTful robustas donde los controladores son totalmente independientes de los servicios de infraestructura como PostgreSQL o los motores de LLM, asegurando que la integración de nuevas tecnologías de IA no afecte el núcleo lógico del sistema ([Afian2025](#)).




Figura 8— Capas concéntricas de dependencias bajo el diseño de Arquitectura Limpia.

3.3 Marco conceptual

- a) **LLM (Large Language Model)**. Modelo de inteligencia artificial basado en redes neuronales profundas, típicamente sobre la arquitectura Transformer, entrenado con cantidades masivas de datos para comprender, procesar y generar lenguaje natural de forma coherente ([Vaswani2017](#); [KardanMoghaddam2025](#)).
- b) **RAG (Retrieval-Augmented Generation)**. Arquitectura que combina la recuperación de fragmentos de información relevantes desde una base de conocimiento externa con la generación de texto de un LLM, utilizada para reducir las alucinaciones y anclar las respuestas a un contexto verificable ([Kannammal2024](#)).
- c) **TrOCR (Transformer-based Optical Character Recognition)**. Arquitectura de extremo a extremo para el reconocimiento de texto, compuesta por un codificador de visión (por ejemplo, DeiT o BEiT) y un decodificador de lenguaje (por ejemplo, RoBERTa), capaz de transcribir imágenes de texto manuscrito o impreso de manera autorregresiva ([Zhang2026](#)).
- d) **Grafo de Conocimiento (Knowledge Graph)**. Estructura de datos que representa información como una red semántica dirigida compuesta por nodos (entidades o tópicos) y aristas (relaciones), utilizada para capturar el contexto global y las conexiones entre los conceptos de un corpus ([Chen2023](#)).
- e) **Topic Maps (Mapas de Tópicos)**. Estándar de representación del conocimiento que define un modelo abstracto para estructurar semánticamente

redes de información y enlaces, facilitando el descubrimiento y la conexión de conceptos ([Obionwu2022](#)).

f) **CER y WER (Character/Word Error Rate)**. Métricas estándar para evaluar sistemas de reconocimiento de texto, que calculan el porcentaje de caracteres o palabras incorrectamente reconocidos respecto al total del texto de referencia; valores más bajos indican mayor precisión del modelo ([AlHitawi2026](#)).

g) **ROUGE y BERTScore**. Métricas utilizadas para evaluar la calidad de resúmenes generados automáticamente: ROUGE mide la superposición de n-gramas entre el resumen generado y uno de referencia, mientras que BERTScore evalúa la similitud semántica mediante representaciones vectoriales contextuales ([Chen2023](#)).

h) **Clean Architecture (Arquitectura Limpia)**. Patrón de diseño de software que organiza el sistema en capas concéntricas, aislando la lógica de negocio de los frameworks, la interfaz de usuario y la base de datos, de modo que las dependencias siempre apunten hacia el núcleo del dominio ([Martín2017](#)).

i) **Endpoint**. En el marco del estilo arquitectónico REST, URL específica mediante la cual un recurso es identificado y accedido por un cliente a través de los métodos estándar del protocolo HTTP ([Fielding2000](#); [Afian2025](#)).

j) **JWT (JSON Web Token)**. Estándar abierto (RFC 7519) que define un formato compacto y seguro basado en JSON para representar y transmitir información verificable (*claims*) entre dos partes, comúnmente utilizado para la autenticación en APIs ([Jones2015](#)).

k) **SignalR**. Biblioteca de software del entorno ASP.NET Core que facilita la comunicación web bidireccional en tiempo real, vital para habilitar la edición concurrente y la colaboración síncrona entre usuarios ([Shirkande2025](#)).

l) **PostgreSQL**. Sistema de gestión de bases de datos relacionales de código abierto que, mediante esquemas optimizados y extensiones específicas, permite almacenar de forma eficiente metadatos, vectores semánticos y estructuras de grafos de conocimiento ([Afian2025](#); [Upadhyay2026](#)).

CAPÍTULO IV METODOLOGÍA

4.1 Tipo y nivel de investigación

La presente investigación se clasifica por su propósito como Tecnológica Aplicada, dado que busca resolver un problema práctico y concreto: la sobrecarga cognitiva y la desorganización de apuntes en el entorno universitario, mediante el desarrollo de una solución de software (SynapTome). Por su alcance y profundidad, el estudio corresponde a un nivel explicativo-experimental (específicamente, un diseño cuasi-experimental). Este nivel permite no solo describir el ecosistema desarrollado, sino también determinar las relaciones de causa y efecto que la Variable Independiente (el ecosistema basado en RAG, TrOCR y Grafos de Conocimiento) ejerce sobre la Variable Dependiente (la retención de conocimientos, el rendimiento académico y el aprendizaje colaborativo). Como señalan **Kreijkes2026**, el uso de diseños experimentales en entornos educativos es fundamental para cuantificar de manera objetiva los efectos de las herramientas basadas en LLMs sobre la comprensión lectora y la memoria de los estudiantes.

4.2 Diseño de la investigación

Para abordar la complejidad del ecosistema SynapTome, el diseño metodológico se divide en dos vertientes complementarias: un diseño de ingeniería de software y un diseño de validación académica.

- **Diseño de Ingeniería de Software:** Se empleará la metodología ágil Scrum. Según **Afian2025**, las metodologías ágiles soportan el desarrollo iterativo, la retroalimentación continua y la adaptabilidad, características esenciales para el desarrollo exitoso de plataformas de tutoría impulsadas por inteligencia artificial. El desarrollo se estructurará en sprints que abarcarán la planificación, el diseño, la implementación del backend y los pipelines de IA, y las pruebas continuas de las funciones.
- **Diseño de Evaluación (Validación):** Se utilizará un diseño de tipo pre-test / post-test con un grupo cuasi-experimental. Se medirá el desempeño académico (retención de conocimientos) de los estudiantes antes de la adopción del ecosistema SynapTome y, tras un periodo de uso continuo de la herramienta,

se aplicará un post-test para evaluar el impacto real generado por la plataforma interactiva y colaborativa en la retención del conocimiento y en el fortalecimiento del aprendizaje colaborativo entre pares.

4.3 Pipeline del sistema

Para operativizar el primer objetivo específico y transformar el flujo analógico de los estudiantes en un entorno digital de alta fidelidad, se diseñó un pipeline de procesamiento asíncrono desacoplado. La justificación de esta estructura lógica radica en la necesidad de mitigar la fatiga y el error humano derivado de la transcripción manual de fórmulas matemáticas bidimensionales complejas (como integrales múltiples, matrices o sistemas diferenciales).

El pipeline actúa directamente sobre la variable dependiente (eficiencia de captura), procesando los apuntes manuscritos mediante tres etapas críticas: normalización de la imagen, inferencia autorregresiva basada en el modelo Transformer TrOCR con *fine-tuning*, y un post-procesamiento de sanitización semántica que traduce los mapas de características visuales en sintaxis LATEX válida y estandarizada. Este flujo asegura que el material resultante disponible para el autoestudio del alumno esté completamente libre de distorsiones algebraicas que alteren el significado científico original del cuaderno de clase.




Figura 9— Descripción clara del contenido de la imagen enfocada en el impacto o flujo del estudiante.

4.4 Descripción ética de la investigación

El desarrollo y despliegue del ecosistema SynapTome se adherirá a estrictos estándares de ética y privacidad de la información (Kreijkes2026; Dano2026). Antes de iniciar las pruebas, se obtendrá un consentimiento informado por escrito de los estudiantes de la UNAMBA, garantizando que su participación sea volun-

taria y que tengan el derecho de retirarse del estudio en cualquier momento. A nivel técnico, el tratamiento de los datos personales y el contenido de los apuntes manuscritos subidos por los usuarios se gestionará con políticas de seguridad de grado industrial. Para asegurar la protección de los datos en tránsito y en reposo, la arquitectura implementará autenticación segura mediante tokens JWT (JSON Web Tokens) en los endpoints de la API, mientras que toda la información persistente, incluidas las métricas de evaluación y los grafos relacionales, será resguardada en una base de datos PostgreSQL aplicando el encriptado adecuado, evitando el acceso no autorizado y manteniendo la confidencialidad de la información académica y personal (Upadhyay2026).

4.5 Población y muestra

- Población: La población objetivo está constituida por los estudiantes matriculados en la Escuela Académico Profesional de Ingeniería de Sistemas de la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), durante el año académico en curso.
- Se seleccionará una muestra mediante un muestreo no probabilístico por conveniencia, basado en la disponibilidad, el nivel de interacción digital de los estudiantes y su inscripción en cursos de alta densidad matemática o teórica. Este tipo de muestreo facilita el reclutamiento para pruebas tecnológicas y de usabilidad en entornos controlados de laboratorio o aulas informáticas (Kreijkes2026).

4.6 Procedimiento

El procedimiento general de la investigación comprenderá cinco fases sistemáticas, desde el levantamiento de requisitos hasta la evaluación del sistema "SynapTome.^{en} un entorno real con estudiantes de Ingeniería de Sistemas de la UNAMBA. La Tabla 2 resume las actividades, las herramientas tecnológicas empleadas y los entregables de cada fase.

Tabla 2— Fases del procedimiento de investigación

Fase	Actividades	Herramientas / Tecnologías	Entregable
1. Levantamiento de requisitos y diseño	Identificación de las necesidades de digitalización y colaboración de los estudiantes; diseño de la arquitectura del ecosistema (modelo relacional y lógica de grafos de conocimiento) (Afian2025)	Diagramas UML, modelo entidad-relación, PostgreSQL	Documento de requisitos y diagrama de arquitectura
2. Desarrollo (Backend y Frontend)	Construcción del núcleo del sistema bajo Clean Architecture: orquestación de la lógica de negocio e integración con APIs de IA en el backend, y desarrollo de una interfaz reactiva y colaborativa en el frontend (Martin2017 ; Afian2025)	C# / ASP.NET Core, Next.js, React, PostgreSQL	Prototipo funcional (módulos CRUD y autenticación JWT)
3. Integración de RAG y TrOCR	Implementación del middleware RAG para acoplar la recuperación de vectores semánticos con los LLMs; fine-tuning de la arquitectura TrOCR con corpus matemático y manuscrito para adaptar el modelo al dominio (Kannammal2024 ; Zhang2026 ; AlvarezPerez2026)	Bases de datos vectoriales, TrOCR, LLM (API), Python para fine-tuning	Pipeline de IA integrado (módulo OCR + módulo RAG)
4. Pruebas alfa y beta	Pruebas de caja negra, pruebas unitarias automatizadas y pruebas preliminares con un grupo reducido de usuarios para depurar errores de concurrencia y validar la sincronización en tiempo real (Shirkande2025)	SignalR (WebSockets), frameworks de testing (xUnit / Jest)	Reporte de pruebas y correcciones
5. Evaluación en entorno real	Despliegue de SynapTome para la muestra de estudiantes de la UNAMBA; ejecución de pre-test y post-test; recolección de datos de rendimiento y métricas del sistema	Cuestionarios digitales, panel de métricas del sistema	Base de datos de resultados (pre/post-test)

4.7 Técnicas e instrumentos

Para medir de manera rigurosa la eficacia algorítmica del sistema y el nivel de aceptación por parte de los usuarios, se emplearán técnicas mixtas (cuantitativas y cualitativas), combinando la evaluación experimental del rendimiento de los modelos de IA con la percepción subjetiva de los estudiantes.

4.7.1 Técnicas

- **Análisis documental:** Revisión de antecedentes, literatura técnica y datasets de referencia (por ejemplo, SPA-Sentences) para establecer las líneas base de comparación de los modelos de OCR/HTR y sumaria-
ción ([TarazonaCruz2024](#)).
- **Experimentación:** Ejecución controlada del pipeline TrOCR y del
módulo RAG sobre un conjunto de apuntes manuscritos y resúmenes
generados, registrando los resultados de manera cuantitativa ([AlHitawi2026](#)).
- **Encuesta:** Aplicación de cuestionarios estructurados a los estudiantes
participantes para recoger su percepción sobre la usabilidad, utilidad y
satisfacción con SynapTome ([Afian2025](#); [Dano2026](#)).

4.7.2 Instrumentos

La Tabla 3 detalla los instrumentos empleados para cada técnica, indicando la variable que mide y la escala o métrica utilizada.

Tabla 3— Instrumentos de recolección de datos

Instrumento	Variable / Dimensión que mide	Escala / Métrica	Fuente
Ficha de registro de transcripción OCR	Eficiencia de captura técnica (preservación de información manuscrita)	Tasa de Error de Caracteres (CER %) y $\text{\LaTeX}$ válido	(AlHitawi2026)
Ficha de evaluación de fidelidad conceptual	Calidad factual del repaso (reducción de errores conceptuales en notas)	Índice de alucinación (%) y coherencia de resúmenes	(Saxena2025; Ning2025)
Cuestionario NASA-TLX (Carga Mental)	Sobrecarga cognitiva y fatiga mental del estudiante en su autoestudio	Escala ordinal de carga de trabajo (0–100 ptos)	(Hart1988)
Cuestionario de usabilidad (SUS) y Ficha de monitoreo web	Eficiencia operativa y frecuencia del aprendizaje colaborativo en red	Puntuación normalizada SUS (0–100) e intercambio colaborativo (ítems/semana)	(Afian2025)
Evaluación Pre-test / Post-test de retención	Rendimiento académico e incremento de la fijación conceptual a largo plazo	Calificación cuantitativa (Escala vigesimal 0–20)	(Kreijkes2026)

4.8 Estadístico de la investigación

Para evaluar el desempeño del pipeline de visión por computadora TrOCR en la digitalización de apuntes manuscritos, se calcularán cuantitativamente la Tasa de Error de Caracteres (CER) y la Tasa de Error de Palabras (WER), garantizando así que la transcripción a $\text{\LaTeX}$ sea altamente precisa (AlHitawi2026). Ambas métricas se basan en la distancia de edición de Levenshtein y se calculan como:

$$\text{CER} = \frac{S + D + I}{N} \quad (4.2)$$

$$\text{WER} = \frac{S_w + D_w + I_w}{N_w} \quad (4.3)$$

donde S , D e I representan el número de sustituciones, eliminaciones e inserciones de caracteres (o S_w , D_w , I_w a nivel de palabras) necesarias para transformar el texto reconocido en el texto de referencia, y N (N_w) es el número total de caracteres (palabras) en el texto de referencia. Valores cercanos a 0 indican una transcripción casi perfecta.

Para evaluar la calidad, coherencia y fidelidad semántica de los resúmenes abstractivos y la mitigación de alucinaciones del motor RAG, se emplearán métricas estándar de procesamiento de lenguaje natural como ROUGE-N y BLEU, complementadas opcionalmente con BERTScore (Saxena2025; Ning2025). La métrica ROUGE-N se define como:

$$\text{ROUGE-N} = \frac{\sum_{S \in \{\text{Referencias}\}} \sum_{\text{gram}_n \in S} \text{Count}_{\text{match}}(\text{gram}_n)}{\sum_{S \in \{\text{Referencias}\}} \sum_{\text{gram}_n \in S} \text{Count}(\text{gram}_n)} \quad (4.4)$$

es decir, la proporción de n -gramas del resumen de referencia que también aparecen en el resumen generado por el sistema.

Para la evaluación de la aceptación tecnológica (Tabla 3), los puntajes obtenidos en los cuestionarios SUS se calcularán siguiendo la fórmula estándar:

$$SUS = 2,5 \times \sum_{i=1}^{10} x'_i \quad (4.5)$$

donde x'_i corresponde a la puntuación ajustada de cada uno de los 10 ítems (restando 1 a los ítems impares y restando el valor original a 5 en los ítems pares), de modo que el puntaje final se normaliza en una escala de 0 a 100.

Finalmente, dado que el diseño de evaluación implica medir el rendimiento académico de un mismo grupo de estudiantes en dos momentos distintos (pre-test y post-test), la comprobación de la hipótesis principal se realizará utilizando la prueba paramétrica T de Student para muestras relacionadas (pares), asumiendo la normalidad en la distribución de los datos de desempeño:

$$t = \frac{\bar{d}}{s_d / \sqrt{n}} \quad (4.6)$$

donde $\bar{d}$ es la media de las diferencias entre las puntuaciones del post-test y el pre-test de cada estudiante, s_d es la desviación estándar de esas diferencias, y n es el tamaño de la muestra. En el caso de que la distribución de las puntuaciones de retención (por ejemplo, resultados de *free recall* o quizzes integrados) no se ajuste a la normalidad, se empleará la prueba no paramétrica de Wilcoxon para muestras relacionadas como alternativa equivalente (Krejkes2026).

Adicionalmente, para cuantificar la magnitud práctica del efecto observado (más allá de su significancia estadística), se calculará el tamaño del efecto mediante la d de Cohen para muestras relacionadas:

$$d = \frac{\bar{d}}{s_d} \quad (4.7)$$

interpretando los valores según las convenciones habituales ($d \approx 0,2$ efecto pequeño, $d \approx 0,5$ efecto moderado, $d \geq 0,8$ efecto grande), de manera consistente con los tamaños de efecto reportados en estudios similares (Krejkes2026).

En todos los casos se aplicará un nivel de significancia de $\alpha = 0,05$ ($p < 0,05$) para confirmar estadísticamente si las mejoras obtenidas en la retención del conocimiento mediante la plataforma SynapTome son significativas frente al modelo tradicional de toma de apuntes.

958
959
960
961
962

963
964

CAPÍTULO V

ADMINISTRACIÓN DEL PROYECTO

965
966
967
968
969
970

5.1 Cronograma de actividades

El proyecto de investigación se desarrollará durante el año académico 2026, organizado en seis fases secuenciales, con una duración total de seis meses. Las Tablas 4 y 5 presentan la distribución temporal de las actividades por fase, desde la planificación y revisión bibliográfica hasta la evaluación final del sistema y el análisis estadístico de los resultados.

Tabla 4— Cronograma de actividades – Fases I a III (Julio – Diciembre 2026)

Fases y Actividades (2026)	Jul				Ago				Sep				Oct				Nov				Dic			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Fase I: Planificación y revisión bibliográfica																								
1. Revisión sistemática de literatura y antecedentes	X	X																						
2. Elaboración y aprobación del proyecto de tesis	X	X																						
3. Coordinación institucional con la UNAMBA			X	X																				
4. Diseño preliminar de la arquitectura (BD relacional y grafos)			X	X																				
Fase II: Diseño y desarrollo del backend																								
5. Levantamiento de requisitos funcionales y no funcionales					X																			
6. Diseño de BD (PostgreSQL) y modelado de grafos					X	X																		
7. Desarrollo del backend (ASP.NET Core, Clean Architecture, JWT)						X	X	X																
8. Diseño de interfaces (mockups) de SynapTome					X	X																		
Fase III: Desarrollo del frontend y colaboración en tiempo real																								
9. Desarrollo del frontend (Next.js / React)									X	X	X													
10. Integración de SignalR (colaboración en tiempo real)										X	X	X												
11. Pruebas unitarias de los módulos CRUD											X	X												

Tabla 5— Cronograma de actividades – Fases IV a VI (Julio – Diciembre 2026)

Fases y Actividades (2026)	Jul				Ago				Sep				Oct				Nov				Dic			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Fase IV: Integración de los módulos de IA (RAG y TrOCR)																								
12. Implementación del middleware RAG													X	X										
13. Fine-tuning de TrOCR (corpus matemático y manuscrito)													X	X	X									
14. Integración del pipeline IA (RAG + TrOCR) al backend															X	X								
Fase V: Pruebas del sistema y pre-test																								
15. Pruebas de caja negra y depuración																	X	X						
16. Pruebas alfa y beta con usuarios																		X	X					
17. Aplicación del pre-test (muestra UNAMBA)																			X	X				
18. Despliegue de SynapTome (evaluación real)																				X				
Fase VI: Evaluación final y análisis de resultados																								
19. Implementación y uso real con la muestra																					X	X		
20. Aplicación del post-test (SUS / UAT)																						X	X	
21. Análisis estadístico (T-Student, <i>d</i> de Cohen)																							X	
22. Redacción de resultados y conclusiones																							X	X
23. Revisión final y entrega de tesis																								X

5.2 Presupuesto

La Tabla 6 presenta el presupuesto estimado para el desarrollo del proyecto de investigación, organizado por categorías de gasto. Las principales herramientas de software (Visual Studio, .NET SDK, Next.js y Jamovi) se utilizarán bajo licencias gratuitas u *open source*, mientras que los principales costos corresponden al consumo de APIs de modelos de lenguaje, al hosting del sistema y a la aplicación de instrumentos a la muestra de estudiantes.

Tabla 6— Presupuesto estimado del proyecto de investigación

N.º	Descripción	Cantidad	P. unitario (S/)	Total (S/)
Hardware				
1	Laptop de desarrollo (equipo ya disponible)	1	0,00	0,00
2	Tablet con lápiz óptico para pruebas de digitalización de apuntes (TrOCR)	1	850,00	850,00
3	Cuadernos y materiales para conformar el corpus de apuntes manuscritos	1	50,00	50,00
Software y servicios en la nube				
4	Visual Studio Community / .NET SDK (licencia gratuita — <i>open source</i>)	1	0,00	0,00
5	Créditos de API de LLM (Anthropic / OpenAI) para RAG y summarización	6 meses	80,00	480,00
6	Hosting del backend (Azure App Service / Railway, plan básico)	6 meses	35,00	210,00
7	Base de datos PostgreSQL en la nube (Supabase / Neon, plan gratuito)	6 meses	0,00	0,00
8	Dominio web (.com)	1	45,00	45,00
9	Jamovi / JASP (software estadístico, licencia gratuita)	1	0,00	0,00
Recursos humanos y servicios				
10	Impresión y aplicación de cuestionarios (SUS, UAT, pre-test y post-test)	120	1,00	120,00
11	Movilidad para coordinación institucional con la UNAMBA	6 salidas	15,00	90,00
12	Material de oficina (papel, lapiceros, impresiones generales)	1	100,00	100,00
TOTAL GENERAL				S/ 1 945,00

5.3 Fuente de financiamiento

El presente proyecto de investigación será financiado íntegramente con recursos propios del investigador. La mayor parte de las herramientas de software utilizadas

981 (Visual Studio, .NET SDK, Next.js, React y Jamovi) son de acceso gratuito o de
982 código abierto, mientras que los servicios en la nube (créditos de API de LLM,
983 hosting y base de datos) se mantienen dentro de planes básicos o niveles gratuitos,
984 lo que reduce significativamente los costos del proyecto.

985

986

987

988

989

REFERENCIAS BIBLIOGRÁFICAS

990

991

992

993

994

995

996

997

998

999

1000

ANEXOS

Tabla 7— Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema SynapTome

Problema de Investigación	Objetivos de la Investigación	Hipótesis de la Investigación	Variables	Indicadores / Métricas	Metodología Aplicada
Problema General ¿De qué manera la transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente SynapTome optimiza el rendimiento académico, reduce la sobrecarga cognitiva y eleva la eficacia del aprendizaje colaborativo en estudiantes universitarios?	Objetivo General Optimizar la gestión del conocimiento, ampliar el acceso a repositorios de estudio y fortalecer el aprendizaje colaborativo, mediante la evaluación e implementación del ecosistema inteligente SynapTome, con el propósito de incrementar significativamente el rendimiento académico de los estudiantes universitarios.	Hipótesis General La transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente SynapTome optimiza significativamente el rendimiento académico, reduce la sobrecarga cognitiva y eleva la eficacia del aprendizaje colaborativo en los estudiantes universitarios (Shirkande2025; Afian2025).	Variable Independiente (VI): Ecosistema inteligente con visión artificial y LLM. Variable Dependiente (VD): Aprendizaje colaborativo y rendimiento académico.	* Tasa de Error de Caracteres (CER %). * Tiempo de consolidación de apuntes (min). * Índice de alucinación factual (%). * Puntaje de sobrecarga mental (NASA-TLX). * Calificación de exámenes (0–20). * Intercambio colaborativo (ítems/semana).	Tipo: Aplicada. Nivel: Explicativo. Diseño: Experimental (Pre-test / Post-test). Enfoque: Cuantitativo. Método: Científico y estadístico. Población y Muestra: Estudiantes de la Escuela de Informática y Sistemas, UNAMBA.
Problema Específico 1 ¿En qué medida la migración de los estudiantes hacia un flujo de digitalización automatizado influye en la tasa de preservación de información técnica y en la reducción del tiempo dedicado a la consolidación de apuntes manuscritos?	Objetivo Específico 1 Medir el incremento en la tasa de preservación de información técnica y la reducción del tiempo de consolidación de apuntes manuscritos en los estudiantes universitarios, mediante la transición de métodos de transcripción analógica tradicionales hacia un flujo de digitalización automatizado de alta precisión.	Hipótesis Específica 1 La migración de los estudiantes hacia un flujo de digitalización automatizado mediante un pipeline HTR basado en la arquitectura TrOCR con <i>fine-tuning</i> incrementa significativamente la tasa de preservación de información técnica en sus apuntes y reduce el tiempo promedio dedicado a la consolidación de notas manuscritas respecto al estado inicial analógico.	Dimensión VI: Módulo de digitalización y transcripción visual (TrOCR). Dimensión VD: Eficiencia de captura técnica del estudiante.	* Tasa de Error de Caracteres (CER %). * Tiempo semanal de transcripción manual o consolidación de apuntes (minutos). * Precisión de renderizado en sintaxis L ^A T _E X (%).	* Pipeline en Node.js de procesamiento de imágenes. * Modelo autorregresivo Transformer (TrOCR). * Análisis de varianza de tiempos de edición. * Pruebas experimentales en asignaturas de Cálculo y Física.
Problema Específico 2 ¿Cómo repercute el condicionamiento del entorno de asimilación cognitiva de los alumnos a un corpus académico validado en el nivel de veracidad factual y en la reducción de errores conceptuales presentes en sus materiales de autoestudio?	Objetivo Específico 2 Determinar la reducción en el índice de errores conceptuales y datos falsos (alucinaciones) en el material de autoestudio utilizado por los alumnos, evaluando el nivel de fidelidad y veracidad factual de sus resúmenes antes y después de restringir su entorno de asimilación cognitiva a un corpus académico validado.	Hipótesis Específica 2 El condicionamiento del entorno de asimilación cognitiva de los alumnos a un corpus académico validado mediante un middleware RAG restrictivo disminuye drásticamente el índice de errores conceptuales y datos falsos presentes en sus materiales de autoestudio, asegurando una alta fidelidad factual en comparación con el uso de herramientas genéricas de información.	Dimensión VI: Middleware de recuperación y fidelidad factual (RAG). Dimensión VD: Calidad factual de los recursos de repaso del estudiante.	* Índice de inserción de conceptos erróneos o alucinados (%). * Coincidencia semántica con el material base académico (%). * Tasa de veracidad conceptual en resúmenes.	* Indexación vectorial relacional. * Chunking semántico parametrizado de sílabos y apuntes oficiales. * Inferencia controlada sobre Modelos de Lenguaje Grande (LLMs). * Evaluación de fidelidad de resúmenes.
Problema Específico 3 ¿Cuál es el impacto latente de la adopción de un entorno de aprendizaje interconectado basado en mapas conceptuales dinámicos sobre las calificaciones promedio alcanzadas por los estudiantes y el nivel de sobrecarga cognitiva percibido?	Objetivo Específico 3 Cuantificar el impacto latente en las calificaciones promedio y el nivel de sobrecarga cognitiva percibida por los estudiantes, analizando la variación de sus puntajes académicos y fatiga mental tras migrar de un esquema de repaso individual aislado a un entorno de aprendizaje interconectado y evaluado de forma dinámica.	Hipótesis Específica 3 La adopción de un entorno de aprendizaje interconectado basado en Grafos de Conocimiento y evaluaciones dinámicas automatizadas incrementa las calificaciones promedio de los estudiantes y reduce los niveles de sobrecarga cognitiva percibida en comparación con los valores basales registrados durante los métodos de repaso individuales y aislados.	Dimensión VI: Motor relacional topológico y evaluaciones dinámicas. Dimensión VD: Desempeño académico y carga cognitiva declarada del alumno.	* Calificaciones cuantitativas alcanzadas en exámenes parciales (Escala 0–20). * Índice de fatiga mental y estrés autopercebido (Escala NASA-TLX). * Volumen de intercambio interactivo eficaz (ítems/semana).	* Base de datos orientada a grafos indexados. * Algoritmos de IA para generación automatizada de cuestionarios formativos (quizzes). * Protocolos de sincronización web interactiva en tiempo real (SignalR). * Aplicación de la prueba estadística t de Student unilateral derecha.