

1 **UNIVERSIDAD NACIONAL MICAELA BASTIDAS DE APURÍMAC**
2 **FACULTAD DE INGENIERÍA**
3
4
5 **ESCUELA ACADÉMICO PROFESIONAL DE INGENIERÍA INFORMATICA Y**
6 **SISTEMAS**



7
8
9
10 Proyecto de Tesis
11
12 Ecosistema Inteligente con Visión Artificial y LLM para mejorar el aprendizaje
13 colaborativo en la UNAMBA, 2026
14

15 Presentado por:

16
17
18 Clinio Omar Rayme Huacho

19
20 Para optar el título de Ingeniero Informatico y Sistemas
21

22
23
24 Abancay, Perú

25
26 2026

UNIVERSIDAD NACIONAL MICAELA BASTIDAS DE APURÍMAC
FACULTAD DE INGENIERÍA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMATICA Y SISTEMAS



TESIS

Ecosistema Inteligente con Visión Artificial y LLM para mejorar el Aprendizaje Colaborativo en la UNAMBA, 2026

Presentado por **Clinio Omar Rayme Huacho**, para optar el título de Ingeniero Informático y Sistemas

Sustentado y aprobado (fecha de sustentación) ante el jurado evaluador:

Presidente: _____
Grado. Nombres y apellidos

Primer miembro: _____
Grado. Nombres y apellidos

Segundo miembro: _____
Grado. Nombres y apellidos

Asesor: _____
M.Sc. Yhon Fuentes Huaman

Agradecimiento

A la Universidad Nacional Micaela Bastidas de Apurímac y de manera especial a la Escuela Académico Profesional de Ingeniería de Informática y Sistemas, por haberme brindado el espacio institucional y las herramientas necesarias para mi formación profesional y científica.

A nuestros asesores y docentes de la facultad, cuyos rigurosos comentarios, correcciones y constante exigencia metodológica permitieron reorientar el enfoque de esta investigación hacia un impacto real y medible en el aprendizaje estudiantil.

A los compañeros de equipo y de ruta académica, por el soporte técnico incondicional, las largas noches de debate arquitectónico y el esfuerzo compartido en la construcción de este proyecto; este logro es también el reflejo de nuestra dedicación colectiva.

Finalmente, a cada uno de los estudiantes de nuestra casa de estudios que participaron activamente en las pruebas experimentales, cuya retroalimentación e interacciones semánticas dieron vida y validaron el propósito de este ecosistema digital.

Dedicatoria

A mis padres, por su amor incondicional, su paciencia infinita y por ser el pilar fundamental que sostuvo cada uno de mis pasos a lo largo de este trayecto académico y personal.

A mi familia, por sus palabras de aliento en los momentos de mayor exigencia y por creer firmemente en mi capacidad para alcanzar mis metas.

Y a todas las personas que, de manera silenciosa pero constante, compartieron sus conocimientos, su tiempo y su apoyo, motivándome a culminar con éxito esta importante etapa de formación profesional.

45
46
47
48

49

ÍNDICE

	Pag.
50 INTRODUCCIÓN	1
51 CAPÍTULO I	3
52 PLANTEAMIENTO DEL PROBLEMA	3
53 1.1 Descripción del problema	3
54 1.2 Enunciado del problema	4
55 1.2.1 Problema general	4
56 1.2.2 Problemas específicos	4
57 1.3 Justificación de la investigación	4
58 1.3.1 Justificación Científica	5
59 1.3.2 Justificación Tecnológica	5
60 1.3.3 Justificación Institucional	5
61 1.4 Ubicación y Contextualización	6
62 CAPÍTULO II	7
63 OBJETIVOS E HIPÓTESIS	7
64 2.1 Objetivos de la investigación	7
65 2.1.1 Objetivo general	7
66 2.1.2 Objetivos específicos	7
67 2.2 Hipótesis de la investigación	7
68 2.2.1 Hipótesis general	7
69 2.2.2 Hipótesis específicas	7
70 CAPÍTULO III	10
71 MARCO TEÓRICO REFERENCIAL	10
72 3.1 Antecedentes	10
73 3.1.1 Antecedentes internacionales	10
74 3.1.2 Antecedentes nacionales	12
75 3.2 Marco teórico	12
76 3.2.1 Inteligencia Artificial Generativa y Arquitectura RAG	12
77 3.2.2 Arquitectura Transformer y Mecanismo de Atención	13
78 3.2.3 Reconocimiento de Texto Manuscrito (HTR), TrOCR y Fórmulas	
79 Matemáticas	14
80 3.2.4 Vector Embeddings y Bases de Datos Vectoriales	15

81	3.2.5	Grafos de Conocimiento	15
82	3.2.6	Generación Automática de Evaluaciones Adaptativas	16
83	3.2.7	Aprendizaje Activo y Recuperación Espaciada (<i>Spaced Repetition</i>)	16
84	3.2.8	Aprendizaje Colaborativo Mediado por Tecnología	17
85	3.2.9	Carga Cognitiva y Medición con NASA-TLX	17
86	3.2.10	Privacidad y Seguridad de Datos Estudiantiles en Plataformas IA	18
87	3.2.11	Arquitectura Limpia (<i>Clean Architecture</i>)	19
88	3.3	Marco conceptual	19
89	CAPÍTULO IV		21
90	METODOLOGÍA		21
91	4.1	Tipo y nivel de investigación	21
92	4.2	Diseño de la investigación	21
93	4.3	Pipeline del sistema	22
94	4.4	Descripción ética de la investigación	22
95	4.5	Población y muestra	23
96	4.6	Procedimiento	23
97	4.7	Técnicas e instrumentos	24
98	4.7.1	Técnicas	24
99	4.7.2	Instrumentos	25
100	4.8	Estadístico de la investigación	25
101	CAPÍTULO V		27
102	ADMINISTRACIÓN DEL PROYECTO		27
103	5.1	Cronograma de actividades	27
104	5.2	Presupuesto	30
105	5.3	Fuente de financiamiento	30
106	REFERENCIAS BIBLIOGRÁFICAS		32
107	ANEXOS		37

108
109
110
111

112

ÍNDICE DE TABLAS

113	Tabla 1 — Operacionalización de las variables de investigación	9
114	Tabla 2 — Fases del procedimiento de investigación	24
115	Tabla 3 — Instrumentos de recolección de datos	25
116	Tabla 4 — Cronograma de actividades – Fases I a III (Julio – Diciembre 2026) .	28
117	Tabla 5 — Cronograma de actividades – Fases IV a VI (Julio – Diciembre 2026)	29
118	Tabla 6 — Presupuesto estimado del proyecto de investigación	30
119	Tabla 7 — Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema	
120	SynapTome	38

121
122
123
124

125

ÍNDICE DE FIGURAS

126	Figura 1 — Descripción clara del contenido de la imagen enfocada en el impacto	
127	o flujo del estudiante.	22

INTRODUCCIÓN

La adopción de la Inteligencia Artificial Generativa ha impulsado una transformación sin precedentes en la educación superior, redefiniendo las metodologías de enseñanza y la asimilación del conocimiento (Vieriu et al., 2025). En este escenario, la gestión de apuntes universitarios ha experimentado una evolución acelerada, migrando desde los métodos manuscritos tradicionales hacia formatos digitales dinámicos e interactivos. Esta transición tecnológica busca optimizar la captura, organización y recuperación de la información académica. Según Krejkes et al. (2026), la integración de Modelos de Lenguaje Grande (LLMs) presenta oportunidades excepcionales para facilitar la comprensión lectora y reducir la carga cognitiva inicial de los estudiantes. Sin embargo, el volumen exponencial de datos técnicos y científicos en disciplinas de ingeniería exige herramientas que trasciendan el simple almacenamiento, demandando ecosistemas capaces de procesar y enlazar semánticamente el contenido educativo.

A pesar de estos avances tecnológicos, la digitalización educativa contemporánea enfrenta desafíos algorítmicos y pedagógicos severos. Los estudiantes de ingeniería padecen de una constante sobrecarga cognitiva al intentar integrar múltiples fuentes de información no estructurada. La adopción pasiva de plataformas de IA genéricas agrava este panorama, induciendo una dependencia tecnológica que inhibe el análisis crítico y la apropiación del conocimiento (Vieriu et al., 2025). A nivel técnico, los LLMs estándar adolecen de un problema crítico de “alucinaciones”; dado que carecen de mecanismos intrínsecos para verificar la veracidad de los hechos, frecuentemente generan información plausible pero fácticamente incorrecta (T. Chen et al., 2023). Adicionalmente, la digitalización de apuntes científicos enfrenta la barrera de la notación matemática, donde los sistemas tradicionales fracasan al procesar estructuras espaciales complejas (Alvarez-Perez et al., 2026). Finalmente, las herramientas actuales promueven un consumo individualista y fragmentado de la información, careciendo de la infraestructura lógica para establecer vínculos semánticos que fomenten una colaboración auténtica entre pares (Jiang et al., 2025).

Para mitigar estas brechas tecnológicas y metodológicas, la presente investigación propone formalmente el desarrollo de SynapTome, un ecosistema digital inteligente y colaborativo fundamentado en los principios de la Arquitectura Limpia (Clean Architecture). La infraestructura del sistema orquesta tecnologías de vanguardia para transformar la gestión del aprendizaje: en el núcleo de procesamiento de lenguaje natural, se implementa una arquitectura de Generación Aumentada por Recuperación (RAG) que restringe la inferencia de la IA a un corpus documental validado, garantizando precisión factual y eliminando las alucinaciones (Ning et al., 2025). Para abordar el reto de la digitalización científica, se integra

un pipeline de visión por computadora basado en el modelo Transformer TrOCR, el cual permite la transcripción estructurada de apuntes manuscritos y fórmulas matemáticas al formato LaTeX (KardanMoghaddam et al., 2025). El elemento diferenciador de SynapTome radica en su motor de base de datos relacional modelado mediante Grafos de Conocimiento en PostgreSQL. Estos grafos indexan topológicamente los bloques de estudio, descubriendo relaciones transversales entre múltiples usuarios para catalizar una verdadera Inteligencia Colectiva”(Obionwu et al., 2022). Todo el ecosistema opera con una sincronización concurrente a través de SignalR y C#, con una interfaz reactiva desarrollada en Next.js.

El presente trabajo de investigación se estructura en cinco capítulos secuenciales que detallan el ciclo de vida del proyecto: el Capítulo I expone el planteamiento del problema, su justificación y el contexto universitario del caso de estudio; el Capítulo II detalla los objetivos generales y específicos, así como las hipótesis de investigación y la operacionalización de variables; el Capítulo III desarrolla el marco teórico referencial, profundizando en los fundamentos de las arquitecturas RAG, TrOCR y la teoría subyacente de los Grafos de Conocimiento; el Capítulo IV describe el diseño metodológico, definiendo el enfoque experimental, las métricas de evaluación técnica y los instrumentos de usabilidad; finalmente, el Capítulo V presenta la arquitectura de software implementada, el análisis de los resultados obtenidos durante el despliegue del sistema y las conclusiones finales derivadas del proyecto.

CAPÍTULO I

PLANTEAMIENTO DEL PROBLEMA

1.1 Descripción del problema

En el entorno académico universitario contemporáneo, los estudiantes enfrentan un volumen exponencial de información técnica y científica que a menudo desencadena una severa sobrecarga cognitiva. El procesamiento simultáneo de múltiples fuentes de información no estructurada y la dificultad de organizar apuntes fragmentados limitan la capacidad de comprensión y retención de los alumnos. Teorías del aprendizaje, como la Teoría de la Carga Cognitiva, explican que la división de la atención durante la captura manual o digital de apuntes puede resultar en la pérdida de información crítica y en un bajo rendimiento académico si los métodos de captura no se alinean con un procesamiento estructurado. A pesar de que la toma de apuntes es una herramienta pedagógica esencial, los enfoques tradicionales a menudo generan ecosistemas de estudio aislados que no logran seguir el ritmo de la complejidad del contenido universitario.

Para mitigar esta sobrecarga, los estudiantes han recurrido a Modelos de Lenguaje Grande (LLMs) genéricos en busca de resúmenes y asistencia académica. Sin embargo, la adopción de estos sistemas presenta fallas críticas. Los LLMs tradicionales frecuentemente fracasan al capturar los matices técnicos y factuales propios de los artículos de investigación e ingeniería. Más grave aún es el problema de las “alucinaciones”; los LLMs carecen de una capacidad intrínseca para verificar la veracidad de la información que generan, lo que resulta en la invención de hechos plausibles pero falsos que contaminan el aprendizaje. Además, el uso de resúmenes genéricos omite la intención y el contexto específico del usuario, lo que subraya la necesidad imperativa de sistemas de IA condicionados factualmente.

Por otra parte, la digitalización de apuntes manuscritos en carreras de ingeniería y ciencias exactas enfrenta un cuello de botella computacional significativo debido a la presencia de fórmulas matemáticas, matrices y gráficos. Los sistemas convencionales de Reconocimiento Óptico de Caracteres (OCR) no están diseñados para interpretar la estructura espacial y semántica de las matemáticas. Es necesario el uso de arquitecturas basadas en Transformers, como TrOCR, sometidas a procesos de fine-tuning específicos, para lograr una conversión estructurada y precisa de notación científica hacia el formato LaTeX. La alta variabilidad en los estilos de escritura y el ruido en las imágenes complican severamente la transcripción automatizada si no se emplean pipelines de Deep Learning avanzados.

Finalmente, existe una carencia fundamental de plataformas verdaderamente colaborativas. Históricamente, la gestión de apuntes ha sido un proceso de consumo individual. El aprendizaje colaborativo basado en la gestión del conocimiento es indispensable para el desarrollo de competencias en el aula. No obstante, las herramientas actuales carecen de la infraestructura necesaria para enlazar semánticamente la información entre pares. La literatura sugiere que la implementación de mapas de tópicos y grafos relacionales en los sistemas de gestión del conocimiento es un habilitador técnico crucial para una pedagogía verdaderamente colaborativa, un componente del cual carecen las plataformas educativas estándar.

1.2 Enunciado del problema

1.2.1 Problema general

¿En cuánto disminuye la sobrecarga de apuntes y la fatiga mental, y en qué medida se incrementa el rendimiento académico y la eficacia colaborativa de los estudiantes universitarios de la UNAMBA al transicionar desde esquemas de estudio aislados hacia un entorno de aprendizaje interconectado y automatizado?

1.2.2 Problemas específicos

- ¿En cuánto se reduce el tiempo de consolidación de apuntes manuscritos y cuál es el incremento en la tasa de preservación de información técnica mediante el uso de la aplicación con un módulo de transcripción automatizada (TrOCR) frente a los métodos de transcripción tradicional?
- **Problema Específico 2:** ¿Cuál es la tasa de reducción de errores conceptuales en el material de repaso de los estudiantes al condicionar las respuestas del sistema mediante un middleware RAG acoplado a un LLM en comparación con las herramientas de inteligencia artificial genéricas de entorno abierto?
- **Problema Específico 3:** ¿En cuánto disminuye el nivel de sobrecarga cognitiva y cuál es la variación en las calificaciones promedio de los alumnos al implementar un motor relacional de grafos de conocimiento con evaluaciones dinámicas automatizadas frente a los esquemas basales de estudio aislados?

1.3 Justificación de la investigación

La presente investigación se justifica desde tres dimensiones fundamentales: científica, tecnológica e institucional, las cuales convergen en el desarrollo y despliegue del ecosistema SynapTome para resolver de manera integral los desafíos contemporáneos en la gestión del aprendizaje universitario.

1.3.1 Justificación Científica

A nivel científico, este estudio aporta evidencia empírica sobre cómo resolver las deficiencias inherentes de los Modelos de Lenguaje Grande (LLMs) en contextos académicos. Se demuestra que la integración de Grafos de Conocimiento actúa como una guía semántica que mitiga la incapacidad de los LLMs para verificar hechos, reduciendo drásticamente las “alucinaciones” durante la sumarización abstractiva (T. Chen et al., 2023). Además, la investigación fundamenta un cambio desde un paradigma de aprendizaje pasivo hacia uno constructivista; el uso guiado de la IA para la generación automática de evaluaciones formativas (*quizzes*) e interacciones basadas en apuntes reduce la sobrecarga cognitiva e incrementa significativamente la retención a largo plazo y la comprensión de los estudiantes (Kreijkes et al., 2026; Afian et al., 2025). Finalmente, el proyecto valida la teoría de la pedagogía colaborativa, comprobando que el uso de Mapas de Tópicos (*Topic Maps*) permite estructurar el conocimiento fragmentado, descubriendo relaciones transversales y fomentando una auténtica “Inteligencia Colectiva” (Obionwu et al., 2022).

1.3.2 Justificación Tecnológica

Desde la perspectiva tecnológica, el desarrollo de SynapTome representa un avance en la superación de los cuellos de botella clásicos de la digitalización científica. El proyecto aborda las altas tasas de error de los sistemas OCR tradicionales mediante la implementación de *pipelines* de visión por computadora basados en la arquitectura *Transformer* (TrOCR y Nougat), los cuales, a través de procesos de *fine-tuning*, logran transcribir con alta precisión notación matemática y fórmulas complejas directamente hacia el formato estructurado $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ (Alvarez-Perez et al., 2026; Kardan-Moghaddam et al., 2025). Asimismo, el diseño del sistema orquesta una Arquitectura Limpia (*Clean Architecture*) que integra *Next.js* en el *frontend*, un *middleware* de Generación Aumentada por Recuperación (RAG) condicionado factualmente (Ning et al., 2025; Jiang et al., 2025), y bases de datos relacionales con soporte vectorial como PostgreSQL. Esta integración *full-stack*, apoyada en WebSockets (SignalR), justifica la viabilidad de desplegar un entorno de coedición seguro, escalable y en tiempo real (Shirkande et al., 2025; Upadhyay et al., 2026).

1.3.3 Justificación Institucional

A nivel institucional, la implementación de este ecosistema en la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), específicamente orientado a la Escuela Académico Profesional de Ingeniería de

Sistemas, proporciona una infraestructura digital de vanguardia que impacta directamente en la calidad educativa. Los estudiantes de ingeniería requieren asimilar un volumen denso de información matemática y técnica; al proveerles una plataforma que centraliza, digitaliza y democratiza el acceso a una mayor cantidad de apuntes interconectados, la universidad facilita una mejora medible en el rendimiento académico y las calificaciones de su comunidad estudiantil (Dano et al., 2026). En consecuencia, esta iniciativa dota a la UNAMBA de herramientas tecnológicas de primer nivel, posicionándola como una institución innovadora que adopta la Inteligencia Artificial de manera ética, estructurada y orientada al beneficio colectivo.

1.4 Ubicación y Contextualización

La presente investigación se contextualiza y aplicará en la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), ubicada en la ciudad de Abancay, en la región de Apurímac, Perú. Específicamente, el caso de estudio está enfocado en atender las necesidades académicas y los retos de aprendizaje de los estudiantes de la Escuela Académico Profesional de Ingeniería de Informática y Sistemas. En este entorno, los estudiantes manejan un alto volumen de asignaturas fundamentadas en el cálculo, la física, el álgebra lineal y la algoritmia. Estos tópicos exigen el uso intensivo de notación matemática compleja, diagramas lógicos y esquemas arquitectónicos, los cuales suelen registrarse tradicionalmente de manera manuscrita. Las barreras en la digitalización de esta información, sumadas a la alta carga cognitiva propia de la disciplina y las limitaciones de infraestructura para la colaboración eficiente entre pares, hacen que los estudiantes de la UNAMBA sean los candidatos idóneos para validar la efectividad del ecosistema SynapTome como una herramienta integral para la gestión y democratización de su conocimiento técnico.

328
329
330
331

332
333

CAPÍTULO II

OBJETIVOS E HIPÓTESIS

334
335

2.1 Objetivos de la investigación

2.1.1 Objetivo general

336
337
338
339

Determinar en cuánto se reduce la sobrecarga de apuntes y la fatiga mental, y medir el incremento en el rendimiento académico de los estudiantes universitarios de la UNAMBA al implementar y evaluar una aplicación web basada en un entorno de aprendizaje interconectado y automatizado.

340
341
342
343
344

2.1.2 Objetivos específicos

345
346
347
348
349
350
351
352

- Evaluar en cuánto se reduce el tiempo dedicado a la consolidación de apuntes manuscritos y cuantificar el incremento en la tasa de preservación de información técnica mediante el uso de la aplicación web con un módulo de transcripción automatizada (TrOCR).
- Medir la tasa de reducción de errores conceptuales en el material de repaso de los estudiantes al condicionar las respuestas de la aplicación web mediante un middleware RAG acoplado a un LLM en comparación con el uso de herramientas de entorno abierto.
- Cuantificar en cuánto disminuye el nivel de sobrecarga cognitiva y determinar la variación en las calificaciones promedio de los alumnos al implementar en la aplicación web un motor relacional de grafos de conocimiento con evaluaciones dinámicas automatizadas.

353
354
355
356
357
358
359

2.2 Hipótesis de la investigación

2.2.1 Hipótesis general

La implementación y evaluación de la aplicación web basada en un entorno de aprendizaje interconectado y automatizado permitira reducir de forma cuantificable la sobrecarga de apuntes y la fatiga mental, logrando una variación positiva en el rendimiento académico de los estudiantes universitarios de la UNAMBA.

360
361
362

2.2.2 Hipótesis específicas

- El uso de la aplicación web con un módulo de transcripción automatizada (TrOCR) reduce significativamente el tiempo dedicado a la

363 consolidación de apuntes manuscritos y eleva la tasa de preservación de
364 información técnica en comparación con los métodos de transcripción
365 tradicional.

366 • El condicionamiento de las respuestas de la aplicación web mediante un
367 middleware RAG acoplado a un LLM produce una tasa de reducción de
368 errores conceptuales y alucinaciones en el material de repaso superior
369 al estado basal de las herramientas de entorno abierto.

370 • La implementación de un motor relacional de grafos de conocimiento
371 con evaluaciones dinámicas automatizadas en la aplicación web dis-
372 minuye numéricamente el nivel de sobrecarga cognitiva percibida y
373 genera un incremento en las calificaciones promedio de los alumnos
374 frente a los esquemas de estudio aislados tradicionales.

Tabla 1— Operacionalización de las variables de investigación

Variable	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Escala / Rangos
Variable Independiente 1: Módulo de transcripción automatizada (TrOCR)	Componente tecnológico basado en arquitecturas Transformers con <i>fine-tuning</i> encargado de la conversión automatizada de apuntes físicos y notación científica hacia texto estructurado en la aplicación web.	Se evalúa registrando el tipo de flujo de trabajo implementado por el alumno y calculando el porcentaje de preservación exacta de caracteres técnicos tras el procesamiento visual de imágenes de cuadernos.	Transmisión y digitalización técnica de apuntes.	Uso de herramientas tecnológicas (Flujo manual tradicional vs. Aplicación web automatizada); tasa de conversión de caracteres técnicos (%); porcentaje de preservación de fórmulas matemáticas.	Flujo de trabajo: 0 = Manual tradicional 1 = Web automatizada Conversión: Alta $\geq 95\%$ Baja $< 80\%$ Preservación: Excelente $> 95\%$ Regular 80–95 %
Variable Independiente 2: Middleware RAG acoplado a LLM	Mecanismo de procesamiento de lenguaje natural acoplado a un LLM que limita y restringe el espacio de inferencia computacional a un corpus de documentos académicos validados por la plataforma web.	Se mide verificando el grado de restricción del entorno de consultas del sistema y calculando la reducción porcentual de datos falsos o alucinaciones en los materiales de repaso generados.	Control factual de contenido sintético.	Configuración del entorno de inferencia (Inferencia abierta genérica vs. Filtro RAG restrictivo); tasa de reducción de errores conceptuales (%); consistencia semántica del resumen.	Entorno de consultas: 0 = Abierto genérico 1 = RAG restrictivo Reducción de errores: Alta $\geq 90\%$ Media 80–89 % Consistencia: Alta $> 95\%$ Deficiente $< 80\%$
Variable Independiente 3: Motor relacional de grafos y evaluaciones dinámicas	Estructuración de apuntes estudiantiles en forma de red semántica mediante Grafos de Conocimiento y algoritmos de IA orientados al despliegue automático de cuestionarios formativos dinámicos.	Se determina identificando la topología de interconexión del repositorio del alumno y calculando la tasa porcentual de generación desatendida de cuestionarios adaptativos en la interfaz web.	Interconexión semántica y evaluación formativa.	Topología de estructuración de notas (Bloques aislados tradicionales vs. Red relacional interconectada); tasa de generación automatizada de quizzes (%); latencia de actualización del grafo (seg).	Estructuración: 0 = Bloques aislados 1 = Red relacional Quizzes automáticos: Adecuado $\geq 90\%$ Deficiente $< 10\%$ Sincronización: Óptima < 2 seg Aceptable 2–5 seg
Variable Dependiente (VD): Sobrecarga de apuntes, fatiga mental y rendimiento académico.	Nivel de disminución del tiempo operativo de organización de notas y de la fatiga mental autopercebida, complementado con la variación positiva en las notas y la efectividad del trabajo colaborativo.	Se mide cuantitativamente comparando los registros de tiempo (minutos), la variación numérica de puntajes en la escala estandarizada NASA-TLX, las calificaciones en exámenes parciales y la frecuencia de uso compartido de recursos.	Eficiencia temporal; Carga cognitiva percibida; Desempeño académico y cooperación.	Tiempo semanal de consolidación de apuntes (min); nivel de sobrecarga cognitiva (puntos en escala NASA-TLX); calificaciones promedio en exámenes parciales; frecuencia de intercambio colaborativo (ítems/semana).	Tiempo de consolidación: Eficiente < 20 min Ineficiente > 90 min NASA-TLX: Baja sobrecarga < 40 Alta sobrecarga > 70 Calificaciones: Sobresaliente 16–20 Regular 11–15 Desaprobado < 11 Intercambio colaborativo: Alto > 15 ítems Bajo < 5 ítems Significancia: $p < 0,05$

CAPÍTULO III

MARCO TEÓRICO REFERENCIAL

3.1 Antecedentes

3.1.1 Antecedentes internacionales

- a) Según [Ning et al. \(2025\)](#), en su investigación sobre la sumarización personalizada consciente de la intención en textos educativos utilizando Modelos de Lenguaje Grande (LLMs), se encontró que el modelado explícito de la intención del usuario mejora drásticamente la relevancia y exactitud de los resúmenes. Su sistema propuesto logró superar a más de 10 modelos base de referencia, obteniendo ganancias de 6 a 8 puntos en las métricas ROUGE y una mejora de más del 5 % en la consistencia factual medida por la métrica FactCC.
- b) Según [T. Chen et al. \(2023\)](#), en su investigación sobre la mejora de la sumarización abstractiva mediante la integración de Grafos de Conocimiento y transformadores de múltiples fuentes, se encontró que el uso de representaciones semánticas estructuradas como guía mitiga la incapacidad intrínseca de los LLMs para verificar la corrección de los hechos. Su modelo MultiBART-GAT demostró un rendimiento superior al generar resúmenes informativos y relevantes, logrando incrementar la puntuación ROUGE-1 a 39.1 y manteniendo un alto nivel de similitud semántica en la evaluación BERTScore.
- c) Según [Jiang et al. \(2025\)](#), en su investigación sobre el sistema de toma de apuntes colaborativo e inteligente NexaNota, se encontró que la construcción automática de redes de temas mediante grafos de conocimiento impacta positivamente en la eficiencia del aprendizaje. En su estudio, la extracción y representación del conocimiento en el sistema alcanzó una precisión del 97.7 % en la identificación de tópicos principales y una exactitud del 86.7 % al establecer las conexiones semánticas entre dichos tópicos.
- d) Según [Kreijkes et al. \(2026\)](#), en su investigación sobre los efectos del uso de Modelos de Lenguaje Grande (LLMs) y la toma de apuntes en la comprensión lectora y la memoria, se encontró que combinar la toma de apuntes tradicional con el uso de LLMs tiene efectos positivos

significativos en la retención de conocimientos en comparación con el uso exclusivo de la IA. Sus resultados demostraron que el esfuerzo cognitivo involucrado en la estructuración propia de apuntes, apoyado por la IA, mejora las métricas de retención literal y comprensión con un tamaño del efecto estadístico (d) de 0.44 y 0.38, respectivamente.

e) Según [Alvarez-Perez et al. \(2026\)](#), en su investigación desarrollada en México centrada en el *fine-tuning* de modelos *Transformers* para la conversión de textos científicos manuscritos al formato estructurado LaTeX, se encontró que arquitecturas visuales de extremo a extremo, como Nougat y TrOCR, superan ampliamente a los sistemas de OCR convencionales al procesar fórmulas matemáticas. Tras el entrenamiento con un corpus específico, el modelo optimizado demostró una alta capacidad para digitalizar notación espacial compleja, reduciendo la Tasa de Error de Caracteres (CER) hasta un 24.42 % en secuencias manuscritas desafiantes, lo que resulta ser un avance indispensable para la digitalización técnica en ingenierías y un aporte relevante al contexto latinoamericano.

f) Según [KardanMoghaddam et al. \(2025\)](#), en su investigación sobre una estructura combinada de transformadores TrOCR y LLMs para la clasificación y extracción de textos manuscritos, se encontró que inyectar las transcripciones de los modelos de visión directamente en un LLM mejora sustancialmente la precisión del procesamiento. Su modelo híbrido (TrOCR-Large acoplado con BART-Large) logró clasificar secuencias de texto con una precisión general (*accuracy*) de 65.29 % y altas puntuaciones F1, demostrando la viabilidad de utilizar *pipelines* de IA en cascada para digitalizar apuntes ruidosos.

g) Según [Solanki et al. \(2026\)](#), en su investigación sobre el ecosistema inteligente "NoteGenius", se encontró que la integración de IA generativa para la creación de apuntes y el aprendizaje colaborativo mitiga el problema de la fragmentación de la información académica. El desarrollo de esta plataforma (basada en tecnologías modernas y almacenamiento en la nube) automatiza la generación de resúmenes, conversión de diapositivas y creación de cuestionarios (quizzes), lo cual impacta directamente de forma positiva en la retención de conocimientos y auto-evaluación del estudiante.

h) Según [Upadhyay et al. \(2026\)](#), en su estudio sobre una aplicación web integral para el análisis automático de contenido y generación de apuntes a partir de videos de YouTube, se evidenció que la or-

questación de APIs de Modelos de Lenguaje Grande (LLMs) con arquitecturas escalables (como React, Express.js y PostgreSQL) optimiza sustancialmente el tiempo de estudio. El sistema logra extraer transcripciones y estructurar apuntes de manera rápida y segura, demostrando la eficacia de los *pipelines* de IA en el procesamiento de contenido multimedia educativo.

- i) Según [Shirkande et al. \(2025\)](#), en su evaluación del sistema "Noteverse", se identificó que las herramientas tradicionales de gestión de conocimiento adolecen de falta de personalización y de mecanismos de organización inteligente. Su investigación valida que implementar bases de datos en la nube y *frameworks* interactivos como Next.js para lograr una sincronización y coedición en tiempo real es vital para la construcción de ecosistemas colaborativos robustos en la educación superior.

3.1.2 Antecedentes nacionales

- a) Según [Tarazona Cruz \(2024\)](#), en su investigación sobre el reconocimiento de texto en manuscritos históricos peruanos utilizando modelos mixtos, se encontró que el uso de modelos de reconocimiento de imágenes preentrenados mediante la plataforma de código abierto OCR4all es viable para digitalizar documentos manuscritos en español. Tras entrenar tres modelos con el conjunto de datos SPA-Sentences (aproximadamente 13,000 oraciones), su sistema alcanzó una Tasa de Error de Caracteres (CER) promedio de 4.11 % en el conjunto de validación, y al aplicarlo sobre manuscritos históricos peruanos de la Biblioteca Nacional del Perú obtuvo una tasa de error promedio de 9.39 %, demostrando la utilidad de estas arquitecturas para el contexto local pese a la variabilidad caligráfica y el deterioro del papel.

3.2 Marco teórico

3.2.1 Inteligencia Artificial Generativa y Arquitectura RAG

La Inteligencia Artificial Generativa, particularmente impulsada por Modelos de Lenguaje Grande (LLMs) como GPT-3.5 o LLaMA 3, ha revolucionado las tareas de procesamiento de lenguaje natural al habilitar la sumarización abstractiva de textos con alta coherencia ([Saxena et al., 2025](#)). No obstante, estos modelos probabilísticos carecen de mecanismos intrínsecos para verificar la veracidad de la información que generan, lo que con frecuencia deriva en "alucinaciones": información plausible pero fácticamente incorrecta ([T. Chen et al., 2023](#)).

Para mitigar este problema, surge la arquitectura de Generación Aumentada por Recuperación (RAG). En lugar de depender exclusivamente de los pesos preentrenados del modelo, RAG restringe el espacio de inferencia recuperando primero los fragmentos de texto más relevantes desde un corpus local y proporcionándolos como contexto estricto al LLM [Kannammal et al. \(2024\)](#). El *pipeline* RAG clásico comprende tres etapas: indexación del corpus mediante *embeddings* vectoriales, recuperación semántica por similitud de coseno, y generación condicionada al contexto recuperado ([Gao et al., 2024](#)). Al acoplar RAG con validadores factuales, la tasa de alucinaciones se minimiza de forma crítica [Ning et al. \(2025\)](#), lo que resulta especialmente relevante para sistemas educativos donde la exactitud del contenido generado es indispensable. La evolución más reciente ha dado lugar a variantes como GraphRAG, que integra grafos de conocimiento en el proceso de recuperación para capturar relaciones estructuradas entre conceptos, superando las limitaciones de la recuperación puramente vectorial ([Klesel et al., 2025](#)).

3.2.2 Arquitectura Transformer y Mecanismo de Atención

El fundamento técnico de los LLMs y de los modelos de visión empleados en el presente proyecto reside en la arquitectura Transformer, introducida por [Vaswani et al. \(2017\)](#) en el trabajo seminal “Attention is All You Need”. A diferencia de las arquitecturas recurrentes (RNN/LSTM) que procesan secuencias de forma estrictamente secuencial, el Transformer opera mediante un mecanismo de *auto-atención* (*Self-Attention*) que calcula, en paralelo, la relevancia relativa de cada posición de la secuencia respecto a todas las demás. Formalmente, la atención escalada de producto punto se define como:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3.1)$$

donde Q , K y V representan las matrices de *queries*, *keys* y *values* proyectadas, y d_k es la dimensión de las *keys*, cuya raíz cuadrada actúa como factor de escala para estabilizar los gradientes ([Vaswani et al., 2017](#)). La extensión multi-cabeza (*Multi-Head Attention*) ejecuta múltiples operaciones de atención en paralelo sobre distintos subespacios de representación, permitiendo al modelo capturar simultáneamente dependencias sintácticas, semánticas y de largo alcance en el texto ([Vaswani et al., 2017](#)).

Esta arquitectura fue posteriormente adaptada al dominio de la visión por computadora mediante el Vision Transformer (ViT), que divide una imagen en parches (*patches*) de tamaño fijo, los proyecta linealmente y los procesa como una secuencia de tokens, habilitando la captura de

dependencias globales entre regiones de la imagen (M. Li et al., 2023). Es precisamente esta sinergia entre un codificador de visión basado en ViT y un decodificador de lenguaje autorregresivo la que subyace al modelo TrOCR, pilar tecnológico del módulo de transcripción de SynapTome.

3.2.3 Reconocimiento de Texto Manuscrito (HTR), TrOCR y Fórmulas Matemáticas

El Reconocimiento Óptico de Caracteres (OCR) tradicional se fundamenta en múltiples módulos independientes: preprocesamiento, segmentación, extracción de características mediante CNN y postprocesamiento, lo que genera una alta propagación de errores y una notable ineficiencia frente a caligrafía compleja (B. Zhang, 2026). Los sistemas CNN-RNN presentan además limitaciones al procesar texto manuscrito con alta variabilidad caligráfica, pues su campo receptivo local impide capturar dependencias de largo alcance entre caracteres (M. Li et al., 2023).

En contraparte, TrOCR unifica estas tareas en una arquitectura única de extremo a extremo. Emplea un codificador de visión preentrenado (BEiT o DeiT) para extraer características visuales de la imagen en parches, y un decodificador de lenguaje (RoBERTa) que genera el texto de manera autorregresiva M. Li et al. (2023). El modelo TrOCR_{LARGE} alcanza una Tasa de Error de Caracteres (CER) de apenas 2,89 % en el *benchmark* IAM, superando a todos los modelos CNN-RNN previos (Sharma et al., 2025).

Una dimensión especialmente crítica para SynapTome es el Reconocimiento de Expresiones Matemáticas Manuscritas (HMER, por sus siglas en inglés). A diferencia del texto corriente, las fórmulas matemáticas presentan una estructura bidimensional compleja: superíndices, subíndices, fracciones, integrales y símbolos especiales cuya disposición espacial es parte integrante de su significado. Los modelos encoder-decoder basados en Transformers, como UniMERNet, abordan esta complejidad mediante la generación directa de código $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ a partir de la imagen de la fórmula, logrando reconocer con alta precisión tanto expresiones impresas como manuscritas en escenarios reales (Alvarez-Perez et al., 2026). El conjunto de datos MathWriting, que provee anotaciones $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ para fórmulas manuscritas en línea (*online*) y fuera de línea (*offline*), constituye actualmente el referente de evaluación para estos modelos (Alvarez-Perez et al., 2026). En el contexto peruano, arquitecturas preentrenadas de esta familia han demostrado ser viables incluso para manuscritos con alta variabilidad caligráfica (Tarazona Cruz, 2024).

3.2.4 *Vector Embeddings* y Bases de Datos Vectoriales

Los *embeddings* vectoriales son representaciones numéricas de alta dimensión que codifican el significado semántico de fragmentos de texto, imágenes u otros tipos de datos. La propiedad fundamental de estos vectores es que la proximidad geométrica en el espacio vectorial refleja similitud semántica: fragmentos con significado afín producen vectores cercanos, independientemente de si comparten vocabulario exacto (Gao et al., 2024). Este principio constituye la base técnica de la recuperación semántica en los sistemas RAG: al codificar tanto los fragmentos del corpus como la consulta del usuario en el mismo espacio vectorial, es posible recuperar los k fragmentos más relevantes mediante una búsqueda de vecinos más cercanos (*k-NN search*).

Para la persistencia y consulta eficiente de estos vectores en el contexto de SynapTome, la extensión *pgvector* para PostgreSQL representa la solución arquitectónica óptima. Esta extensión permite almacenar vectores de alta dimensión directamente en tablas relacionales y ejecutar búsquedas de similitud mediante los operadores de distancia coseno, euclídea o producto punto, combinando las capacidades de búsqueda semántica con las garantías ACID y las operaciones relacionales estándar de SQL (Afian et al., 2025). La indexación mediante estructuras HNSW (*Hierarchical Navigable Small World*) permite escalar estas búsquedas a millones de vectores con latencias de consulta inferiores a 10 ms, manteniendo una alta tasa de recuperación (*recall*) (Upadhyay et al., 2026). Esta arquitectura unificada — datos relacionales y vectores en una sola base de datos — simplifica significativamente la infraestructura del sistema y elimina la necesidad de sincronizar datos entre una base de datos relacional y un almacén vectorial independiente.

3.2.5 Grafos de Conocimiento

Los Grafos de Conocimiento son estructuras matemáticas que representan la información como una red semántica dirigida, conformada por nodos (entidades o tópicos) y aristas (relaciones). Esta topología permite capturar el contexto global y las relaciones transversales dentro de un corpus documental, sirviendo como esqueleto para la extracción de características y el aprendizaje representacional T. Chen et al. (2023). Una revisión sistemática reciente identifica que su principal aporte en educación reside en la capacidad de modelar la progresión del conocimiento del estudiante a lo largo del tiempo, conectando conceptos de distintas asignaturas y niveles cognitivos (Abu-Salih et al., 2024). En este sentido, permiten representar el estado de aprendizaje de cada alumno como una red dinámica de nodos

de competencia, facilitando la personalización de rutas de estudio y la identificación de brechas conceptuales (Soumya et al., 2025).

En el contexto de sistemas de gestión del aprendizaje, estos mapas de tópicos transforman el contenido aislado en recursos enlazados, impulsando la “Inteligencia Colectiva” (Obionwu et al., 2022). La integración de grafos de conocimiento con arquitecturas RAG —denominada Graph-RAG— representa el estado del arte en recuperación semántica educativa: al estructurar el corpus de apuntes como un grafo, el sistema puede recorrer relaciones semánticas para recuperar fragmentos contextualmente relevantes que la búsqueda vectorial clásica no identificaría (J. Li et al., 2025). Para su implementación en el *backend*, PostgreSQL con pgvector garantiza la integridad, el indexado veloz y el almacenamiento seguro de los metadatos y vectores de las entidades semánticas (Afian et al., 2025; Upadhyay et al., 2026).

3.2.6 Generación Automática de Evaluaciones Adaptativas

La generación automática de cuestionarios a partir del contenido de apuntes constituye una de las aplicaciones más directas de los LLMs en educación. Los sistemas basados en IA son capaces de producir ítems alineados con la Taxonomía de Bloom —desde preguntas de recordación hasta ítems de evaluación y creación— a partir de fragmentos de texto, reduciendo significativamente la carga docente (Lodovico Molina et al., 2025). Herramientas como QuizWiz demuestran que los LLMs integrados en plataformas educativas pueden generar cuestionarios personalizados y adaptativos en tiempo real, ajustando la dificultad al nivel de dominio actual del estudiante (Farah et al., 2024).

Los grafos de conocimiento desempeñan un rol instrumental en esta dinámica: al estructurar los apuntes como una red de conceptos relacionados, el sistema selecciona de forma dirigida los nodos temáticos sobre los cuales generar preguntas, garantizando cobertura curricular equilibrada y evitando redundancia (L. Zhang et al., 2026). Esta sinergia entre grafos de conocimiento y generación automática de evaluaciones constituye el núcleo de la variable independiente 3 del presente proyecto.

3.2.7 Aprendizaje Activo y Recuperación Espaciada (*Spaced Repetition*)

La Teoría de la Recuperación Espaciada (*Spaced Repetition*) se fundamenta en la curva del olvido de Ebbinghaus, que describe cómo la tasa de retención decae exponencialmente con el tiempo en ausencia de revisiones. La estrategia consiste en programar las revisiones de un concepto justo antes del momento en que será olvidado, maximizando la consolidación

en la memoria a largo plazo mediante el denominado *efecto de espaciado* (Huang, 2025). La práctica de recuperación activa (*Active Recall*) complementa esta estrategia: en lugar de releer pasivamente el material, el estudiante intenta recordar activamente la información, lo que fortalece las trazas mnémicas de forma significativamente más efectiva que la revisión pasiva; estudios recientes demuestran que los estudiantes que practican recuperación activa superan en más de un 50 % en pruebas diferidas a quienes solo releen el material (Huang, 2025).

Los sistemas de repetición espaciada modernos han evolucionado desde modelos de intervalo fijo —como el sistema Leitner— hacia algoritmos adaptativos basados en datos, como FSRS5 (*Free Spaced Repetition Scheduler*), que estima dinámicamente el intervalo óptimo de revisión para cada ítem según el historial de respuestas del estudiante (Torres et al., 2025). La integración de LLMs en estos sistemas permite generar automáticamente las tarjetas de estudio (*flashcards*) a partir del contenido de los apuntes digitalizados, cerrando el ciclo entre transcripción, estructuración y refuerzo del aprendizaje (Torres et al., 2025). En el contexto de SynapTome, este módulo se articula directamente con el motor de grafos de conocimiento: los nodos con menor frecuencia de revisión o menor puntuación de dominio activan automáticamente la generación de nuevas instancias de práctica de recuperación.

3.2.8 Aprendizaje Colaborativo Mediado por Tecnología

El aprendizaje colaborativo, entendido como el proceso mediante el cual los estudiantes construyen conocimiento de forma conjunta a través del intercambio de recursos, ha sido ampliamente validado como estrategia que mejora la retención y el desempeño académico (Kasirye, 2023). Una revisión sistemática de 148 artículos publicados entre 2021 y 2024 concluye que las herramientas de IA mejoran la personalización, la comunicación entre pares y el andamiaje del rendimiento, al tiempo que promueven entornos colaborativos mediante soporte de aprendizaje cooperativo (Msambwa et al., 2025). Sin embargo, la evidencia también advierte sobre una tensión emergente: el exceso de asistencia de IA en tareas de toma de notas puede reducir el compromiso cognitivo activo del estudiante (Tankelevitch et al., 2025), lo que sugiere que SynapTome debe calibrar el nivel de automatización para preservar el procesamiento profundo de la información.

3.2.9 Carga Cognitiva y Medición con NASA-TLX

La Teoría de la Carga Cognitiva postula que la memoria de trabajo humana posee una capacidad limitada para procesar información simultáneamen-

te, y que el diseño de entornos de aprendizaje debe minimizar la carga extrínseca para maximizar los recursos cognitivos disponibles (Hart et al., 1988). Para la cuantificación objetiva de esta carga, el instrumento NASA Task Load Index (NASA-TLX) constituye el estándar de referencia más ampliamente adoptado. Evalúa seis dimensiones: Demanda Mental, Demanda Física, Demanda Temporal, Rendimiento, Esfuerzo y Frustración, obteniendo un índice global ponderado (Hart et al., 1988). Su validez ha sido reconfirmada recientemente en contextos de interacción humano-computadora (Babaei et al., 2025). En estudios con estudiantes universitarios, la Demanda Temporal y la Demanda Mental emergen como las dimensiones de mayor puntuación, con correlaciones significativas entre ambas ($\rho = 0,58$, $p < 0,001$), subrayando la relevancia de diseñar sistemas que reduzcan simultáneamente la presión temporal y el esfuerzo mental (Cahyadi et al., 2026).

3.2.10 Privacidad y Seguridad de Datos Estudiantiles en Plataformas IA

El despliegue de plataformas educativas potenciadas por IA implica la recopilación y procesamiento de datos estudiantiles altamente sensibles: registros académicos, patrones de comportamiento, historial de consultas y contenido de apuntes personales. La gestión ética y segura de estos datos es un imperativo técnico y legal que condiciona el diseño arquitectónico de SynapTome (Lněnička et al., 2024). En el ámbito normativo internacional, dos marcos regulatorios delimitan las obligaciones de las plataformas educativas: la Ley de Privacidad y Derechos Educativos de la Familia (FERPA, por sus siglas en inglés), vigente en contextos anglosajones, y el Reglamento General de Protección de Datos (GDPR) de la Unión Europea, cuyo alcance extraterritorial puede afectar a cualquier plataforma que procese datos de ciudadanos europeos (Lněnička et al., 2024). Ambos marcos exigen el principio de *minimización de datos* —recopilar únicamente los datos estrictamente necesarios—, el consentimiento informado, y la implementación de salvaguardas técnicas como cifrado en reposo y en tránsito, control de acceso basado en roles (RBAC) y registros de auditoría. Adicionalmente, la Ley de Inteligencia Artificial de la Unión Europea (EU AI Act) clasifica los sistemas de IA utilizados en educación como sistemas de “alto riesgo”, lo que impone obligaciones adicionales de transparencia, explicabilidad y evaluación de impacto sobre la privacidad (DPIA) antes de su despliegue (Lněnička et al., 2024). En el diseño de SynapTome, estas consideraciones se traducen en la adopción de Arquitectura Limpia con separación estricta entre la capa de datos y los servicios de IA, el cifrado de los *embeddings* vectoriales almacenados en PostgreSQL, y

la implementación de políticas de retención de datos que permitan la eliminación completa del historial de un estudiante a solicitud expresa.

3.2.11 Arquitectura Limpia (*Clean Architecture*)

La Arquitectura Limpia es un patrón de diseño de software que promueve la separación estricta de responsabilidades mediante un sistema de capas concéntricas, aislando la lógica de negocio y las reglas del dominio de los *frameworks*, interfaces de usuario o bases de datos [Martin \(2017\)](#). Su principio central, la Regla de Dependencia, establece que los módulos de alto nivel no deben depender de los de bajo nivel, sino que ambos deben depender de abstracciones ([Martin, 2017](#)).

En el desarrollo de plataformas educativas integrales, mantener un *backend* escalable y modular bajo este enfoque resulta indispensable para soportar *pipelines* intensivos de IA [Upadhyay et al. \(2026\)](#) y [Solanki et al. \(2026\)](#). Su aplicación en ecosistemas basados en C# y ASP.NET Core permite construir APIs RESTful robustas donde los controladores son totalmente independientes de los servicios de infraestructura como PostgreSQL o los motores de LLM, asegurando que la integración de nuevas tecnologías de IA no afecte el núcleo lógico del sistema ([Afian et al., 2025](#)).

3.3 Marco conceptual

- a) **LLM (Large Language Model)**. Modelo de inteligencia artificial basado en redes neuronales profundas, típicamente sobre la arquitectura Transformer, entrenado con cantidades masivas de datos para comprender, procesar y generar lenguaje natural de forma coherente ([Vaswani et al., 2017](#); [KardanMoghaddam et al., 2025](#)).
- b) **RAG (Retrieval-Augmented Generation)**. Arquitectura que combina la recuperación de fragmentos de información relevantes desde una base de conocimiento externa con la generación de texto de un LLM, utilizada para reducir las alucinaciones y anclar las respuestas a un contexto verificable ([Kannammal et al., 2024](#)).
- c) **TrOCR (Transformer-based Optical Character Recognition)**. Arquitectura de extremo a extremo para el reconocimiento de texto, compuesta por un codificador de visión (por ejemplo, DeiT o BEiT) y un decodificador de lenguaje (por ejemplo, RoBERTa), capaz de transcribir imágenes de texto manuscrito o impreso de manera autorregresiva ([B. Zhang, 2026](#)).
- d) **Grafo de Conocimiento (Knowledge Graph)**. Estructura de datos que representa información como una red semántica dirigida compuesta por nodos (entidades o tópicos) y aristas (relaciones), utilizada para capturar el contex-

to global y las conexiones entre los conceptos de un corpus (T. Chen et al., 2023).

- e) **Topic Maps (Mapas de Tópicos).** Estándar de representación del conocimiento que define un modelo abstracto para estructurar semánticamente redes de información y enlaces, facilitando el descubrimiento y la conexión de conceptos (Obionwu et al., 2022).
- f) **CER y WER (Character/Word Error Rate).** Métricas estándar para evaluar sistemas de reconocimiento de texto, que calculan el porcentaje de caracteres o palabras incorrectamente reconocidos respecto al total del texto de referencia; valores más bajos indican mayor precisión del modelo (Al-Hitawi et al., 2026).
- g) **ROUGE y BERTScore.** Métricas utilizadas para evaluar la calidad de resúmenes generados automáticamente: ROUGE mide la superposición de n-gramas entre el resumen generado y uno de referencia, mientras que BERTScore evalúa la similitud semántica mediante representaciones vectoriales contextuales (T. Chen et al., 2023).
- h) **Clean Architecture (Arquitectura Limpia).** Patrón de diseño de software que organiza el sistema en capas concéntricas, aislando la lógica de negocio de los frameworks, la interfaz de usuario y la base de datos, de modo que las dependencias siempre apunten hacia el núcleo del dominio (Martin, 2017).
- i) **Endpoint.** En el marco del estilo arquitectónico REST, URL específica mediante la cual un recurso es identificado y accedido por un cliente a través de los métodos estándar del protocolo HTTP (Fielding, 2000; Afian et al., 2025).
- j) **JWT (JSON Web Token).** Estándar abierto (RFC 7519) que define un formato compacto y seguro basado en JSON para representar y transmitir información verificable (*claims*) entre dos partes, comúnmente utilizado para la autenticación en APIs (Jones et al., 2015).
- k) **SignalR.** Biblioteca de software del entorno ASP.NET Core que facilita la comunicación web bidireccional en tiempo real, vital para habilitar la edición concurrente y la colaboración síncrona entre usuarios (Shirkande et al., 2025).
- l) **PostgreSQL.** Sistema de gestión de bases de datos relacionales de código abierto que, mediante esquemas optimizados y extensiones específicas, permite almacenar de forma eficiente metadatos, vectores semánticos y estructuras de grafos de conocimiento (Afian et al., 2025; Upadhyay et al., 2026).

CAPÍTULO IV METODOLOGÍA

4.1 Tipo y nivel de investigación

La presente investigación se clasifica por su propósito como Tecnológica Aplicada, dado que busca resolver un problema práctico y concreto: la sobrecarga cognitiva y la desorganización de apuntes en el entorno universitario, mediante el desarrollo de una solución de software (SynapTome). Por su alcance y profundidad, el estudio corresponde a un nivel explicativo-experimental (específicamente, un diseño cuasi-experimental). Este nivel permite no solo describir el ecosistema desarrollado, sino también determinar las relaciones de causa y efecto que la Variable Independiente (el ecosistema basado en RAG, TrOCR y Grafos de Conocimiento) ejerce sobre la Variable Dependiente (la retención de conocimientos y el nivel de colaboración). Como señalan [Kreijkes et al. \(2026\)](#), el uso de diseños experimentales en entornos educativos es fundamental para cuantificar de manera objetiva los efectos de las herramientas basadas en LLMs sobre la comprensión lectora y la memoria de los estudiantes.

4.2 Diseño de la investigación

Para abordar la complejidad del ecosistema SynapTome, el diseño metodológico se divide en dos vertientes complementarias: un diseño de ingeniería de software y un diseño de validación académica.

- Diseño de Ingeniería de Software: Se empleará la metodología ágil Scrum. Según [Afan et al. \(2025\)](#), las metodologías ágiles soportan el desarrollo iterativo, la retroalimentación continua y la adaptabilidad, características esenciales para el desarrollo exitoso de plataformas de tutoría impulsadas por inteligencia artificial. El desarrollo se estructurará en sprints que abarcarán la planificación, el diseño, la implementación del backend y los pipelines de IA, y las pruebas continuas de las funciones.
- Diseño de Evaluación (Validación): Se utilizará un diseño de tipo pre-test / post-test con un grupo cuasi-experimental. Se medirá el desempeño académico (retención de conocimientos) de los estudiantes antes de la adopción del ecosistema SynapTome y, tras un periodo de uso continuo de la herramienta, se aplicará un post-test para evaluar el impacto real generado por la plataforma interactiva y colaborativa.

4.3 Pipeline del sistema

Para operativizar el primer objetivo específico y transformar el flujo analógico de los estudiantes en un entorno digital de alta fidelidad, se diseñó un pipeline de procesamiento asíncrono desacoplado. La justificación de esta estructura lógica radica en la necesidad de mitigar la fatiga y el error humano derivado de la transcripción manual de fórmulas matemáticas bidimensionales complejas (como integrales múltiples, matrices o sistemas diferenciales).

El pipeline actúa directamente sobre la variable dependiente (eficiencia de captura), procesando los apuntes manuscritos mediante tres etapas críticas: normalización de la imagen, inferencia autorregresiva basada en el modelo Transformer TrOCR con *fine-tuning*, y un post-procesamiento de sanitización semántica que traduce los mapas de características visuales en sintaxis $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ válida y estandarizada. Este flujo asegura que el material resultante disponible para el autoestudio del alumno esté completamente libre de distorsiones algebraicas que alteren el significado científico original del cuaderno de clase.




Figura 1— Descripción clara del contenido de la imagen enfocada en el impacto o flujo del estudiante.

4.4 Descripción ética de la investigación

El desarrollo y despliegue del ecosistema SynapTome se adherirá a estrictos estándares de ética y privacidad de la información (Kreijkes et al., 2026; Dano et al., 2026). Antes de iniciar las pruebas, se obtendrá un consentimiento informado por escrito de los estudiantes de la UNAMBA, garantizando que su participación sea voluntaria y que tengan el derecho de retirarse del estudio en cualquier momento.

A nivel técnico, el tratamiento de los datos personales y el contenido de los apuntes manuscritos subidos por los usuarios se gestionará con políticas de seguridad de grado industrial. Para asegurar la protección de los datos en tránsito y en

reposito, la arquitectura implementará autenticación segura mediante tokens JWT (JSON Web Tokens) en los endpoints de la API, mientras que toda la información persistente, incluidas las métricas de evaluación y los grafos relacionales, será resguardada en una base de datos PostgreSQL aplicando el encriptado adecuado, evitando el acceso no autorizado y manteniendo la confidencialidad de la información académica y personal (Upadhyay et al., 2026).

4.5 Población y muestra

- Población: La población objetivo está constituida por los estudiantes matriculados en la Escuela Académico Profesional de Ingeniería de Sistemas de la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), durante el año académico en curso.
- Se seleccionará una muestra mediante un muestreo no probabilístico por conveniencia, basado en la disponibilidad, el nivel de interacción digital de los estudiantes y su inscripción en cursos de alta densidad matemática o teórica. Este tipo de muestreo facilita el reclutamiento para pruebas tecnológicas y de usabilidad en entornos controlados de laboratorio o aulas informáticas (Kreijkes et al., 2026).

4.6 Procedimiento

El procedimiento general de la investigación comprenderá cinco fases sistemáticas, desde el levantamiento de requisitos hasta la evaluación del sistema "SynapTome.^{en} un entorno real con estudiantes de Ingeniería de Sistemas de la UNAMBA. La Tabla 2 resume las actividades, las herramientas tecnológicas empleadas y los entregables de cada fase.

Tabla 2— Fases del procedimiento de investigación

Fase	Actividades	Herramientas / Tecno- logías	Entregable
1. Levantamiento de requisitos y diseño	Identificación de las necesidades de digitalización y colaboración de los estudiantes; diseño de la arquitectura del ecosistema (modelo relacional y lógica de grafos de conocimiento) (Afian et al., 2025)	Diagramas UML, modelo entidad-relación, PostgreSQL	Documento de requisitos y diagrama de arquitectura
2. Desarrollo (Backend y Frontend)	Construcción del núcleo del sistema bajo Clean Architecture: orquestación de la lógica de negocio e integración con APIs de IA en el backend, y desarrollo de una interfaz reactiva y colaborativa en el frontend (Martin, 2017; Afian et al., 2025)	C# / ASP.NET Core, Next.js, React, PostgreSQL	Prototipo funcional (módulos CRUD y autenticación JWT)
3. Integración de RAG y TrOCR	Implementación del middleware RAG para acoplar la recuperación de vectores semánticos con los LLMs; fine-tuning de la arquitectura TrOCR con corpus matemático y manuscrito para adaptar el modelo al dominio (Kannammal et al., 2024; B. Zhang, 2026; Alvarez-Perez et al., 2026)	Bases de datos vectoriales, TrOCR, LLM (API), Python para fine-tuning	Pipeline de IA integrado (módulo OCR + módulo RAG)
4. Pruebas alfa y beta	Pruebas de caja negra, pruebas unitarias automatizadas y pruebas preliminares con un grupo reducido de usuarios para depurar errores de concurrencia y validar la sincronización en tiempo real (Shirkande et al., 2025)	SignalR (WebSockets), frameworks de testing (xUnit / Jest)	Reporte de pruebas y correcciones
5. Evaluación en entorno real	Despliegue de SynapTome para la muestra de estudiantes de la UNAMBA; ejecución de pre-test y post-test; recolección de datos de rendimiento y métricas del sistema	Cuestionarios digitales, panel de métricas del sistema	Base de datos de resultados (pre/post-test)

4.7 Técnicas e instrumentos

Para medir de manera rigurosa la eficacia algorítmica del sistema y el nivel de aceptación por parte de los usuarios, se emplearán técnicas mixtas (cuantitativas y cualitativas), combinando la evaluación experimental del rendimiento de los modelos de IA con la percepción subjetiva de los estudiantes.

4.7.1 Técnicas

- **Análisis documental:** Revisión de antecedentes, literatura técnica y datasets de referencia (por ejemplo, SPA-Sentences) para establecer las líneas base de comparación de los modelos de OCR/HTR y sumariación (Tarazona Cruz, 2024).
- **Experimentación:** Ejecución controlada del pipeline TrOCR y del módulo RAG sobre un conjunto de apuntes manuscritos y resúmenes generados, registrando los resultados de manera cuantitativa (Al-Hitawi et al., 2026).
- **Encuesta:** Aplicación de cuestionarios estructurados a los estudiantes participantes para recoger su percepción sobre la usabilidad, utilidad y satisfacción con SynapTome (Afian et al., 2025; Dano et al., 2026).

4.7.2 Instrumentos

La Tabla 3 detalla los instrumentos empleados para cada técnica, indicando la variable que mide y la escala o métrica utilizada.

Tabla 3— Instrumentos de recolección de datos

Instrumento	Variable / Dimensión que mide	Escala / Métrica	Fuente
Ficha de registro de transcripción OCR	Eficiencia de captura técnica (preservación de información manuscrita)	Tasa de Error de Caracteres (CER %) y $\text{\LaTeX}$ válido	(Al-Hitawi et al., 2026)
Ficha de evaluación de fidelidad conceptual	Calidad factual del repaso (reducción de errores conceptuales en notas)	Índice de alucinación (%) y coherencia de resúmenes	(Saxena et al., 2025; Ning et al., 2025)
Cuestionario NASA-TLX (Carga Mental)	Sobrecarga cognitiva y fatiga mental del estudiante en su autoestudio	Escala ordinal de carga de trabajo (0–100 pts)	(Hart1988)
Cuestionario de usabilidad adaptado (SUS)	Eficiencia operativa en la organización colaborativa de apuntes en red	Puntuación normalizada SUS (0–100 pts)	(Afian et al., 2025)
Evaluación Pre-test / Post-test de retención	Rendimiento académico e incremento de la fijación conceptual a largo plazo	Calificación cuantitativa (Escala vigesimal 0–20)	(Kreijkes et al., 2026)

4.8 Estadístico de la investigación

Para evaluar el desempeño del pipeline de visión por computadora TrOCR en la digitalización de apuntes manuscritos, se calcularán cuantitativamente la Tasa de Error de Caracteres (CER) y la Tasa de Error de Palabras (WER), garantizando así que la transcripción a $\text{\LaTeX}$ sea altamente precisa (Al-Hitawi et al., 2026). Ambas métricas se basan en la distancia de edición de Levenshtein y se calculan como:

$$\text{CER} = \frac{S + D + I}{N} \quad (4.2)$$

$$\text{WER} = \frac{S_w + D_w + I_w}{N_w} \quad (4.3)$$

donde S , D e I representan el número de sustituciones, eliminaciones e inserciones de caracteres (o S_w , D_w , I_w a nivel de palabras) necesarias para transformar el texto reconocido en el texto de referencia, y N (N_w) es el número total de caracteres (palabras) en el texto de referencia. Valores cercanos a 0 indican una transcripción casi perfecta.

Para evaluar la calidad, coherencia y fidelidad semántica de los resúmenes abstractivos y la mitigación de alucinaciones del motor RAG, se emplearán métricas estándar de procesamiento de lenguaje natural como ROUGE-N y BLEU, complementadas opcionalmente con BERTScore (Saxena et al., 2025; Ning et al., 2025). La métrica ROUGE-N se define como:

$$\text{ROUGE-N} = \frac{\sum_{S \in \{\text{Referencias}\}} \sum_{\text{gram}_n \in S} \text{Count}_{\text{match}}(\text{gram}_n)}{\sum_{S \in \{\text{Referencias}\}} \sum_{\text{gram}_n \in S} \text{Count}(\text{gram}_n)} \quad (4.4)$$

es decir, la proporción de n -gramas del resumen de referencia que también aparecen en el resumen generado por el sistema.

915 Para la evaluación de la aceptación tecnológica (Tabla 3), los puntajes obtenidos
916 en los cuestionarios SUS se calcularán siguiendo la fórmula estándar:

$$SUS = 2,5 \times \sum_{i=1}^{10} x'_i \quad (4.5)$$

917 donde x'_i corresponde a la puntuación ajustada de cada uno de los 10 ítems
918 (restando 1 a los ítems impares y restando el valor original a 5 en los ítems pares),
919 de modo que el puntaje final se normaliza en una escala de 0 a 100.

920 Finalmente, dado que el diseño de evaluación implica medir el rendimiento
921 académico de un mismo grupo de estudiantes en dos momentos distintos (pre-test
922 y post-test), la comprobación de la hipótesis principal se realizará utilizando la
923 prueba paramétrica T de Student para muestras relacionadas (pares), asumiendo
924 la normalidad en la distribución de los datos de desempeño:

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} \quad (4.6)$$

925 donde $\bar{d}$ es la media de las diferencias entre las puntuaciones del post-test y el
926 pre-test de cada estudiante, s_d es la desviación estándar de esas diferencias, y n
927 es el tamaño de la muestra. En el caso de que la distribución de las puntuaciones
928 de retención (por ejemplo, resultados de *free recall* o quizzes integrados) no se
929 ajuste a la normalidad, se empleará la prueba no paramétrica de Wilcoxon para
930 muestras relacionadas como alternativa equivalente (Kreijkes et al., 2026).

931 Adicionalmente, para cuantificar la magnitud práctica del efecto observado (más
932 allá de su significancia estadística), se calculará el tamaño del efecto mediante la
933 d de Cohen para muestras relacionadas:

$$d = \frac{\bar{d}}{s_d} \quad (4.7)$$

934 interpretando los valores según las convenciones habituales ($d \approx 0,2$ efecto pe-
935 queño, $d \approx 0,5$ efecto moderado, $d \geq 0,8$ efecto grande), de manera consistente
936 con los tamaños de efecto reportados en estudios similares (Kreijkes et al., 2026).
937 En todos los casos se aplicará un nivel de significancia de $\alpha = 0,05$ ($p < 0,05$)
938 para confirmar estadísticamente si las mejoras obtenidas en la retención del cono-
939 cimiento mediante la plataforma SynapTome son significativas frente al modelo
940 tradicional de toma de apuntes.

941
942
943
944

945
946

CAPÍTULO V

ADMINISTRACIÓN DEL PROYECTO

947
948
949
950
951
952

5.1 Cronograma de actividades

El proyecto de investigación se desarrollará durante el año académico 2026, organizado en seis fases secuenciales, con una duración total de seis meses. Las Tablas 4 y 5 presentan la distribución temporal de las actividades por fase, desde la planificación y revisión bibliográfica hasta la evaluación final del sistema y el análisis estadístico de los resultados.

Tabla 4— Cronograma de actividades – Fases I a III (Julio – Diciembre 2026)

Fases y Actividades (2026)	Jul				Ago				Sep				Oct				Nov				Dic			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Fase I: Planificación y revisión bibliográfica																								
1. Revisión sistemática de literatura y antecedentes	X	X																						
2. Elaboración y aprobación del proyecto de tesis	X	X																						
3. Coordinación institucional con la UNAMBA			X	X																				
4. Diseño preliminar de la arquitectura (BD relacional y grafos)			X	X																				
Fase II: Diseño y desarrollo del backend																								
5. Levantamiento de requisitos funcionales y no funcionales					X																			
6. Diseño de BD (PostgreSQL) y modelado de grafos					X	X																		
7. Desarrollo del backend (ASP.NET Core, Clean Architecture, JWT)						X	X	X																
8. Diseño de interfaces (mockups) de SynapTome					X	X																		
Fase III: Desarrollo del frontend y colaboración en tiempo real																								
9. Desarrollo del frontend (Next.js / React)									X	X	X													
10. Integración de SignalR (colaboración en tiempo real)										X	X	X												
11. Pruebas unitarias de los módulos CRUD											X	X												

Tabla 5— Cronograma de actividades – Fases IV a VI (Julio – Diciembre 2026)

Fases y Actividades (2026)	Jul				Ago				Sep				Oct				Nov				Dic			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Fase IV: Integración de los módulos de IA (RAG y TrOCR)																								
12. Implementación del middleware RAG													X	X										
13. Fine-tuning de TrOCR (corpus matemático y manuscrito)													X	X	X									
14. Integración del pipeline IA (RAG + TrOCR) al backend															X	X								
Fase V: Pruebas del sistema y pre-test																								
15. Pruebas de caja negra y depuración																	X	X						
16. Pruebas alfa y beta con usuarios																		X	X					
17. Aplicación del pre-test (muestra UNAMBA)																			X	X				
18. Despliegue de SynapTome (evaluación real)																				X				
Fase VI: Evaluación final y análisis de resultados																								
19. Implementación y uso real con la muestra																					X	X		
20. Aplicación del post-test (SUS / UAT)																						X	X	
21. Análisis estadístico (T-Student, <i>d</i> de Cohen)																							X	
22. Redacción de resultados y conclusiones																							X	X
23. Revisión final y entrega de tesis																								X

5.2 Presupuesto

La Tabla 6 presenta el presupuesto estimado para el desarrollo del proyecto de investigación, organizado por categorías de gasto. Las principales herramientas de software (Visual Studio, .NET SDK, Next.js y Jamovi) se utilizarán bajo licencias gratuitas u *open source*, mientras que los principales costos corresponden al consumo de APIs de modelos de lenguaje, al hosting del sistema y a la aplicación de instrumentos a la muestra de estudiantes.

Tabla 6— Presupuesto estimado del proyecto de investigación

N.º	Descripción	Cantidad	P. unitario (S/)	Total (S/)
Hardware				
1	Laptop de desarrollo (equipo ya disponible)	1	0,00	0,00
2	Tablet con lápiz óptico para pruebas de digitalización de apuntes (TrOCR)	1	850,00	850,00
3	Cuadernos y materiales para conformar el corpus de apuntes manuscritos	1	50,00	50,00
Software y servicios en la nube				
4	Visual Studio Community / .NET SDK (licencia gratuita — <i>open source</i>)	1	0,00	0,00
5	Créditos de API de LLM (Anthropic / OpenAI) para RAG y summarización	6 meses	80,00	480,00
6	Hosting del backend (Azure App Service / Railway, plan básico)	6 meses	35,00	210,00
7	Base de datos PostgreSQL en la nube (Supabase / Neon, plan gratuito)	6 meses	0,00	0,00
8	Dominio web (.com)	1	45,00	45,00
9	Jamovi / JASP (software estadístico, licencia gratuita)	1	0,00	0,00
Recursos humanos y servicios				
10	Impresión y aplicación de cuestionarios (SUS, UAT, pre-test y post-test)	120	1,00	120,00
11	Movilidad para coordinación institucional con la UNAMBA	6 salidas	15,00	90,00
12	Material de oficina (papel, lapiceros, impresiones generales)	1	100,00	100,00
TOTAL GENERAL				S/ 1 945,00

5.3 Fuente de financiamiento

El presente proyecto de investigación será financiado íntegramente con recursos propios del investigador. La mayor parte de las herramientas de software utilizadas

963 (Visual Studio, .NET SDK, Next.js, React y Jamovi) son de acceso gratuito o de
964 código abierto, mientras que los servicios en la nube (créditos de API de LLM,
965 hosting y base de datos) se mantienen dentro de planes básicos o niveles gratuitos,
966 lo que reduce significativamente los costos del proyecto.

967
968
969
970

971

REFERENCIAS BIBLIOGRÁFICAS

972 ABU-SALIH, Bilal y ALOTAIBI, Salihah, 2024. A Systematic Literature Review of Know-
973 ledge Graph Construction and Application in Education. *Heliyon*. Vol. 10, n.º 3, e25383.
974 Disp. desde DOI: 10.1016/j.heliyon.2024.e25383.

975 AFIAN, M. et al., 2025. Real-Time Collaborative Systems and Cloud-Based Architectural
976 Frameworks for Academic Knowledge Management. *Journal of Systems and Software*
977 *Engineering Applications*. Vol. 42, n.º 2, págs. 115-128. Disp. desde DOI: 10.1016/j.
978 jssea.2024.10.012.

979 ALVAREZ-PEREZ, Rodrigo y BARRÓN-FERNANDEZ, Ricardo, 2026. Fine tuning Trans-
980 formers models for converting handwritten scientific texts into LaTeX format. *Interna-*
981 *tional Journal of Combinatorial Optimization Problems and Informatics*. Vol. 17, n.º 2,
982 págs. 38-54.

983 BABAEI, Ebrahim; DINGLER, Tilman; TAG, Benjamin y VELLOSO, Eduardo, 2025.
984 Should We Use the NASA-TLX in HCI? A Review of Theoretical and Methodological Is-
985 sues Around Mental Workload Measurement. *International Journal of Human-Computer*
986 *Studies*. Vol. 201, pág. 103515. Disp. desde DOI: 10.1016/j.ijhcs.2025.103515.

987 CAHYADI, A. et al., 2026. Cognitive Load During Student-Created Virtual Worlds: A NASA-
988 TLX Assessment Using Spatial.io. *Multimodal Technologies and Interaction*. Vol. 5, n.º
989 2, pág. 22. Disp. desde DOI: 10.3390/mti5020022.

990 CHEN, Tong; WANG, Xuewei; YUE, Tianwei; BAI, Xiaoyu; LE, Cindy X. y WANG, Wen-
991 ping, 2023. Enhancing Abstractive Summarization with Extracted Knowledge Graphs
992 and Multi-Source Transformers. *Applied Sciences*. Vol. 13, n.º 7753.

993 DANO, Marydil Anne L.; BANDONG, Samantha Nicole Y.; CABALHUG, Mae Kyla Brig-
994 gette P.; CARACA, Shyra Beth L.; DONGUINES, Henrey Daniel M.; ELPEDEZ, Edmark
995 Iren B.; LAJERA, Sophia Nicole C.; LAZARRAGA, Michael Joseph P.; PUCHERO, Ju-
996 dee Anthonette D.; RADO, John Laurence K.; CUI-TORING, Kimberly N. y TORING,
997 Eugene E., 2026. Digital Note Taking, Traditional Handwritten Notes, and Academic
998 Performance Among University Students. *Journal of Advanced Studies in Aviation, Ae-*
999 *rospace, and Management*. Vol. 1, n.º 4.

1000 FARAH, Joëlle et al., 2024. QuizWiz: Integrating Generative Artificial Intelligence in an
1001 Online Study Tool. En: *Proceedings of the 2024 7th International Conference on Big*
1002 *Data and Education (ICBDE)*. ACM. Disp. desde DOI: 10.1145/3704289.3704296.

- 1003 FIELDING, Roy Thomas, 2000. *Architectural Styles and the Design of Network-based Soft-*
1004 *ware Architectures*. Tesis doct. University of California, Irvine.
- 1005 GAO, Yunfan; XIONG, Yun; GAO, Xinyu; JIA, Kangxiang; PAN, Jinliang; BI, Yuxi; DAI,
1006 Yi; SUN, Jiawei; GUO, Qianyu; WANG, Meng y WANG, Haofen, 2024. Retrieval-
1007 Augmented Generation for Large Language Models: A Survey. *arXiv preprint*. arXiv:2312.10997.
- 1008 HART, Sandra G. y STAVELAND, Lowell E., 1988. Development of NASA-TLX (Task
1009 Load Index): Results of Empirical and Theoretical Research. *Advances in Psychology*.
1010 Vol. 52, págs. 139-183. Disp. desde doi: 10.1016/S0166-4115(08)62386-9.
- 1011 AL-HITAWI, Mohammed A.S. y GYÖNGYÖSSY, N. M., 2026. Enhancing Transformer-
1012 Based Language Models for Hungarian Handwritten Text Recognition. *F1000Research*.
1013 Vol. 15, n.º 181.
- 1014 HUANG, Ming, 2025. Spaced Repetition and Retrieval Practice: Efficient Learning Me-
1015 chanisms from a Cognitive Psychology Perspective and Their Empowerment by AI.
1016 *International Journal of Asian Social Science Research*. Vol. 2, n.º 6, págs. 31-37.
- 1017 JIANG, Mi; GAO, Junran; PAN, Zeyu; WU, Yue y WANG, Zile, 2025. NexaNota: An AI-
1018 Powered Smart Linked Lecture Note-Taking System Leveraging Large Language Models.
1019 En: *2025 International Conference on Big Data and Informatization Education (ICBDIE)*.
1020 ACM.
- 1021 JONES, Michael B.; BRADLEY, John y SAKIMURA, Nat, 2015. *JSON Web Token (JWT)*
1022 [RFC 7519, IETF]. Disponible también desde: [https://www.rfc-editor.org/rfc/](https://www.rfc-editor.org/rfc/rfc7519)
1023 [rfc7519](https://www.rfc-editor.org/rfc/rfc7519).
- 1024 KANNAMMAL, K. E.; BHARATH KUMAR, M. S.; DHARANI DARAN, G.; KAVIN
1025 KRISHNA, S.; KAMALI, S. y MAAJIDA, A., 2024. NoteFlow AI. *International Journal*
1026 *of Scientific Research in Engineering and Management (IJSREM)*.
- 1027 KARDANMOGHADDAM, Hossein; AKBARIMAJD, Adel; RANJBARPOUR, Moham-
1028 mad; NOOSHYAR, Mahdi y JAMALI, Shahram, 2025. A Structure Based on TrOCR
1029 Transformer and Large Language Model for Classification of Handwritten Texts. *Facta*
1030 *Universitatis, Series: Electronics and Energetics*. Vol. 38, n.º 4, págs. 697-714.
- 1031 KASIRYE, Fred, 2023. Collaborative Learning and Higher Education. *Globalization and*
1032 *Business*. N.º 15.
- 1033 KLESEL, Michael y WITTMANN, H. F., 2025. Retrieval-Augmented Generation (RAG).
1034 *Business & Information Systems Engineering*. Vol. 67, n.º 4, págs. 551-561. Disp. desde
1035 DOI: 10.1007/s12599-025-00934-4.

- 1036 KREIJKES, Pia; KEWENIG, Viktor; KUVALJA, Martina; LEE, Mina; HOFMAN, Jake
1037 M.; VITELLO, Sylvia; SELLEN, Abigail; RINTEL, Sean; GOLDSTEIN, Daniel G.;
1038 ROTHCHILD, David; TANKELEVITCH, Lev y OATES, Tim, 2026. Effects of LLM
1039 use and note-taking on reading comprehension and memory: A randomised experiment
1040 in secondary schools. *Computers & Education*. Vol. 243, pág. 105514.
- 1041 LI, Jingyi; CHEN, Wei; ZHANG, Hao et al., 2025. Education-Oriented Graph Retrieval-
1042 Augmented Generation for Learning Path Recommendation. *arXiv preprint*. arXiv:2506.22303.
- 1043 LI, Minghao; LV, Tengchao; CHEN, Jingye; CUI, Lei; LU, Yijuan; FLORENCIO, Dinei;
1044 ZHANG, Cha; LI, Zhoujun y WEI, Furu, 2023. TrOCR: Transformer-Based Optical
1045 Character Recognition with Pre-Trained Models. En: *Proceedings of the AAAI Conference*
1046 *on Artificial Intelligence*. Vol. 37, págs. 13094-13102. Disp. desde doi: 10.1609/aaai.v37i11.26538.
- 1048 LNĚNÍČKA, Martin et al., 2024. Human-Centric Explainable AI in Education: Privacy,
1049 Security and Ethical Considerations. *arXiv preprint*. arXiv:2410.19822.
- 1050 LODOVICO MOLINA, Sebastián et al., 2025. QuerIA: Adaptive Question Generation and
1051 Evaluation in Higher Education Using Large Language Models and Contextual Learning.
1052 *Expert Systems with Applications*. Disp. desde doi: 10.1016/j.eswa.2025.037558.
- 1053 Combina prompt engineering, chunking semántico y alineación con Taxonomía de Bloom.
- 1054 MARTIN, Robert C., 2017. *Clean Architecture: A Craftsman's Guide to Software Structure*
1055 *and Design*. Prentice Hall. ISBN 9780134494166.
- 1056 MSAMBWA, Daniel et al., 2025. The Impact of AI on the Personal and Collaborative
1057 Learning Environments in Higher Education. *European Journal of Education*. Disp.
1058 desde doi: 10.1111/ejed.12909. Revisión sistemática de 148 artículos (2021–2024).
- 1059 NING, Wenyu; SHI, Shaotao; YIN, Yuchen; GUO, Zixuan y XIE, Jinrong, 2025. Intent-aware
1060 personalized summarization for educational texts with large language models. *Journal of*
1061 *King Saud University - Computer and Information Sciences*. Vol. 37, pág. 308.
- 1062 OBIONWU, Victor; BRONESKE, David y SAAKE, Gunter, 2022. Topic maps as a tool
1063 for facilitating collaborative work pedagogy in knowledge management systems. En: *The*
1064 *12th International Conference on Information Communication and Management (ICICM*
1065 *2022)*. ACM.
- 1066 SAXENA, Rishabh; SINGH, Shubhangi y DUBEY, Preeti, 2025. Comparative Analysis of
1067 Large Language Models for the Application of Scientific Article Summarization. *Procedia*
1068 *Computer Science*. Vol. 259, págs. 532-542.

- 1069 SHARMA, Madhav; SAXENA, Rakesh Kumar; SAINI, Hukum Chand; AGARWAL, Sa-
1070 miksha; SAXENA, Akash y RUNTHALA, Ashish, 2025. TrOCR: Transformer-Based
1071 OCR with Pre-Trained Vision–Language Models. En: *2025 IEEE Pune Section Interna-*
1072 *tional Conference (PuneCon)*. IEEE. Benchmarking en IAM, Bentham y SROIE; supera
1073 pipelines CNN-RNN.
- 1074 SHIRKANDE, S.T.; OMKAR, Gaikwad; HARSHAL, Palve; JAYESH, Patil y ANIKET, Kha-
1075 de, 2025. Noteverse: Intelligent Note Management for Organizational Hub. *International*
1076 *Journal on Advanced Electrical and Computer Engineering*. Vol. 14, n.º 1.
- 1077 SOLANKI, Minal; CHANDANKHEDE, Puja K. y BADWAIK, Sanjana J., 2026. Note-
1078 Genius: An Intelligent AI-Powered Ecosystem for Note Generation and Collaborative
1079 Learning. *International Journal of Advanced Research in Science, Communication and*
1080 *Technology (IJARSCT)*. Vol. 6, n.º 1, págs. 550-555.
- 1081 SOUMYA, M. D. y KRISHNAMOORTHY, S., 2025. Knowledge Graphs for Representing
1082 Knowledge Progression of Students across Heterogeneous Learning Systems. *Internatio-*
1083 *nal Journal of Artificial Intelligence in Education*. Vol. 35, págs. 1695-1723. Disp. desde
1084 DOI: 10.1007/s40593-024-00434-w.
- 1085 TANKELEVITCH, Lev et al., 2025. More AI Assistance Reduces Cognitive Engagement:
1086 Examining the AI Assistance Dilemma in AI-Supported Note-Taking. *arXiv preprint*.
1087 arXiv:2509.03392. Estudio CHI 2025 sobre toma de notas asistida por IA.
- 1088 TARAZONA CRUZ, Luz Silvana, 2024. *Reconocimiento de texto en manuscritos históricos*
1089 *peruanos utilizando modelos mixtos*. Lima, Perú. Disponible también desde: <http://hdl.handle.net/20.500.12404/29310>. Tesis de maestría. Pontificia Universidad
1090 Católica del Perú.
- 1092 TORRES, Miguel et al., 2025. Enhancing Active Recall and Spaced Repetition with LLM-
1093 Augmented Review Systems. *Proceedings of the American Society for Engineering Edu-*
1094 *cation (ASEE)*. Disp. desde DOI: 10.18260/1-2--47123.
- 1095 UPADHYAY, Aryan; MOHOD, Arjun; CHAUDHARI, Manish; SHAHU, Kartik; WAGH-
1096 MARE, Kartik y KUBADE, Harshad M., 2026. AI-Powered YouTube Video Summa-
1097 rization: A Comprehensive Web Application for Automatic Content Analysis and Note
1098 Generation. *International Journal for Research in Applied Science and Engineering Tech-*
1099 *nology (IJRASET)*. Vol. 14, n.º 1. Disp. desde DOI: 10.22214/ijraset.2026.76857.
- 1100 VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; USZKOREIT, Jakob; JONES,
1101 Llion; GOMEZ, Aidan N.; KAISER, Lukasz y POLOSUKHIN, Illia, 2017. Attention Is
1102 All You Need. En: *Advances in Neural Information Processing Systems (NeurIPS)*.
- 1103 VIERIU, Aniella Mihaela y PETREA, Gabriel, 2025. The Impact of Artificial Intelligence
1104 (AI) on Students' Academic Development. *Education Sciences*. Vol. 15, n.º 3, pág. 343.

- 1105 ZHANG, Bo, 2026. A Review of the Development of Text Recognition Techniques. En:
1106 *CONF-SPML 2026 Symposium: The 2nd Neural Computing and Applications Workshop*.
- 1107 ZHANG, Liang et al., 2026. Personalized Learning Path Recommendation Based on Know-
1108 ledge Graphs: A Survey. *Electronics*. Vol. 15, n.º 1, pág. 238. Disp. desde DOI: [10.3390/
1109 electronics15010238](https://doi.org/10.3390/electronics15010238). Revisión narrativa 2014–2025, bases Web of Science y Scopus.

1110

1111

1112

1113

1114

1115

1116

1117

1118

1119

1120

ANEXOS

Tabla 7— Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema SynapTome

Problema de Investigación	Objetivos de la Investigación	Hipótesis de la Investigación	Variables	Indicadores / Métricas	Metodología Aplicada
Problema General ¿De qué manera la transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente SynapTome optimiza el rendimiento académico, reduce la sobrecarga cognitiva y eleva la eficacia del aprendizaje colaborativo en estudiantes universitarios?	Objetivo General Optimizar la gestión del conocimiento, ampliar el acceso a repositorios de estudio y fortalecer el aprendizaje colaborativo, mediante la evaluación e implementación del ecosistema inteligente SynapTome, con el propósito de incrementar significativamente el rendimiento académico de los estudiantes universitarios.	Hipótesis General La transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente SynapTome optimiza significativamente el rendimiento académico, reduce la sobrecarga cognitiva y eleva la eficacia del aprendizaje colaborativo en los estudiantes universitarios (Shirkande et al., 2025; Afian et al., 2025).	Variable Independiente (VI): Uso del ecosistema inteligente SynapTome. Variable Dependiente (VD): Rendimiento académico y optimización de procesos cognitivos.	* Tasa de Error de Caracteres (CER %). * Tiempo de consolidación de apuntes (min). * Índice de alucinación factual (%). * Puntaje de sobrecarga mental (NASA-TLX). * Calificación de exámenes (0–20). * Intercambio colaborativo (ítems/semana).	Tipo: Aplicada. Nivel: Explicativo. Diseño: Experimental (Pre-test / Pos-test). Enfoque: Cuantitativo. Método: Científico y estadístico. Población y Muestra: Estudiantes de la Escuela de Informática y Sistemas, UNAMBA.
Problema Específico 1 ¿En qué medida la migración de los estudiantes hacia un flujo de digitalización automatizado influye en la tasa de preservación de información técnica y en la reducción del tiempo dedicado a la consolidación de apuntes manuscritos?	Objetivo Específico 1 Medir el incremento en la tasa de preservación de información técnica y la reducción del tiempo de consolidación de apuntes manuscritos en los estudiantes universitarios, mediante la transición de métodos de transcripción analógica tradicionales hacia un flujo de digitalización automatizado de alta precisión.	Hipótesis Específica 1 La migración de los estudiantes hacia un flujo de digitalización automatizado mediante un pipeline HTR basado en la arquitectura TrOCR con <i>fine-tuning</i> incrementa significativamente la tasa de preservación de información técnica en sus apuntes y reduce el tiempo promedio dedicado a la consolidación de notas manuscritas respecto al estado inicial analógico.	Dimensión VI: Módulo de digitalización y transcripción visual (TrOCR). Dimensión VD: Eficiencia de captura técnica del estudiante.	* Tasa de Error de Caracteres (CER %). * Tiempo semanal de transcripción manual o consolidación de apuntes (minutos). * Precisión de renderizado en sintaxis L ^A T _E X (%).	* Pipeline en Node.js de procesamiento de imágenes. * Modelo autorregresivo Transformer (TrOCR). * Análisis de varianza de tiempos de edición. * Pruebas experimentales en asignaturas de Cálculo y Física.
Problema Específico 2 ¿Cómo repercute el condicionamiento del entorno de asimilación cognitiva de los alumnos a un corpus académico validado en el nivel de veracidad factual y en la reducción de errores conceptuales presentes en sus materiales de autoestudio?	Objetivo Específico 2 Determinar la reducción en el índice de errores conceptuales y datos falsos (alucinaciones) en el material de autoestudio utilizado por los alumnos, evaluando el nivel de fidelidad y veracidad factual de sus resúmenes antes y después de restringir su entorno de asimilación cognitiva a un corpus académico validado.	Hipótesis Específica 2 El condicionamiento del entorno de asimilación cognitiva de los alumnos a un corpus académico validado mediante un middleware RAG restrictivo disminuye drásticamente el índice de errores conceptuales y datos falsos presentes en sus materiales de autoestudio, asegurando una alta fidelidad factual en comparación con el uso de herramientas genéricas de información.	Dimensión VI: Middleware de recuperación y fidelidad factual (RAG). Dimensión VD: Calidad factual de los recursos de repaso del estudiante.	* Índice de inserción de conceptos erróneos o alucinados (%). * Coincidencia semántica con el material base académico (%). * Tasa de veracidad conceptual en resúmenes.	* Indexación vectorial relacional. * Chunking semántico parametrizado de sílabos y apuntes oficiales. * Inferencia controlada sobre Modelos de Lenguaje Grande (LLMs). * Evaluación de fidelidad de resúmenes.
Problema Específico 3 ¿Cuál es el impacto latente de la adopción de un entorno de aprendizaje interconectado basado en mapas conceptuales dinámicos sobre las calificaciones promedio alcanzadas por los estudiantes y el nivel de sobrecarga cognitiva percibido?	Objetivo Específico 3 Cuantificar el impacto latente en las calificaciones promedio y el nivel de sobrecarga cognitiva percibida por los estudiantes, analizando la variación de sus puntajes académicos y fatiga mental tras migrar de un esquema de repaso individual aislado a un entorno de aprendizaje interconectado y evaluado de forma dinámica.	Hipótesis Específica 3 La adopción de un entorno de aprendizaje interconectado basado en Grafos de Conocimiento y evaluaciones dinámicas automatizadas incrementa las calificaciones promedio de los estudiantes y reduce los niveles de sobrecarga cognitiva percibida en comparación con los valores basales registrados durante los métodos de	Dimensión VI: Motor relacional topológico y evaluaciones dinámicas. Dimensión VD: Desempeño académico y carga cognitiva declarada del alumno.	* Calificaciones cuantitativas alcanzadas en exámenes parciales (Escala 0–20). * Índice de fatiga mental y estrés autopercebido (Escala NASA-TLX). * Volumen de intercambio interactivo eficaz (ítems/semana).	* Base de datos orientada a grafos indexados. * Algoritmos de IA para generación automatizada de cuestionarios formativos (<i>quizzes</i>). * Protocolos de sincronización web interactiva en tiempo real (SignalR). * Aplicación de la prueba estadística t de Student unilateral derecha.