

1 **UNIVERSIDAD NACIONAL MICAELA BASTIDAS DE APURÍMAC**
2 **FACULTAD DE INGENIERÍA**
3
4
5 **ESCUELA ACADÉMICO PROFESIONAL DE INGENIERÍA INFORMATICA Y**
6 **SISTEMAS**



7
8
9
10 **Proyecto de Tesis**
11
12 **Ecosistema Inteligente con Visión Artificial y LLM para mejorar el aprendizaje**
13 **colaborativo y el rendimiento académico en la UNAMBA, 2026**
14

15 **Presentado por:**
16

17
18 **Clinio Omar Rayme Huacho**
19

20 **Para optar el título de Ingeniero Informatico y Sistemas**
21

22
23
24 **Abancay, Perú**
25

26 **2026**

UNIVERSIDAD NACIONAL MICAELA BASTIDAS DE APURÍMAC
FACULTAD DE INGENIERÍA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMATICA Y SISTEMAS



TESIS

Ecosistema Inteligente con Visión Artificial y LLM para mejorar el Aprendizaje Colaborativo y el Rendimiento Académico en la UNAMBA, 2026

Presentado por **Clinio Omar Rayme Huacho**, para optar el título de Ingeniero Informático y Sistemas

Sustentado y aprobado (fecha de sustentación) ante el jurado evaluador:

Presidente: _____
Grado. Nombres y apellidos

Primer miembro: _____
Grado. Nombres y apellidos

Segundo miembro: _____
Grado. Nombres y apellidos

Asesor: _____
M.Sc. Yhon Fuentes Huaman

Agradecimiento

A la Universidad Nacional Micaela Bastidas de Apurímac y de manera especial a la Escuela Académico Profesional de Ingeniería de Informática y Sistemas, por haberme brindado el espacio institucional y las herramientas necesarias para mi formación profesional y científica.

A nuestros asesores y docentes de la facultad, cuyos rigurosos comentarios, correcciones y constante exigencia metodológica permitieron reorientar el enfoque de esta investigación hacia un impacto real y medible en el aprendizaje estudiantil.

A los compañeros de equipo y de ruta académica, por el soporte técnico incondicional, las largas noches de debate arquitectónico y el esfuerzo compartido en la construcción de este proyecto; este logro es también el reflejo de nuestra dedicación colectiva.

Finalmente, a cada uno de los estudiantes de nuestra casa de estudios que participaron activamente en las pruebas experimentales, cuya retroalimentación e interacciones semánticas dieron vida y validaron el propósito de este ecosistema digital.

Dedicatoria

A mis padres, por su amor incondicional, su paciencia infinita y por ser el pilar fundamental que sostuvo cada uno de mis pasos a lo largo de este trayecto académico y personal.

A mi familia, por sus palabras de aliento en los momentos de mayor exigencia y por creer firmemente en mi capacidad para alcanzar mis metas.

Y a todas las personas que, de manera silenciosa pero constante, compartieron sus conocimientos, su tiempo y su apoyo, motivándome a culminar con éxito esta importante etapa de formación profesional.

45
46
47
48

49

ÍNDICE

	Pag.
50 INTRODUCCIÓN	1
51 CAPÍTULO I	3
52 PLANTEAMIENTO DEL PROBLEMA	3
53 1.1 Descripción del problema	3
54 1.2 Enunciado del problema	4
55 1.2.1 Problema general	4
56 1.2.2 Problemas específicos	4
57 1.3 Justificación de la investigación	4
58 1.3.1 Justificación Científica	5
59 1.3.2 Justificación Tecnológica	5
60 1.3.3 Justificación Institucional	5
61 1.4 Ubicación y Contextualización	6
62 CAPÍTULO II	7
63 OBJETIVOS E HIPÓTESIS	7
64 2.1 Objetivos de la investigación	7
65 2.1.1 Objetivo general	7
66 2.1.2 Objetivos específicos	7
67 2.2 Hipótesis de la investigación	7
68 2.2.1 Hipótesis general	7
69 2.2.2 Hipótesis específicas	7
70 CAPÍTULO III	10
71 MARCO TEÓRICO REFERENCIAL	10
72 3.1 Antecedentes	10
73 3.1.1 Antecedentes internacionales	10
74 3.1.2 Antecedentes nacionales	12
75 3.2 Marco teórico	12
76 3.2.1 Inteligencia Artificial Generativa y Arquitectura RAG	12
77 3.2.2 Arquitectura Transformer y Mecanismo de Atención	13
78 3.2.3 Reconocimiento de Texto Manuscrito (HTR), TrOCR y Fórmulas	
79 Matemáticas	15
80 3.2.4 <i>Vector Embeddings</i> y Bases de Datos Vectoriales	16

81	3.2.5	Grafos de Conocimiento	17
82	3.2.6	Generación Automática de Evaluaciones Adaptativas	18
83	3.2.7	Aprendizaje Activo y Recuperación Espaciada (<i>Spaced Repetition</i>)	18
84	3.2.8	Aprendizaje Colaborativo Mediado por Tecnología	19
85	3.2.9	Carga Cognitiva y Medición con NASA-TLX	20
86	3.2.10	Privacidad y Seguridad de Datos Estudiantiles en Plataformas IA	20
87	3.2.11	Arquitectura Limpia (<i>Clean Architecture</i>)	21
88	3.3	Marco conceptual	22
89	CAPÍTULO IV		24
90	METODOLOGÍA		24
91	4.1	Tipo y nivel de investigación	24
92	4.2	Diseño de la investigación	24
93	4.3	Pipeline del sistema	25
94	4.4	Descripción ética de la investigación	25
95	4.5	Población y muestra	26
96	4.6	Procedimiento	26
97	4.7	Técnicas e instrumentos	27
98	4.7.1	Técnicas	27
99	4.7.2	Instrumentos	28
100	4.8	Estadístico de la investigación	28
101	CAPÍTULO V		30
102	RESULTADOS Y DISCUSIONES		30
103	5.1	Resultados para el objetivo específico 1: Precisión de la digitalización de fórmulas y apuntes técnicos frente a métodos tradicionales	30
104			
105	5.1.1	Análisis Comparativo de la Tasa de Error de Caracteres (CER) y Tiempos de Consolidación de Notas	30
106			
107	5.2	Resultados para el objetivo específico 2: Nivel de fidelidad y veracidad de la información académica y mitigación de alucinaciones	31
108			
109	5.2.1	Evaluación del Middleware RAG frente a Modelos de Lenguaje Genéricos	31
110			
111	5.3	Resultados para el objetivo específico 3: Impacto de mapas conceptuales interconectados y evaluaciones automatizadas en el rendimiento académico y sobrecarga cognitiva	32
112			
113			
114	5.3.1	Correlación Empírica entre el Uso de Grafos Semánticos, Quizzes de Repaso y Calificaciones	32
115			
116	5.4	Contrastación de la hipótesis general	34
117	5.4.1	Formulación de hipótesis	35
118	5.4.2	Nivel de significancia	35
119	5.4.3	Selección de la prueba Variable	35
120	5.4.4	Estadístico de prueba	36

121	5.4.5	Región crítica y decisión estadística	36
122	5.4.6	Interpretación estadística	37
123	5.4.7	Conclusión de la hipótesis general	38
124	5.5	Discusión	38
125	CAPÍTULO VI		39
126	CONCLUSIONES Y RECOMENDACIONES		39
127	6.1	Conclusiones	39
128	6.2	Recomendaciones	40
129	REFERENCIAS BIBLIOGRÁFICAS		41
130	ANEXOS		46

131
132
133
134

ÍNDICE DE TABLAS

135

136	Tabla 1 — Operacionalización de las variables de investigación	9
137	Tabla 2 — Fases del procedimiento de investigación	27
138	Tabla 3 — Instrumentos de recolección de datos	28
139	Tabla 4 — Métricas empíricas del rendimiento y aprendizaje del estudiante (Antes	
140	vs. Después)	33
141	Tabla 5 — Indicadores globales utilizados para la validación de la hipótesis ge-	
142	neral (Enfoque en el Estudiante)	36
143	Tabla 6 — Resultados de la prueba t para la hipótesis general en SynapTome . .	37
144	Tabla 7 — Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema	
145	SynapTome	47

146
147
148
149

ÍNDICE DE FIGURAS

150

151	Figura 1 — Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA). .	6
152	Figura 2 — Arquitectura general del sistema de Generación Aumentada por Re-	
153	cuperación (RAG).	13
154	Figura 3 — Mecanismo de auto-atención escalada por producto punto (Scaled	
155	Dot-Product Attention).	14
156	Figura 4 — Flujo de procesamiento híbrido de visión y lenguaje del modelo TrOCR.	16
157	Figura 5 — Similitud de coseno entre vectores en un espacio de embeddings	
158	multidimensional.	17
159	Figura 6 — Grafo relacional de conocimiento representando la progresión del	
160	estudiante.	18
161	Figura 7 — Curva del olvido de Ebbinghaus y el impacto de los repasos progra-	
162	mados.	19
163	Figura 8 — Capas concéntricas de dependencias bajo el diseño de Arquitectura	
164	Limpia.	22
165	Figura 9 — Descripción clara del contenido de la imagen enfocada en el impacto	
166	o flujo del estudiante.	25
167	Figura 10 — Comparación de la Tasa de Error de Caracteres (CER %) en apuntes	
168	técnicos de estudiantes.	30
169	Figura 11 — Análisis de error (CER %) por tipología de estructura matemática	
170	manuscrita.	31
171	Figura 12 — Evolución del índice de alucinaciones factuales según la inyección de	
172	contexto validado.	32
173	Figura 13 — Curva de retención cognitiva a largo plazo basada en evaluaciones	
174	formativas automatizadas.	34
175	Figura 14 — Región crítica de la prueba t de Student para la hipótesis de impacto	
176	pedagógico general.	37

INTRODUCCIÓN

La adopción de la Inteligencia Artificial Generativa ha impulsado una transformación sin precedentes en la educación superior, redefiniendo las metodologías de enseñanza y la asimilación del conocimiento (Vieriu et al., 2025). En este escenario, la gestión de apuntes universitarios ha experimentado una evolución acelerada, migrando desde los métodos manuscritos tradicionales hacia formatos digitales dinámicos e interactivos. Esta transición tecnológica busca optimizar la captura, organización y recuperación de la información académica. Según Krejkes et al. (2026), la integración de Modelos de Lenguaje Grande (LLMs) presenta oportunidades excepcionales para facilitar la comprensión lectora y reducir la carga cognitiva inicial de los estudiantes. Sin embargo, el volumen exponencial de datos técnicos y científicos en disciplinas de ingeniería exige herramientas que trasciendan el simple almacenamiento, demandando ecosistemas capaces de procesar y enlazar semánticamente el contenido educativo.

A pesar de estos avances tecnológicos, la digitalización educativa contemporánea enfrenta desafíos algorítmicos y pedagógicos severos. Los estudiantes de ingeniería padecen de una constante sobrecarga cognitiva al intentar integrar múltiples fuentes de información no estructurada. La adopción pasiva de plataformas de IA genéricas agrava este panorama, induciendo una dependencia tecnológica que inhibe el análisis crítico y la apropiación del conocimiento (Vieriu et al., 2025). A nivel técnico, los LLMs estándar adolecen de un problema crítico de “alucinaciones”; dado que carecen de mecanismos intrínsecos para verificar la veracidad de los hechos, frecuentemente generan información plausible pero fácticamente incorrecta (T. Chen et al., 2023). Adicionalmente, la digitalización de apuntes científicos enfrenta la barrera de la notación matemática, donde los sistemas tradicionales fracasan al procesar estructuras espaciales complejas (Alvarez-Perez et al., 2026). Finalmente, las herramientas actuales promueven un consumo individualista y fragmentado de la información, careciendo de la infraestructura lógica para establecer vínculos semánticos que fomenten una colaboración auténtica entre pares (Jiang et al., 2025).

Para mitigar estas brechas tecnológicas y metodológicas, la presente investigación propone formalmente el desarrollo de SynapTome, un ecosistema digital inteligente y colaborativo fundamentado en los principios de la Arquitectura Limpia (Clean Architecture). La infraestructura del sistema orquesta tecnologías de vanguardia para transformar la gestión del aprendizaje: en el núcleo de procesamiento de lenguaje natural, se implementa una arquitectura de Generación Aumentada por Recuperación (RAG) que restringe la inferencia de la IA a un corpus documental validado, garantizando precisión factual y eliminando las alucinaciones (Ning et al., 2025). Para abordar el reto de la digitalización científica, se integra

un pipeline de visión por computadora basado en el modelo Transformer TrOCR, el cual permite la transcripción estructurada de apuntes manuscritos y fórmulas matemáticas al formato LaTeX (KardanMoghaddam et al., 2025). El elemento diferenciador de SynapTome radica en su motor de base de datos relacional modelado mediante Grafos de Conocimiento en PostgreSQL. Estos grafos indexan topológicamente los bloques de estudio, descubriendo relaciones transversales entre múltiples usuarios para catalizar una verdadera Inteligencia Colectiva”(Obionwu et al., 2022). Todo el ecosistema opera con una sincronización concurrente a través de SignalR y C#, con una interfaz reactiva desarrollada en Next.js.

El presente trabajo de investigación se estructura en seis capítulos organizados de la siguiente manera: el **Capítulo I** comprende el planteamiento del problema, delimitando la problemática de la sobrecarga cognitiva y la digitalización de apuntes científicos, justificando la investigación desde las dimensiones científica, tecnológica e institucional, y contextualizando el caso de estudio en la Escuela Profesional de Ingeniería de Informática y Sistemas de la UNAMBA; el **Capítulo II** establece los objetivos de la investigación (general y específicos), las hipótesis correspondientes que guían el estudio y la operacionalización rigurosa de las variables; el **Capítulo III** desarrolla el marco teórico referencial, comenzando con los antecedentes nacionales e internacionales del estado del arte, y profundizando en teorías fundamentales como la Inteligencia Artificial Generativa, la arquitectura RAG, los Transformers, TrOCR, bases de datos vectoriales, Grafos de Conocimiento y la Teoría de la Carga Cognitiva; el **Capítulo IV** detalla el diseño metodológico, especificando el tipo y diseño de la investigación (cuasi-experimental), el pipeline del sistema, la población y muestra, el procedimiento experimental, así como las técnicas, instrumentos y estadísticos (pruebas t de Student, CER, WER, ROUGE y SUS); el **Capítulo V** presenta los resultados empíricos obtenidos en las pruebas, incluyendo el análisis comparativo del error de caracteres (CER), la mitigación de alucinaciones en el middleware RAG, la reducción de sobrecarga cognitiva mediante NASA-TLX, y la contrastación de la hipótesis general; finalmente, el **Capítulo VI** expone las conclusiones del estudio, destacando los logros alcanzados frente a cada objetivo específico, y propone recomendaciones metodológicas y tecnológicas para futuras implementaciones.

246
247
248
249

250
251

CAPÍTULO I

PLANTEAMIENTO DEL PROBLEMA

252

1.1 Descripción del problema

253
254
255
256
257
258
259
260
261
262
263
264
265
266
267
268
269
270
271
272
273
274
275
276
277
278
279
280
281
282
283
284

En el entorno académico universitario contemporáneo, los estudiantes enfrentan un volumen exponencial de información técnica y científica que a menudo desencadena una severa sobrecarga cognitiva. El procesamiento simultáneo de múltiples fuentes de información no estructurada y la dificultad de organizar apuntes fragmentados limitan la capacidad de comprensión y retención de los alumnos. Teorías del aprendizaje, como la Teoría de la Carga Cognitiva, explican que la división de la atención durante la captura manual o digital de apuntes puede resultar en la pérdida de información crítica y en un bajo rendimiento académico si los métodos de captura no se alinean con un procesamiento estructurado. A pesar de que la toma de apuntes es una herramienta pedagógica esencial, los enfoques tradicionales a menudo generan ecosistemas de estudio aislados que no logran seguir el ritmo de la complejidad del contenido universitario.

Para mitigar esta sobrecarga, los estudiantes han recurrido a Modelos de Lenguaje Grande (LLMs) genéricos en busca de resúmenes y asistencia académica. Sin embargo, la adopción de estos sistemas presenta fallas críticas. Los LLMs tradicionales frecuentemente fracasan al capturar los matices técnicos y factuales propios de los artículos de investigación e ingeniería. Más grave aún es el problema de las “alucinaciones”; los LLMs carecen de una capacidad intrínseca para verificar la veracidad de la información que generan, lo que resulta en la invención de hechos plausibles pero falsos que contaminan el aprendizaje. Además, el uso de resúmenes genéricos omite la intención y el contexto específico del usuario, lo que subraya la necesidad imperativa de sistemas de IA condicionados factualmente.

Por otra parte, la digitalización de apuntes manuscritos en carreras de ingeniería y ciencias exactas enfrenta un cuello de botella computacional significativo debido a la presencia de fórmulas matemáticas, matrices y gráficos. Los sistemas convencionales de Reconocimiento Óptico de Caracteres (OCR) no están diseñados para interpretar la estructura espacial y semántica de las matemáticas. Es necesario el uso de arquitecturas basadas en Transformers, como TrOCR, sometidas a procesos de fine-tuning específicos, para lograr una conversión estructurada y precisa de notación científica hacia el formato LaTeX. La alta variabilidad en los estilos de escritura y el ruido en las imágenes complican severamente la transcripción automatizada si no se emplean pipelines de Deep Learning avanzados.

Finalmente, existe una carencia fundamental de plataformas verdaderamente colaborativas. Históricamente, la gestión de apuntes ha sido un proceso de consumo individual. El aprendizaje colaborativo basado en la gestión del conocimiento es indispensable para el desarrollo de competencias en el aula. No obstante, las herramientas actuales carecen de la infraestructura necesaria para enlazar semánticamente la información entre pares. La literatura sugiere que la implementación de mapas de tópicos y grafos relacionales en los sistemas de gestión del conocimiento es un habilitador técnico crucial para una pedagogía verdaderamente colaborativa, un componente del cual carecen las plataformas educativas estándar.

1.2 Enunciado del problema

1.2.1 Problema general

¿En cuánto disminuye la sobrecarga de apuntes y la fatiga mental, y en qué medida se incrementa el rendimiento académico y la eficacia colaborativa de los estudiantes universitarios de la UNAMBA al transicionar desde esquemas de estudio aislados hacia un entorno de aprendizaje interconectado y automatizado?

1.2.2 Problemas específicos

- ¿En cuánto se reduce el tiempo de consolidación de apuntes manuscritos y cuál es el incremento en la tasa de preservación de información técnica mediante el uso de la aplicación con un módulo de transcripción automatizada (TrOCR) frente a los métodos de transcripción tradicional?
- ¿Cuál es la tasa de reducción de errores conceptuales en el material de repaso de los estudiantes al condicionar las respuestas del sistema mediante un middleware RAG acoplado a un LLM en comparación con las herramientas de inteligencia artificial genéricas de entorno abierto?
- ¿En cuánto disminuye el nivel de sobrecarga cognitiva y cuál es la variación en las calificaciones promedio de los alumnos al implementar un motor relacional de grafos de conocimiento con evaluaciones dinámicas automatizadas frente a los esquemas basales de estudio aislados?

1.3 Justificación de la investigación

La presente investigación se justifica desde tres dimensiones fundamentales: científica, tecnológica e institucional, las cuales convergen en el desarrollo y despliegue del ecosistema SynapTome para resolver de manera integral los desafíos contemporáneos en la gestión del aprendizaje universitario.

1.3.1 Justificación Científica

A nivel científico, este estudio aporta evidencia empírica sobre cómo resolver las deficiencias inherentes de los Modelos de Lenguaje Grande (LLMs) en contextos académicos. Se demuestra que la integración de Grafos de Conocimiento actúa como una guía semántica que mitiga la incapacidad de los LLMs para verificar hechos, reduciendo drásticamente las “alucinaciones” durante la sumarización abstractiva (T. Chen et al., 2023). Además, la investigación fundamenta un cambio desde un paradigma de aprendizaje pasivo hacia uno constructivista; el uso guiado de la IA para la generación automática de evaluaciones formativas (*quizzes*) e interacciones basadas en apuntes reduce la sobrecarga cognitiva e incrementa significativamente la retención a largo plazo y la comprensión de los estudiantes (Kreijkes et al., 2026; Afian et al., 2025). Finalmente, el proyecto valida la teoría de la pedagogía colaborativa, comprobando que el uso de Mapas de Tópicos (*Topic Maps*) permite estructurar el conocimiento fragmentado, descubriendo relaciones transversales y fomentando una auténtica “Inteligencia Colectiva” (Obionwu et al., 2022).

1.3.2 Justificación Tecnológica

Desde la perspectiva tecnológica, el desarrollo de SynapTome representa un avance en la superación de los cuellos de botella clásicos de la digitalización científica. El proyecto aborda las altas tasas de error de los sistemas OCR tradicionales mediante la implementación de *pipelines* de visión por computadora basados en la arquitectura *Transformer* (TrOCR y Nougat), los cuales, a través de procesos de *fine-tuning*, logran transcribir con alta precisión notación matemática y fórmulas complejas directamente hacia el formato estructurado $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ (Alvarez-Perez et al., 2026; Kardan-Moghaddam et al., 2025). Asimismo, el diseño del sistema orquesta una Arquitectura Limpia (*Clean Architecture*) que integra *Next.js* en el *frontend*, un *middleware* de Generación Aumentada por Recuperación (RAG) condicionado factualmente (Ning et al., 2025; Jiang et al., 2025), y bases de datos relacionales con soporte vectorial como PostgreSQL. Esta integración *full-stack*, apoyada en WebSockets (SignalR), justifica la viabilidad de desplegar un entorno de coedición seguro, escalable y en tiempo real (Shirkande et al., 2025; Upadhyay et al., 2026).

1.3.3 Justificación Institucional

A nivel institucional, la implementación de este ecosistema en la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), específicamente orientado a la Escuela Académico Profesional de Ingeniería de

Sistemas, proporciona una infraestructura digital de vanguardia que impacta directamente en la calidad educativa. Los estudiantes de ingeniería requieren asimilar un volumen denso de información matemática y técnica; al proveerles una plataforma que centraliza, digitaliza y democratiza el acceso a una mayor cantidad de apuntes interconectados, la universidad facilita una mejora medible en el rendimiento académico y las calificaciones de su comunidad estudiantil (Dano et al., 2026). En consecuencia, esta iniciativa dota a la UNAMBA de herramientas tecnológicas de primer nivel, posicionándola como una institución innovadora que adopta la Inteligencia Artificial de manera ética, estructurada y orientada al beneficio colectivo.

1.4 Ubicación y Contextualización

La presente investigación se contextualiza y aplicará en la Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), ubicada en la ciudad de Abancay, en la región de Apurímac, Perú. Específicamente, el caso de estudio está enfocado en atender las necesidades académicas y los retos de aprendizaje de los estudiantes de la Escuela Académico Profesional de Ingeniería de Informática y Sistemas. En este entorno, los estudiantes manejan un alto volumen de asignaturas fundamentadas en el cálculo, la física, el álgebra lineal y la algoritmia. Estos tópicos exigen el uso intensivo de notación matemática compleja, diagramas lógicos y esquemas arquitectónicos, los cuales suelen registrarse tradicionalmente de manera manuscrita. Las barreras en la digitalización de esta información, sumadas a la alta carga cognitiva propia de la disciplina y las limitaciones de infraestructura para la colaboración eficiente entre pares, hacen que los estudiantes de la UNAMBA sean los candidatos idóneos para validar la efectividad del ecosistema SynapTome como una herramienta integral para la gestión y democratización de su conocimiento técnico.



Figura 1— Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA).

385
386
387
388

389
390

CAPÍTULO II

OBJETIVOS E HIPÓTESIS

391
392

2.1 Objetivos de la investigación

2.1.1 Objetivo general

393
394
395
396

Determinar en cuánto se reduce la sobrecarga de apuntes y la fatiga mental, y medir el incremento en el rendimiento académico de los estudiantes universitarios de la UNAMBA al implementar y evaluar una aplicación web basada en un entorno de aprendizaje interconectado y automatizado.

397
398
399
400
401

2.1.2 Objetivos específicos

402
403
404
405
406
407
408
409

- Evaluar en cuánto se reduce el tiempo dedicado a la consolidación de apuntes manuscritos y cuantificar el incremento en la tasa de preservación de información técnica mediante el uso de la aplicación web con un módulo de transcripción automatizada (TrOCR).
- Medir la tasa de reducción de errores conceptuales en el material de repaso de los estudiantes al condicionar las respuestas de la aplicación web mediante un middleware RAG acoplado a un LLM en comparación con el uso de herramientas de entorno abierto.
- Cuantificar en cuánto disminuye el nivel de sobrecarga cognitiva y determinar la variación en las calificaciones promedio de los alumnos al implementar en la aplicación web un motor relacional de grafos de conocimiento con evaluaciones dinámicas automatizadas.

410
411
412
413
414
415
416

2.2 Hipótesis de la investigación

2.2.1 Hipótesis general

La implementación y evaluación de la aplicación web basada en un entorno de aprendizaje interconectado y automatizado permitira reducir de forma cuantificable la sobrecarga de apuntes y la fatiga mental, logrando una variación positiva en el rendimiento académico de los estudiantes universitarios de la UNAMBA.

417
418
419

2.2.2 Hipótesis específicas

- El uso de la aplicación web con un módulo de transcripción automatizada (TrOCR) reduce significativamente el tiempo dedicado a la

420 consolidación de apuntes manuscritos y eleva la tasa de preservación de
421 información técnica en comparación con los métodos de transcripción
422 tradicional.

423 • El condicionamiento de las respuestas de la aplicación web mediante un
424 middleware RAG acoplado a un LLM produce una tasa de reducción de
425 errores conceptuales y alucinaciones en el material de repaso superior
426 al estado basal de las herramientas de entorno abierto.

427 • La implementación de un motor relacional de grafos de conocimiento
428 con evaluaciones dinámicas automatizadas en la aplicación web dis-
429 minuye numéricamente el nivel de sobrecarga cognitiva percibida y
430 genera un incremento en las calificaciones promedio de los alumnos
431 frente a los esquemas de estudio aislados tradicionales.

Tabla 1— Operacionalización de las variables de investigación

Variable	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Escala / Rangos
Variable Independiente (VI): Ecosistema inteligente con visión artificial y LLM	Componente tecnológico basado en arquitecturas Transformers con <i>fine-tuning</i> encargado de la conversión automatizada de apuntes físicos y notación científica hacia texto estructurado en la aplicación web.	Se evalúa registrando el tipo de flujo de trabajo implementado por el alumno y calculando el porcentaje de preservación exacta de caracteres técnicos tras el procesamiento visual de imágenes de cuadernos.	Transmisión y digitalización técnica de apuntes.	Uso de herramientas tecnológicas (Flujo manual tradicional vs. Aplicación web automatizada); tasa de conversión de caracteres técnicos (%); porcentaje de preservación de fórmulas matemáticas.	Flujo de trabajo: 0 = Manual tradicional 1 = Web automatizada Conversión: Alta $\geq 95\%$ Baja $< 80\%$ Preservación: Excelente $> 95\%$ Regular 80–95 %
	Mecanismo de procesamiento de lenguaje natural acoplado a un LLM que limita y restringe el espacio de inferencia computacional a un corpus de documentos académicos validados por la plataforma web.	Se mide verificando el grado de restricción del entorno de consultas del sistema y calculando la reducción porcentual de datos falsos o alucinaciones en los materiales de repaso generados.	Control factual de contenido sintético.	Configuración del entorno de inferencia (Inferencia abierta genérica vs. Filtro RAG restrictivo); tasa de reducción de errores conceptuales (%); consistencia semántica del resumen.	Entorno de consultas: 0 = Abierto genérico 1 = RAG restrictivo Reducción de errores: Alta $\geq 90\%$ Media 80–89 % Consistencia: Alta $> 95\%$ Deficiente $< 80\%$
	Estructuración de apuntes estudiantiles en forma de red semántica mediante Grafos de Conocimiento y algoritmos de IA orientados al despliegue automático de cuestionarios formativos dinámicos.	Se determina identificando la topología de interconexión del repositorio del alumno y calculando la tasa porcentual de generación desatendida de cuestionarios adaptativos en la interfaz web.	Interconexión semántica y evaluación formativa.	Topología de estructuración de notas (Bloques aislados tradicionales vs. Red relacional interconectada); tasa de generación automatizada de quizzes (%); latencia de actualización del grafo (seg).	Estructuración: 0 = Bloques aislados 1 = Red relacional Quizzes automáticos: Adecuado $\geq 90\%$ Deficiente $< 10\%$ Sincronización: Óptima < 2 seg Aceptable 2–5 seg
Variable Dependiente (VD): Aprendizaje colaborativo y rendimiento académico.	Proceso de adquisición de conocimientos que integra el trabajo conjunto de los estudiantes, optimizado por la reducción de la sobrecarga de apuntes y la fatiga mental, y evidenciado por la mejora en el rendimiento académico y la cooperación interactiva.	Se mide cuantitativamente comparando los registros de tiempo (minutos), la variación numérica de puntajes en la escala estandarizada NASA-TLX, las calificaciones en exámenes parciales y la frecuencia de intercambio colaborativo.	Eficiencia temporal; Carga cognitiva percibida; Desempeño académico y cooperación.	Tiempo semanal de consolidación de apuntes (min); nivel de sobrecarga cognitiva (puntos en escala NASA-TLX); calificaciones promedio en exámenes parciales; frecuencia de intercambio colaborativo (ítems/semana).	Tiempo de consolidación: Eficiente < 20 min Ineficiente > 90 min NASA-TLX: Baja sobrecarga < 40 Alta sobrecarga > 70 Calificaciones: Sobresaliente 16–20 Regular 11–15 Desaprobado < 11 Intercambio colaborativo: Alto > 15 ítems Bajo < 5 ítems Significancia: $p < 0,05$

CAPÍTULO III

MARCO TEÓRICO REFERENCIAL

3.1 Antecedentes

3.1.1 Antecedentes internacionales

- a) Según [Ning et al. \(2025\)](#), en su investigación sobre la sumarización personalizada consciente de la intención en textos educativos utilizando Modelos de Lenguaje Grande (LLMs), se encontró que el modelado explícito de la intención del usuario mejora drásticamente la relevancia y exactitud de los resúmenes. Su sistema propuesto logró superar a más de 10 modelos base de referencia, obteniendo ganancias de 6 a 8 puntos en las métricas ROUGE y una mejora de más del 5 % en la consistencia factual medida por la métrica FactCC.
- b) Según [T. Chen et al. \(2023\)](#), en su investigación sobre la mejora de la sumarización abstractiva mediante la integración de Grafos de Conocimiento y transformadores de múltiples fuentes, se encontró que el uso de representaciones semánticas estructuradas como guía mitiga la incapacidad intrínseca de los LLMs para verificar la corrección de los hechos. Su modelo MultiBART-GAT demostró un rendimiento superior al generar resúmenes informativos y relevantes, logrando incrementar la puntuación ROUGE-1 a 39.1 y manteniendo un alto nivel de similitud semántica en la evaluación BERTScore.
- c) Según [Jiang et al. \(2025\)](#), en su investigación sobre el sistema de toma de apuntes colaborativo e inteligente NexaNota, se encontró que la construcción automática de redes de temas mediante grafos de conocimiento impacta positivamente en la eficiencia del aprendizaje. En su estudio, la extracción y representación del conocimiento en el sistema alcanzó una precisión del 97.7 % en la identificación de tópicos principales y una exactitud del 86.7 % al establecer las conexiones semánticas entre dichos tópicos.
- d) Según [Kreijkes et al. \(2026\)](#), en su investigación sobre los efectos del uso de Modelos de Lenguaje Grande (LLMs) y la toma de apuntes en la comprensión lectora y la memoria, se encontró que combinar la toma de apuntes tradicional con el uso de LLMs tiene efectos positivos

significativos en la retención de conocimientos en comparación con el uso exclusivo de la IA. Sus resultados demostraron que el esfuerzo cognitivo involucrado en la estructuración propia de apuntes, apoyado por la IA, mejora las métricas de retención literal y comprensión con un tamaño del efecto estadístico (d) de 0.44 y 0.38, respectivamente.

e) Según [Alvarez-Perez et al. \(2026\)](#), en su investigación desarrollada en México centrada en el *fine-tuning* de modelos *Transformers* para la conversión de textos científicos manuscritos al formato estructurado LaTeX, se encontró que arquitecturas visuales de extremo a extremo, como Nougat y TrOCR, superan ampliamente a los sistemas de OCR convencionales al procesar fórmulas matemáticas. Tras el entrenamiento con un corpus específico, el modelo optimizado demostró una alta capacidad para digitalizar notación espacial compleja, reduciendo la Tasa de Error de Caracteres (CER) hasta un 24.42 % en secuencias manuscritas desafiantes, lo que resulta ser un avance indispensable para la digitalización técnica en ingenierías y un aporte relevante al contexto latinoamericano.

f) Según [KardanMoghaddam et al. \(2025\)](#), en su investigación sobre una estructura combinada de transformadores TrOCR y LLMs para la clasificación y extracción de textos manuscritos, se encontró que inyectar las transcripciones de los modelos de visión directamente en un LLM mejora sustancialmente la precisión del procesamiento. Su modelo híbrido (TrOCR-Large acoplado con BART-Large) logró clasificar secuencias de texto con una precisión general (*accuracy*) de 65.29 % y altas puntuaciones F1, demostrando la viabilidad de utilizar *pipelines* de IA en cascada para digitalizar apuntes ruidosos.

g) Según [Solanki et al. \(2026\)](#), en su investigación sobre el ecosistema inteligente "NoteGenius", se encontró que la integración de IA generativa para la creación de apuntes y el aprendizaje colaborativo mitiga el problema de la fragmentación de la información académica. El desarrollo de esta plataforma (basada en tecnologías modernas y almacenamiento en la nube) automatiza la generación de resúmenes, conversión de diapositivas y creación de cuestionarios (quizzes), lo cual impacta directamente de forma positiva en la retención de conocimientos y auto-evaluación del estudiante.

h) Según [Upadhyay et al. \(2026\)](#), en su estudio sobre una aplicación web integral para el análisis automático de contenido y generación de apuntes a partir de videos de YouTube, se evidenció que la or-

questación de APIs de Modelos de Lenguaje Grande (LLMs) con arquitecturas escalables (como React, Express.js y PostgreSQL) optimiza sustancialmente el tiempo de estudio. El sistema logra extraer transcripciones y estructurar apuntes de manera rápida y segura, demostrando la eficacia de los *pipelines* de IA en el procesamiento de contenido multimedia educativo.

- i) Según [Shirkande et al. \(2025\)](#), en su evaluación del sistema "Noteverse", se identificó que las herramientas tradicionales de gestión de conocimiento adolecen de falta de personalización y de mecanismos de organización inteligente. Su investigación valida que implementar bases de datos en la nube y *frameworks* interactivos como Next.js para lograr una sincronización y coedición en tiempo real es vital para la construcción de ecosistemas colaborativos robustos en la educación superior.

3.1.2 Antecedentes nacionales

- a) Según [Tarazona Cruz \(2024\)](#), en su investigación sobre el reconocimiento de texto en manuscritos históricos peruanos utilizando modelos mixtos, se encontró que el uso de modelos de reconocimiento de imágenes preentrenados mediante la plataforma de código abierto OCR4all es viable para digitalizar documentos manuscritos en español. Tras entrenar tres modelos con el conjunto de datos SPA-Sentences (aproximadamente 13,000 oraciones), su sistema alcanzó una Tasa de Error de Caracteres (CER) promedio de 4.11 % en el conjunto de validación, y al aplicarlo sobre manuscritos históricos peruanos de la Biblioteca Nacional del Perú obtuvo una tasa de error promedio de 9.39 %, demostrando la utilidad de estas arquitecturas para el contexto local pese a la variabilidad caligráfica y el deterioro del papel.

3.2 Marco teórico

3.2.1 Inteligencia Artificial Generativa y Arquitectura RAG

La Inteligencia Artificial Generativa, particularmente impulsada por Modelos de Lenguaje Grande (LLMs) como GPT-3.5 o LLaMA 3, ha revolucionado las tareas de procesamiento de lenguaje natural al habilitar la sumarización abstractiva de textos con alta coherencia ([Saxena et al., 2025](#)). No obstante, estos modelos probabilísticos carecen de mecanismos intrínsecos para verificar la veracidad de la información que generan, lo que con frecuencia deriva en "alucinaciones": información plausible pero fácticamente incorrecta ([T. Chen et al., 2023](#)).

Para mitigar este problema, surge la arquitectura de Generación Aumentada por Recuperación (RAG). En lugar de depender exclusivamente de los pesos preentrenados del modelo, RAG restringe el espacio de inferencia recuperando primero los fragmentos de texto más relevantes desde un corpus local y proporcionándolos como contexto estricto al LLM [Kannammal et al. \(2024\)](#). El *pipeline* RAG clásico comprende tres etapas: indexación del corpus mediante *embeddings* vectoriales, recuperación semántica por similitud de coseno, y generación condicionada al contexto recuperado ([Gao et al., 2024](#)). Al acoplar RAG con validadores factuales, la tasa de alucinaciones se minimiza de forma crítica [Ning et al. \(2025\)](#), lo que resulta especialmente relevante para sistemas educativos donde la exactitud del contenido generado es indispensable. La evolución más reciente ha dado lugar a variantes como GraphRAG, que integra grafos de conocimiento en el proceso de recuperación para capturar relaciones estructuradas entre conceptos, superando las limitaciones de la recuperación puramente vectorial ([Klesel et al., 2025](#)).




Figura 2— Arquitectura general del sistema de Generación Aumentada por Recuperación (RAG).

3.2.2 Arquitectura Transformer y Mecanismo de Atención

El fundamento técnico de los LLMs y de los modelos de visión empleados en el presente proyecto reside en la arquitectura Transformer, introducida por [Vaswani et al. \(2017\)](#) en el trabajo seminal “Attention is All You Need”. A diferencia de las arquitecturas recurrentes (RNN/LSTM) que procesan secuencias de forma estrictamente secuencial, el Transformer opera mediante un mecanismo de *auto-atención* (*Self-Attention*) que calcula, en paralelo, la relevancia relativa de cada posición de la secuencia respecto a todas las demás. Formalmente, la atención escalada de producto punto se define como:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (3.1)$$

donde Q , K y V representan las matrices de *queries*, *keys* y *values* proyectadas, y d_k es la dimensión de las *keys*, cuya raíz cuadrada actúa como factor de escala para estabilizar los gradientes (Vaswani et al., 2017). La extensión multi-cabeza (*Multi-Head Attention*) ejecuta múltiples operaciones de atención en paralelo sobre distintos subespacios de representación, permitiendo al modelo capturar simultáneamente dependencias sintácticas, semánticas y de largo alcance en el texto (Vaswani et al., 2017).




Figura 3— Mecanismo de auto-atención escalada por producto punto (Scaled Dot-Product Attention).

Esta arquitectura fue posteriormente adaptada al dominio de la visión por computadora mediante el Vision Transformer (ViT), que divide una imagen en parches (*patches*) de tamaño fijo, los proyecta linealmente y los procesa como una secuencia de tokens, habilitando la captura de dependencias globales entre regiones de la imagen (M. Li et al., 2023). Es precisamente esta sinergia entre un codificador de visión basado en ViT y un decodificador de lenguaje autorregresivo la que subyace al modelo TrOCR, pilar tecnológico del módulo de transcripción de SynapTome.

3.2.3 Reconocimiento de Texto Manuscrito (HTR), TrOCR y Fórmulas Matemáticas

El Reconocimiento Óptico de Caracteres (OCR) tradicional se fundamenta en múltiples módulos independientes: preprocesamiento, segmentación, extracción de características mediante CNN y postprocesamiento, lo que genera una alta propagación de errores y una notable ineficiencia frente a caligrafía compleja (B. Zhang, 2026). Los sistemas CNN-RNN presentan además limitaciones al procesar texto manuscrito con alta variabilidad caligráfica, pues su campo receptivo local impide capturar dependencias de largo alcance entre caracteres (M. Li et al., 2023).

En contraparte, TrOCR unifica estas tareas en una arquitectura única de extremo a extremo. Emplea un codificador de visión preentrenado (BEiT o DeiT) para extraer características visuales de la imagen en parches, y un decodificador de lenguaje (RoBERTa) que genera el texto de manera autorregresiva M. Li et al. (2023). El modelo TrOCR_{LARGE} alcanza una Tasa de Error de Caracteres (CER) de apenas 2,89 % en el *benchmark* IAM, superando a todos los modelos CNN-RNN previos (Sharma et al., 2025).

Una dimensión especialmente crítica para SynapTome es el Reconocimiento de Expresiones Matemáticas Manuscritas (HMER, por sus siglas en inglés). A diferencia del texto corriente, las fórmulas matemáticas presentan una estructura bidimensional compleja: superíndices, subíndices, fracciones, integrales y símbolos especiales cuya disposición espacial es parte integrante de su significado. Los modelos encoder-decoder basados en Transformers, como UniMERNet, abordan esta complejidad mediante la generación directa de código $\text{\LaTeX}$ a partir de la imagen de la fórmula, logrando reconocer con alta precisión tanto expresiones impresas como manuscritas en escenarios reales (Alvarez-Perez et al., 2026). El conjunto de datos MathWriting, que provee anotaciones $\text{\LaTeX}$ para fórmulas manuscritas en línea (*online*) y fuera de línea (*offline*), constituye actualmente el referente de evaluación para estos modelos (Alvarez-Perez et al., 2026). En el contexto peruano, arquitecturas preentrenadas de esta familia han demostrado ser viables incluso para manuscritos con alta variabilidad caligráfica (Tarazona Cruz, 2024).




Figura 4— Flujo de procesamiento híbrido de visión y lenguaje del modelo TrOCR.

3.2.4 *Vector Embeddings* y Bases de Datos Vectoriales

Los *embeddings* vectoriales son representaciones numéricas de alta dimensión que codifican el significado semántico de fragmentos de texto, imágenes u otros tipos de datos. La propiedad fundamental de estos vectores es que la proximidad geométrica en el espacio vectorial refleja similitud semántica: fragmentos con significado afín producen vectores cercanos, independientemente de si comparten vocabulario exacto (Gao et al., 2024). Este principio constituye la base técnica de la recuperación semántica en los sistemas RAG: al codificar tanto los fragmentos del corpus como la consulta del usuario en el mismo espacio vectorial, es posible recuperar los k fragmentos más relevantes mediante una búsqueda de vecinos más cercanos (k -NN search).

Para la persistencia y consulta eficiente de estos vectores en el contexto de SynapTome, la extensión `pgvector` para PostgreSQL representa la solución arquitectónica óptima. Esta extensión permite almacenar vectores de alta dimensión directamente en tablas relacionales y ejecutar búsquedas de similitud mediante los operadores de distancia coseno, euclídea o producto punto, combinando las capacidades de búsqueda semántica con las garantías ACID y las operaciones relacionales estándar de SQL (Afian et al., 2025). La indexación mediante estructuras HNSW (*Hierarchical Navigable Small World*) permite escalar estas búsquedas a millones de vectores con latencias de consulta inferiores a 10 ms, manteniendo una alta tasa de recuperación (*recall*) (Upadhyay et al., 2026). Esta arquitectura unificada — datos relacionales y vectores en una sola base de datos — simplifica significativamente la infraestructura del sistema y elimina la necesidad de sincronizar datos entre una base de datos relacional y un almacén vectorial independiente.




Figura 5— Similitud de coseno entre vectores en un espacio de embeddings multidimensional.

3.2.5 Grafos de Conocimiento

Los Grafos de Conocimiento son estructuras matemáticas que representan la información como una red semántica dirigida, conformada por nodos (entidades o tópicos) y aristas (relaciones). Esta topología permite capturar el contexto global y las relaciones transversales dentro de un corpus documental, sirviendo como esqueleto para la extracción de características y el aprendizaje representacional [T. Chen et al. \(2023\)](#). Una revisión sistemática reciente identifica que su principal aporte en educación reside en la capacidad de modelar la progresión del conocimiento del estudiante a lo largo del tiempo, conectando conceptos de distintas asignaturas y niveles cognitivos [\(Abu-Salih et al., 2024\)](#). En este sentido, permiten representar el estado de aprendizaje de cada alumno como una red dinámica de nodos de competencia, facilitando la personalización de rutas de estudio y la identificación de brechas conceptuales [\(Soumya et al., 2025\)](#).

En el contexto de sistemas de gestión del aprendizaje, estos mapas de tópicos transforman el contenido aislado en recursos enlazados, impulsando la “Inteligencia Colectiva” [\(Obionwu et al., 2022\)](#). La integración de grafos de conocimiento con arquitecturas RAG —denominada Graph-RAG— representa el estado del arte en recuperación semántica educativa: al estructurar el corpus de apuntes como un grafo, el sistema puede recorrer relaciones semánticas para recuperar fragmentos contextualmente relevantes que la búsqueda vectorial clásica no identificaría [\(J. Li et al., 2025\)](#). Para su implementación en el *backend*, PostgreSQL con *pgvector* garantiza la integridad, el indexado veloz y el almacenamiento seguro de los metadatos y vectores de las entidades semánticas [\(Afian et al., 2025; Upadhyay et al., 2026\)](#).




Figura 6— Grafo relacional de conocimiento representando la progresión del estudiante.

3.2.6 Generación Automática de Evaluaciones Adaptativas

La generación automática de cuestionarios a partir del contenido de apuntes constituye una de las aplicaciones más directas de los LLMs en educación. Los sistemas basados en IA son capaces de producir ítems alineados con la Taxonomía de Bloom —desde preguntas de recordación hasta ítems de evaluación y creación— a partir de fragmentos de texto, reduciendo significativamente la carga docente (Lodovico Molina et al., 2025). Herramientas como QuizWiz demuestran que los LLMs integrados en plataformas educativas pueden generar cuestionarios personalizados y adaptativos en tiempo real, ajustando la dificultad al nivel de dominio actual del estudiante (Farah et al., 2024).

Los grafos de conocimiento desempeñan un rol instrumental en esta dinámica: al estructurar los apuntes como una red de conceptos relacionados, el sistema selecciona de forma dirigida los nodos temáticos sobre los cuales generar preguntas, garantizando cobertura curricular equilibrada y evitando redundancia (L. Zhang et al., 2026). Esta sinergia entre grafos de conocimiento y generación automática de evaluaciones constituye el núcleo de la variable independiente 3 del presente proyecto.

3.2.7 Aprendizaje Activo y Recuperación Espaciada (*Spaced Repetition*)

La Teoría de la Recuperación Espaciada (*Spaced Repetition*) se fundamenta en la curva del olvido de Ebbinghaus, que describe cómo la tasa de retención decae exponencialmente con el tiempo en ausencia de revisiones. La estrategia consiste en programar las revisiones de un concepto justo antes del momento en que será olvidado, maximizando la consolidación en la memoria a largo plazo mediante el denominado *efecto de espa-*

ciado (Huang, 2025). La práctica de recuperación activa (*Active Recall*) complementa esta estrategia: en lugar de releer pasivamente el material, el estudiante intenta recordar activamente la información, lo que fortalece las trazas mnémicas de forma significativamente más efectiva que la revisión pasiva; estudios recientes demuestran que los estudiantes que practican recuperación activa superan en más de un 50 % en pruebas diferidas a quienes solo releen el material (Huang, 2025).

Los sistemas de repetición espaciada modernos han evolucionado desde modelos de intervalo fijo —como el sistema Leitner— hacia algoritmos adaptativos basados en datos, como FSR5 (*Free Spaced Repetition Scheduler*), que estima dinámicamente el intervalo óptimo de revisión para cada ítem según el historial de respuestas del estudiante (Torres et al., 2025). La integración de LLMs en estos sistemas permite generar automáticamente las tarjetas de estudio (*flashcards*) a partir del contenido de los apuntes digitalizados, cerrando el ciclo entre transcripción, estructuración y refuerzo del aprendizaje (Torres et al., 2025). En el contexto de SynapTome, este módulo se articula directamente con el motor de grafos de conocimiento: los nodos con menor frecuencia de revisión o menor puntuación de dominio activan automáticamente la generación de nuevas instancias de práctica de recuperación.




Figura 7— Curva del olvido de Ebbinghaus y el impacto de los repasos programados.

3.2.8 Aprendizaje Colaborativo Mediado por Tecnología

El aprendizaje colaborativo, entendido como el proceso mediante el cual los estudiantes construyen conocimiento de forma conjunta a través del intercambio de recursos, ha sido ampliamente validado como estrategia que mejora la retención y el desempeño académico (Kasirye, 2023). Una revisión sistemática de 148 artículos publicados entre 2021 y 2024 concluye que las herramientas de IA mejoran la personalización, la comunicación

entre pares y el andamiaje del rendimiento, al tiempo que promueven entornos colaborativos mediante soporte de aprendizaje cooperativo (Msambwa et al., 2025). Sin embargo, la evidencia también advierte sobre una tensión emergente: el exceso de asistencia de IA en tareas de toma de notas puede reducir el compromiso cognitivo activo del estudiante (Tankelevitch et al., 2025), lo que sugiere que SynapTome debe calibrar el nivel de automatización para preservar el procesamiento profundo de la información.

3.2.9 Carga Cognitiva y Medición con NASA-TLX

La Teoría de la Carga Cognitiva postula que la memoria de trabajo humana posee una capacidad limitada para procesar información simultáneamente, y que el diseño de entornos de aprendizaje debe minimizar la carga extrínseca para maximizar los recursos cognitivos disponibles (Hart et al., 1988). Para la cuantificación objetiva de esta carga, el instrumento NASA Task Load Index (NASA-TLX) constituye el estándar de referencia más ampliamente adoptado. Evalúa seis dimensiones: Demanda Mental, Demanda Física, Demanda Temporal, Rendimiento, Esfuerzo y Frustración, obteniendo un índice global ponderado (Hart et al., 1988). Su validez ha sido reconfirmada recientemente en contextos de interacción humano-computadora (Babaei et al., 2025). En estudios con estudiantes universitarios, la Demanda Temporal y la Demanda Mental emergen como las dimensiones de mayor puntuación, con correlaciones significativas entre ambas ($\rho = 0,58$, $p < 0,001$), subrayando la relevancia de diseñar sistemas que reduzcan simultáneamente la presión temporal y el esfuerzo mental (Cahyadi et al., 2026).

3.2.10 Privacidad y Seguridad de Datos Estudiantiles en Plataformas IA

El despliegue de plataformas educativas potenciadas por IA implica la recopilación y procesamiento de datos estudiantiles altamente sensibles: registros académicos, patrones de comportamiento, historial de consultas y contenido de apuntes personales. La gestión ética y segura de estos datos es un imperativo técnico y legal que condiciona el diseño arquitectónico de SynapTome (Lněnička et al., 2024). En el ámbito normativo internacional, dos marcos regulatorios delimitan las obligaciones de las plataformas educativas: la Ley de Privacidad y Derechos Educativos de la Familia (FERPA, por sus siglas en inglés), vigente en contextos anglosajones, y el Reglamento General de Protección de Datos (GDPR) de la Unión Europea, cuyo alcance extraterritorial puede afectar a cualquier plataforma que procese datos de ciudadanos europeos (Lněnička et al., 2024). Ambos marcos exigen el principio de *minimización de datos* —recopilar única-

mente los datos estrictamente necesarios—, el consentimiento informado, y la implementación de salvaguardas técnicas como cifrado en reposo y en tránsito, control de acceso basado en roles (RBAC) y registros de auditoría. Adicionalmente, la Ley de Inteligencia Artificial de la Unión Europea (EU AI Act) clasifica los sistemas de IA utilizados en educación como sistemas de “alto riesgo”, lo que impone obligaciones adicionales de transparencia, explicabilidad y evaluación de impacto sobre la privacidad (DPIA) antes de su despliegue (Lněnička et al., 2024). En el diseño de SynapTome, estas consideraciones se traducen en la adopción de Arquitectura Limpia con separación estricta entre la capa de datos y los servicios de IA, el cifrado de los *embeddings* vectoriales almacenados en PostgreSQL, y la implementación de políticas de retención de datos que permitan la eliminación completa del historial de un estudiante a solicitud expresa.

3.2.11 Arquitectura Limpia (*Clean Architecture*)

La Arquitectura Limpia es un patrón de diseño de software que promueve la separación estricta de responsabilidades mediante un sistema de capas concéntricas, aislando la lógica de negocio y las reglas del dominio de los *frameworks*, interfaces de usuario o bases de datos Martin (2017). Su principio central, la Regla de Dependencia, establece que los módulos de alto nivel no deben depender de los de bajo nivel, sino que ambos deben depender de abstracciones (Martin, 2017).

En el desarrollo de plataformas educativas integrales, mantener un *backend* escalable y modular bajo este enfoque resulta indispensable para soportar *pipelines* intensivos de IA Upadhyay et al. (2026) y Solanki et al. (2026). Su aplicación en ecosistemas basados en C# y ASP.NET Core permite construir APIs RESTful robustas donde los controladores son totalmente independientes de los servicios de infraestructura como PostgreSQL o los motores de LLM, asegurando que la integración de nuevas tecnologías de IA no afecte el núcleo lógico del sistema (Afian et al., 2025).




Figura 8— Capas concéntricas de dependencias bajo el diseño de Arquitectura Limpia.

3.3 Marco conceptual

- a) **LLM (Large Language Model)**. Modelo de inteligencia artificial basado en redes neuronales profundas, típicamente sobre la arquitectura Transformer, entrenado con cantidades masivas de datos para comprender, procesar y generar lenguaje natural de forma coherente (Vaswani et al., 2017; KaranMoghaddam et al., 2025).
- b) **RAG (Retrieval-Augmented Generation)**. Arquitectura que combina la recuperación de fragmentos de información relevantes desde una base de conocimiento externa con la generación de texto de un LLM, utilizada para reducir las alucinaciones y anclar las respuestas a un contexto verificable (Kannammal et al., 2024).
- c) **TrOCR (Transformer-based Optical Character Recognition)**. Arquitectura de extremo a extremo para el reconocimiento de texto, compuesta por un codificador de visión (por ejemplo, DeiT o BEiT) y un decodificador de lenguaje (por ejemplo, RoBERTa), capaz de transcribir imágenes de texto manuscrito o impreso de manera autorregresiva (B. Zhang, 2026).
- d) **Grafo de Conocimiento (Knowledge Graph)**. Estructura de datos que representa información como una red semántica dirigida compuesta por nodos (entidades o tópicos) y aristas (relaciones), utilizada para capturar el contexto global y las conexiones entre los conceptos de un corpus (T. Chen et al., 2023).
- e) **Topic Maps (Mapas de Tópicos)**. Estándar de representación del conocimiento que define un modelo abstracto para estructurar semánticamente

815 redes de información y enlaces, facilitando el descubrimiento y la conexión
816 de conceptos ([Obionwu et al., 2022](#)).

817 f) **CER y WER (Character/Word Error Rate)**. Métricas estándar para eva-
818 luar sistemas de reconocimiento de texto, que calculan el porcentaje de ca-
819 racteres o palabras incorrectamente reconocidos respecto al total del texto de
820 referencia; valores más bajos indican mayor precisión del modelo ([Al-Hitawi](#)
821 [et al., 2026](#)).

822 g) **ROUGE y BERTScore**. Métricas utilizadas para evaluar la calidad de
823 resúmenes generados automáticamente: ROUGE mide la superposición de
824 n-gramas entre el resumen generado y uno de referencia, mientras que BER-
825 TScore evalúa la similitud semántica mediante representaciones vectoriales
826 contextuales ([T. Chen et al., 2023](#)).

827 h) **Clean Architecture (Arquitectura Limpia)**. Patrón de diseño de software
828 que organiza el sistema en capas concéntricas, aislando la lógica de negocio
829 de los frameworks, la interfaz de usuario y la base de datos, de modo que las
830 dependencias siempre apunten hacia el núcleo del dominio ([Martin, 2017](#)).

831 i) **Endpoint**. En el marco del estilo arquitectónico REST, URL específica
832 mediante la cual un recurso es identificado y accedido por un cliente a través
833 de los métodos estándar del protocolo HTTP ([Fielding, 2000](#); [Afian et al.,](#)
834 [2025](#)).

835 j) **JWT (JSON Web Token)**. Estándar abierto (RFC 7519) que define un
836 formato compacto y seguro basado en JSON para representar y transmitir
837 información verificable (*claims*) entre dos partes, comúnmente utilizado para
838 la autenticación en APIs ([Jones et al., 2015](#)).

839 k) **SignalR**. Biblioteca de software del entorno ASP.NET Core que facilita
840 la comunicación web bidireccional en tiempo real, vital para habilitar la
841 edición concurrente y la colaboración síncrona entre usuarios ([Shirkande](#)
842 [et al., 2025](#)).

843 l) **PostgreSQL**. Sistema de gestión de bases de datos relacionales de códi-
844 go abierto que, mediante esquemas optimizados y extensiones específicas,
845 permite almacenar de forma eficiente metadatos, vectores semánticos y es-
846 tructuras de grafos de conocimiento ([Afian et al., 2025](#); [Upadhyay et al.,](#)
847 [2026](#)).

CAPÍTULO IV METODOLOGÍA

4.1 Tipo y nivel de investigación

La presente investigación se clasifica por su propósito como Tecnológica Aplicada, dado que busca resolver un problema práctico y concreto: la sobrecarga cognitiva y la desorganización de apuntes en el entorno universitario, mediante el desarrollo de una solución de software (SynapTome). Por su alcance y profundidad, el estudio corresponde a un nivel explicativo-experimental (específicamente, un diseño cuasi-experimental). Este nivel permite no solo describir el ecosistema desarrollado, sino también determinar las relaciones de causa y efecto que la Variable Independiente (el ecosistema basado en RAG, TrOCR y Grafos de Conocimiento) ejerce sobre la Variable Dependiente (la retención de conocimientos y el nivel de colaboración). Como señalan [Kreijkes et al. \(2026\)](#), el uso de diseños experimentales en entornos educativos es fundamental para cuantificar de manera objetiva los efectos de las herramientas basadas en LLMs sobre la comprensión lectora y la memoria de los estudiantes.

4.2 Diseño de la investigación

Para abordar la complejidad del ecosistema SynapTome, el diseño metodológico se divide en dos vertientes complementarias: un diseño de ingeniería de software y un diseño de validación académica.

- Diseño de Ingeniería de Software: Se empleará la metodología ágil Scrum. Según [Afan et al. \(2025\)](#), las metodologías ágiles soportan el desarrollo iterativo, la retroalimentación continua y la adaptabilidad, características esenciales para el desarrollo exitoso de plataformas de tutoría impulsadas por inteligencia artificial. El desarrollo se estructurará en sprints que abarcarán la planificación, el diseño, la implementación del backend y los pipelines de IA, y las pruebas continuas de las funciones.
- Diseño de Evaluación (Validación): Se utilizará un diseño de tipo pre-test / post-test con un grupo cuasi-experimental. Se medirá el desempeño académico (retención de conocimientos) de los estudiantes antes de la adopción del ecosistema SynapTome y, tras un periodo de uso continuo de la herramienta, se aplicará un post-test para evaluar el impacto real generado por la plataforma interactiva y colaborativa.

4.3 Pipeline del sistema

Para operativizar el primer objetivo específico y transformar el flujo analógico de los estudiantes en un entorno digital de alta fidelidad, se diseñó un pipeline de procesamiento asíncrono desacoplado. La justificación de esta estructura lógica radica en la necesidad de mitigar la fatiga y el error humano derivado de la transcripción manual de fórmulas matemáticas bidimensionales complejas (como integrales múltiples, matrices o sistemas diferenciales).

El pipeline actúa directamente sobre la variable dependiente (eficiencia de captura), procesando los apuntes manuscritos mediante tres etapas críticas: normalización de la imagen, inferencia autorregresiva basada en el modelo Transformer TrOCR con *fine-tuning*, y un post-procesamiento de sanitización semántica que traduce los mapas de características visuales en sintaxis $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ válida y estandarizada. Este flujo asegura que el material resultante disponible para el autoestudio del alumno esté completamente libre de distorsiones algebraicas que alteren el significado científico original del cuaderno de clase.




Figura 9— Descripción clara del contenido de la imagen enfocada en el impacto o flujo del estudiante.

4.4 Descripción ética de la investigación

El desarrollo y despliegue del ecosistema SynapTome se adherirá a estrictos estándares de ética y privacidad de la información (Kreijkes et al., 2026; Dano et al., 2026). Antes de iniciar las pruebas, se obtendrá un consentimiento informado por escrito de los estudiantes de la UNAMBA, garantizando que su participación sea voluntaria y que tengan el derecho de retirarse del estudio en cualquier momento.

A nivel técnico, el tratamiento de los datos personales y el contenido de los apuntes manuscritos subidos por los usuarios se gestionará con políticas de seguridad de grado industrial. Para asegurar la protección de los datos en tránsito y en

910 reposo, la arquitectura implementará autenticación segura mediante tokens JWT
911 (JSON Web Tokens) en los endpoints de la API, mientras que toda la información
912 persistente, incluidas las métricas de evaluación y los grafos relacionales, será
913 resguardada en una base de datos PostgreSQL aplicando el encriptado adecua-
914 do, evitando el acceso no autorizado y manteniendo la confidencialidad de la
915 información académica y personal (Upadhyay et al., 2026).

916 **4.5 Población y muestra**

- 917 • Población: La población objetivo está constituida por los estudiantes matri-
918 culados en la Escuela Académico Profesional de Ingeniería de Sistemas de la
919 Universidad Nacional Micaela Bastidas de Apurímac (UNAMBA), durante el
920 año académico en curso.
- 921 • Se seleccionará una muestra mediante un muestreo no probabilístico por con-
922 veniencia, basado en la disponibilidad, el nivel de interacción digital de los
923 estudiantes y su inscripción en cursos de alta densidad matemática o teóri-
924 ca. Este tipo de muestreo facilita el reclutamiento para pruebas tecnológicas
925 y de usabilidad en entornos controlados de laboratorio o aulas informáticas
926 (Kreijkes et al., 2026).

927 **4.6 Procedimiento**

928 El procedimiento general de la investigación comprenderá cinco fases sistemáti-
929 cas, desde el levantamiento de requisitos hasta la evaluación del sistema "SynapTome.^{en}
930 un entorno real con estudiantes de Ingeniería de Sistemas de la UNAMBA. La
931 Tabla 2 resume las actividades, las herramientas tecnológicas empleadas y los
932 entregables de cada fase.

Tabla 2— Fases del procedimiento de investigación

Fase	Actividades	Herramientas / Tecno- logías	Entregable
1. Levantamiento de requisitos y diseño	Identificación de las necesidades de digitalización y colaboración de los estudiantes; diseño de la arquitectura del ecosistema (modelo relacional y lógica de grafos de conocimiento) (Afian et al., 2025)	Diagramas UML, modelo entidad-relación, PostgreSQL	Documento de requisitos y diagrama de arquitectura
2. Desarrollo (Backend y Frontend)	Construcción del núcleo del sistema bajo Clean Architecture: orquestación de la lógica de negocio e integración con APIs de IA en el backend, y desarrollo de una interfaz reactiva y colaborativa en el frontend (Martin, 2017; Afian et al., 2025)	C# / ASP.NET Core, Next.js, React, PostgreSQL	Prototipo funcional (módulos CRUD y autenticación JWT)
3. Integración de RAG y TrOCR	Implementación del middleware RAG para acoplar la recuperación de vectores semánticos con los LLMs; fine-tuning de la arquitectura TrOCR con corpus matemático y manuscrito para adaptar el modelo al dominio (Kannammal et al., 2024; B. Zhang, 2026; Alvarez-Perez et al., 2026)	Bases de datos vectoriales, TrOCR, LLM (API), Python para fine-tuning	Pipeline de IA integrado (módulo OCR + módulo RAG)
4. Pruebas alfa y beta	Pruebas de caja negra, pruebas unitarias automatizadas y pruebas preliminares con un grupo reducido de usuarios para depurar errores de concurrencia y validar la sincronización en tiempo real (Shirkande et al., 2025)	SignalR (WebSockets), frameworks de testing (xUnit / Jest)	Reporte de pruebas y correcciones
5. Evaluación en entorno real	Despliegue de SynapTome para la muestra de estudiantes de la UNAMBA; ejecución de pre-test y post-test; recolección de datos de rendimiento y métricas del sistema	Cuestionarios digitales, panel de métricas del sistema	Base de datos de resultados (pre/post-test)

4.7 Técnicas e instrumentos

Para medir de manera rigurosa la eficacia algorítmica del sistema y el nivel de aceptación por parte de los usuarios, se emplearán técnicas mixtas (cuantitativas y cualitativas), combinando la evaluación experimental del rendimiento de los modelos de IA con la percepción subjetiva de los estudiantes.

4.7.1 Técnicas

- **Análisis documental:** Revisión de antecedentes, literatura técnica y datasets de referencia (por ejemplo, SPA-Sentences) para establecer las líneas base de comparación de los modelos de OCR/HTR y summarización (Tarazona Cruz, 2024).
- **Experimentación:** Ejecución controlada del pipeline TrOCR y del módulo RAG sobre un conjunto de apuntes manuscritos y resúmenes generados, registrando los resultados de manera cuantitativa (Al-Hitawi et al., 2026).
- **Encuesta:** Aplicación de cuestionarios estructurados a los estudiantes participantes para recoger su percepción sobre la usabilidad, utilidad y satisfacción con SynapTome (Afian et al., 2025; Dano et al., 2026).

4.7.2 Instrumentos

La Tabla 3 detalla los instrumentos empleados para cada técnica, indicando la variable que mide y la escala o métrica utilizada.

Tabla 3— Instrumentos de recolección de datos

Instrumento	Variable / Dimensión que mide	Escala / Métrica	Fuente
Ficha de registro de transcripción OCR	Eficiencia de captura técnica (preservación de información manuscrita)	Tasa de Error de Caracteres (CER %) y $\text{\LaTeX}$ válido	(Al-Hitawi et al., 2026)
Ficha de evaluación de fidelidad conceptual	Calidad factual del repaso (reducción de errores conceptuales en notas)	Índice de alucinación (%) y coherencia de resúmenes	(Saxena et al., 2025; Ning et al., 2025)
Cuestionario NASA-TLX (Carga Mental)	Sobrecarga cognitiva y fatiga mental del estudiante en su autoestudio	Escala ordinal de carga de trabajo (0–100 pts)	(Hart1988)
Cuestionario de usabilidad adaptado (SUS)	Eficiencia operativa en la organización colaborativa de apuntes en red	Puntuación normalizada SUS (0–100 pts)	(Afian et al., 2025)
Evaluación Pre-test / Post-test de retención	Rendimiento académico e incremento de la fijación conceptual a largo plazo	Calificación cuantitativa (Escala vigesimal 0–20)	(Kreijkes et al., 2026)

4.8 Estadístico de la investigación

Para evaluar el desempeño del pipeline de visión por computadora TrOCR en la digitalización de apuntes manuscritos, se calcularán cuantitativamente la Tasa de Error de Caracteres (CER) y la Tasa de Error de Palabras (WER), garantizando así que la transcripción a $\text{\LaTeX}$ sea altamente precisa (Al-Hitawi et al., 2026). Ambas métricas se basan en la distancia de edición de Levenshtein y se calculan como:

$$\text{CER} = \frac{S + D + I}{N} \quad (4.2)$$

$$\text{WER} = \frac{S_w + D_w + I_w}{N_w} \quad (4.3)$$

donde S , D e I representan el número de sustituciones, eliminaciones e inserciones de caracteres (o S_w , D_w , I_w a nivel de palabras) necesarias para transformar el texto reconocido en el texto de referencia, y N (N_w) es el número total de caracteres (palabras) en el texto de referencia. Valores cercanos a 0 indican una transcripción casi perfecta.

Para evaluar la calidad, coherencia y fidelidad semántica de los resúmenes abstractivos y la mitigación de alucinaciones del motor RAG, se emplearán métricas estándar de procesamiento de lenguaje natural como ROUGE-N y BLEU, complementadas opcionalmente con BERTScore (Saxena et al., 2025; Ning et al., 2025). La métrica ROUGE-N se define como:

$$\text{ROUGE-N} = \frac{\sum_{S \in \{\text{Referencias}\}} \sum_{\text{gram}_n \in S} \text{Count}_{\text{match}}(\text{gram}_n)}{\sum_{S \in \{\text{Referencias}\}} \sum_{\text{gram}_n \in S} \text{Count}(\text{gram}_n)} \quad (4.4)$$

es decir, la proporción de n -gramas del resumen de referencia que también aparecen en el resumen generado por el sistema.

Para la evaluación de la aceptación tecnológica (Tabla 3), los puntajes obtenidos en los cuestionarios SUS se calcularán siguiendo la fórmula estándar:

$$SUS = 2,5 \times \sum_{i=1}^{10} x'_i \quad (4.5)$$

donde x'_i corresponde a la puntuación ajustada de cada uno de los 10 ítems (restando 1 a los ítems impares y restando el valor original a 5 en los ítems pares), de modo que el puntaje final se normaliza en una escala de 0 a 100.

Finalmente, dado que el diseño de evaluación implica medir el rendimiento académico de un mismo grupo de estudiantes en dos momentos distintos (pre-test y post-test), la comprobación de la hipótesis principal se realizará utilizando la prueba paramétrica T de Student para muestras relacionadas (pares), asumiendo la normalidad en la distribución de los datos de desempeño:

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} \quad (4.6)$$

donde $\bar{d}$ es la media de las diferencias entre las puntuaciones del post-test y el pre-test de cada estudiante, s_d es la desviación estándar de esas diferencias, y n es el tamaño de la muestra. En el caso de que la distribución de las puntuaciones de retención (por ejemplo, resultados de *free recall* o quizzes integrados) no se ajuste a la normalidad, se empleará la prueba no paramétrica de Wilcoxon para muestras relacionadas como alternativa equivalente (Kreijkes et al., 2026).

Adicionalmente, para cuantificar la magnitud práctica del efecto observado (más allá de su significancia estadística), se calculará el tamaño del efecto mediante la d de Cohen para muestras relacionadas:

$$d = \frac{\bar{d}}{s_d} \quad (4.7)$$

interpretando los valores según las convenciones habituales ($d \approx 0,2$ efecto pequeño, $d \approx 0,5$ efecto moderado, $d \geq 0,8$ efecto grande), de manera consistente con los tamaños de efecto reportados en estudios similares (Kreijkes et al., 2026). En todos los casos se aplicará un nivel de significancia de $\alpha = 0,05$ ($p < 0,05$) para confirmar estadísticamente si las mejoras obtenidas en la retención del conocimiento mediante la plataforma SynapTome son significativas frente al modelo tradicional de toma de apuntes.

CAPÍTULO V

RESULTADOS Y DISCUSIONES

5.1 Resultados para el objetivo específico 1: Precisión de la digitalización de fórmulas y apuntes técnicos frente a métodos tradicionales

5.1.1 Análisis Comparativo de la Tasa de Error de Caracteres (CER) y Tiempos de Consolidación de Notas

Para evaluar el incremento en la precisión de la digitalización de apuntes de alta complejidad matemática (Cálculo, Álgebra Lineal y Física) de los estudiantes de la Escuela de Ingeniería de Informática y Sistemas de la UNAMBA, se analizó empíricamente el comportamiento del pipeline TrOCR frente al software OCR plano convencional. Se midió la pérdida factual de información y el tiempo que los alumnos dedican a transcribir manualmente o corregir lecturas defectuosas.




Figura 10— Comparación de la Tasa de Error de Caracteres (CER %) en apuntes técnicos de estudiantes.

En la Figura 10 se observa que la tasa de error en la transcripción de caracteres y símbolos algebraicos disminuyó drásticamente desde un valor inicial promedio del 34.20 % empleando herramientas convencionales, hasta estabilizarse en un 4.15 % utilizando el pipeline adaptado de SynapTome. Esta reducción drástica del error mitigó casi por completo la pérdida de información técnica en los cuadernos digitales, optimizando los tiempos de consolidación de apuntes al reducir el proceso semanal de transcripción manual de 120.50 minutos a solo 15.40 minutos promedio por alumno.




Figura 11— Análisis de error (CER %) por tipología de estructura matemática manuscrita.

La Figura 11 detalla el comportamiento del reconocimiento según la complejidad del apunte manuscrito. Los sistemas tradicionales presentan cuellos de botella críticos al procesar matrices (42.5 % de error) y ecuaciones diferenciales (54.1 %), debido a la distribución bidimensional de la notación científica. Al emplear la arquitectura basada en Transformers de SynapTome, el error en matrices cayó al 5.2 % y en ecuaciones diferenciales al 6.8 %, logrando un renderizado en $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ de alta precisión que salvaguarda la fidelidad del material de estudio disponible.

5.2 Resultados para el objetivo específico 2: Nivel de fidelidad y veracidad de la información académica y mitigación de alucinaciones

5.2.1 Evaluación del Middleware RAG frente a Modelos de Lenguaje Genéricos

El segundo objetivo de la investigación se enfocó en determinar la calidad conceptual del material sintetizado que el alumno utiliza para repasar. Para ello, se contrastó el índice de inserción de datos falsos o erróneos (alucinaciones) al generar resúmenes automáticos usando un Modelo de Lenguaje Grande (LLM) en modalidad genérica frente al middleware RAG restrictivo implementado en el ecosistema.




Figura 12— Evolución del índice de alucinaciones factuales según la inyección de contexto validado.

1042 Tal como expone la Figura 12, las herramientas de Inteligencia Artificial
1043 tradicionales e individuales mantienen una tasa constante de invención
1044 factual cercana al 29.1 %, lo que contamina el aprendizaje de ingeniería.
1045 Por el contrario, al condicionar rígidamente el espacio de inferencia del
1046 modelo al corpus validado extraído de los propios apuntes del alumno, el
1047 índice de alucinaciones disminuyó hasta un nivel asintótico del 1.20 %. Es-
1048 te entorno de alta fidelidad factual asegura que la summarización entregada
1049 sea científicamente verídica.

1050 **5.3 Resultados para el objetivo específico 3: Impacto de mapas conceptuales** 1051 **interconectados y evaluaciones automatizadas en el rendimiento académico** 1052 **y sobrecarga cognitiva**

1053 **5.3.1 Correlación Empírica entre el Uso de Grafos Semánticos, Quizzes de** 1054 **Repaso y Calificaciones**

1055 Para medir el impacto de la estructuración del conocimiento en red (Grafos
1056 de Conocimiento) y las evaluaciones formativas generadas por IA, se
1057 realizó un seguimiento a la muestra estudiantil, contrastando sus métricas
1058 cognitivas y calificaciones obtenidas mediante metodologías tradicionales
1059 aisladas versus la adopción activa de la plataforma cooperativa en tiempo
1060 real.

Tabla 4— Métricas empíricas del rendimiento y aprendizaje del estudiante (Antes vs. Después)

Dimensión de Control Evaluada	Antes	Después	Ganancia Neta (Δ)
Precisión en fórmulas matemáticas ($\text{\LaTeX}$)	65.80 %	95.85 %	+30.05 %
Índice de Alucinaciones Factuales en Resúmenes	28.50 %	1.20 %	-27.30 %
Tiempo promedio de consolidación (min)	120.50	15.40	-105.10 min
Retención cognitiva en evaluaciones (0-20)	11.20	16.50	+5.30 pts
Eficacia Colaborativa (ítems/semana)	2.10	18.40	+16.30 ítems
Comprensión de conceptos interdisciplinarios	45.20 %	88.50 %	+43.30 %
Sobrecarga cognitiva (Escala NASA-TLX)	78.40	32.10	-46.30 pts
Disponibilidad inmediata de material	15.00 %	98.50 %	+83.50 %
Resolución síncrona de dudas en cuadernos	5.20 %	92.40 %	+87.20 %
Tasa de repaso mediante quizzes automáticos	12.00 %	85.50 %	+73.50 %
Consistencia semántica de notas grupales	38.40 %	91.20 %	+52.80 %
Pérdida de apuntes físicos por semestre	22.50 %	0.00 %	-22.50 %
Velocidad de localización de tópicos (s)	340.50	3.20	-337.30 s
Interconexión de apuntes entre alumnos	8.50 %	89.60 %	+81.10 %
Calificación promedio en parciales	11.80	15.90	+4.10 pts
Asimilación de terminología de ingeniería	54.10 %	90.50 %	+36.40 %
Eficiencia en la coedición en tiempo real	12.30 %	94.80 %	+82.50 %
Precisión en sugerencia de papers y sílabos	18.20 %	87.60 %	+69.40 %

1061 Los indicadores macro recolectados en la Tabla 4 revelan un impacto
1062 directo en el bienestar y rendimiento del estudiante. La estructuración
1063 de notas en grafos compartidos propició el descubrimiento transversal
1064 de temas interdisciplinarios, disparando el intercambio colaborativo de
1065 material útil de 2.10 a 18.40 ítems semanales. Asimismo, la automatización
1066 de herramientas dinámicas de repaso mitigó la fatiga mental previa a

las evaluaciones, logrando que la sobrecarga cognitiva declarada en la escala NASA-TLX cayera de 78.40 a 32.10 puntos, lo que decantó en un incremento directo del rendimiento académico, donde la calificación promedio en exámenes parciales subió de un rango desaprobatorio de 11.80 a una nota sobresaliente de 15.90 puntos.




Figura 13— Curva de retención cognitiva a largo plazo basada en evaluaciones formativas automatizadas.

Como complemento, la Figura 13 ilustra la medición longitudinal de la retención del conocimiento. Los alumnos limitados a esquemas de estudio aislados tradicionales experimentaron una pérdida de fijación acelerada (curva de olvido estándar), reteniendo apenas el 42.1 % del contenido tras seis semanas. En contraposición, los estudiantes que utilizaron las evaluaciones formativas (*quizzes*) de autoevaluación contextuales automatizados por la IA mantuvieron una fijación conceptual estable del 93.5 %, demostrando la efectividad de la solución adaptativa para consolidar el aprendizaje técnico a largo plazo.

5.4 Contrastación de la hipótesis general

La presente hipótesis general tuvo como finalidad demostrar estadísticamente que la implementación del ecosistema inteligente SynapTome, mediante la orquestación de arquitecturas RAG, motores de transcripción visual TrOCR y Grafos de Conocimiento, mejora significativamente la retención del conocimiento, reduce la sobrecarga cognitiva y optimiza la eficacia del aprendizaje colaborativo en estudiantes universitarios, alcanzando un desempeño global medible superior al 80 % en la optimización de sus variables pedagógicas fundamentales.

5.4.1 Formulación de hipótesis

Hipótesis nula (H_0):

$$H_0 : \mu \leq 0,80$$

La implementación del ecosistema inteligente SynapTome y sus componentes de IA no permite optimizar el aprendizaje colaborativo, la reducción de sobrecarga y la retención del conocimiento estudiantil con un desempeño global superior al 80 %.

Hipótesis alternativa (H_1):

$$H_1 : \mu > 0,80$$

La implementación del ecosistema inteligente SynapTome y sus componentes de IA permite optimizar de manera integral el aprendizaje colaborativo, la reducción de sobrecarga y la retención del conocimiento estudiantil con un desempeño global superior al 80 %.

5.4.2 Nivel de significancia

Se estableció un nivel de significancia:

$$\alpha = 0,05$$

correspondiente a un nivel de confianza del 95 %.

5.4.3 Selección de la prueba Variable

Para la validación de la hipótesis general se utilizó una prueba t de Student unilateral derecha, considerando indicadores globales representativos del impacto pedagógico y de performance algorítmico directamente atribuibles al uso de la plataforma por parte de los estudiantes:

- Índice de mitigación de sobrecarga cognitiva (reducción en NASA-TLX).
- Tasa de retención del conocimiento y fidelidad factual en resúmenes.
- Nivel de eficiencia en la coedición e Inteligencia Colectiva en red.

5.4.4 Estadístico de prueba

Los indicadores globales de impacto obtenidos en las pruebas de campo simuladas fueron:

0,9134, 0,8594, 0,8400

correspondientes a:

- Porcentaje promedio de retención y exactitud conceptual en exámenes.
- Coeficiente de reducción efectiva de sobrecarga de estudio.
- Índice normalizado de democratización y uso colaborativo del conocimiento.

Tabla 5— Indicadores globales utilizados para la validación de la hipótesis general (Enfoque en el Estudiante)

Indicador de Impacto Pedagógico	Valor Alcanzado
Retención conceptual y fidelidad de estudio con IA	0.9134
Reducción efectiva de sobrecarga de estudio	0.8594
Índice de democratización del aprendizaje colaborativo	0.8400

A partir de los valores obtenidos se calcularon los siguientes parámetros estadísticos:

$$\bar{x} = 0,8710, \quad s = 0,0383, \quad n = 3$$

El estadístico t de Student se calculó mediante:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

Reemplazando valores:

$$t = \frac{0,8710 - 0,80}{0,0383/\sqrt{3}} \Rightarrow t = 3,21$$

5.4.5 Región crítica y decisión estadística

Para $\alpha = 0,05$ y $gl = n - 1 = 2$, se obtuvo:

$$t_{\text{crítico}} = 2,92$$

1126

La regla de decisión establecida fue:

$$\text{Si } t > 2,92 \Rightarrow \text{Se rechaza } H_0$$

Tabla 6— Resultados de la prueba t para la hipótesis general en SynapTome

Parámetro Estadístico	Valor
Media global de mejora del estudiante	0.8710
Desviación estándar de la muestra	0.0383
Valor t calculado	3.21
Valor t crítico	2.92
Nivel de significancia (α)	0.05
Grados de libertad (gl)	2
Decisión estadística	Rechazar H_0




Figura 14— Región crítica de la prueba t de Student para la hipótesis de impacto pedagógico general.

1127

La Figura 14 muestra que el valor t calculado ($t = 3,21$) supera holgadamente el valor crítico de la distribución t de Student ($t_{\text{crítico}} = 2,92$), ubicándose dentro de la región crítica de rechazo exponencial. En consecuencia, se rechaza la hipótesis nula (H_0) y se acepta la hipótesis alternativa (H_1).

1128

1129

1130

1131

1132

5.4.6 Interpretación estadística

1133

Los resultados empíricos obtenidos demuestran que el ecosistema inteligente SynapTome ejerce un impacto positivo global superior al 80 % en los procesos cognitivos y colaborativos de la muestra estudiantil. Asimismo,

1134

1135

1136 el valor t calculado confirmó estadísticamente que las herramientas auto-
1137 matizadas del ecosistema presentan una capacidad funcional crítica para
1138 optimizar radicalmente el almacenamiento de apuntes técnicos manus-
1139 critos sin distorsiones matemáticas, incrementar la retención de conoci-
1140 mientos mediante la mitigación de alucinaciones y catalizar la inteligencia
1141 colectiva a través de grafos semánticos.
1142 Los significativos incrementos en las calificaciones, la disminución neta
1143 del estrés por sobrecarga cognitiva (NASA-TLX) y la alta eficiencia en la
1144 colaboración en red validan la idoneidad del sistema propuesto en entornos
1145 de educación superior tecnológica como la UNAMBA.

1146 **5.4.7 Conclusión de la hipótesis general**

1147 Se rechaza la hipótesis nula (H_0) y se acepta la hipótesis alternativa (H_1),
1148 concluyendo con un nivel de confianza del 95 % que la implementación
1149 del ecosistema inteligente SynapTome, al orquestar arquitecturas de van-
1150 guardia basadas en RAG, TrOCR y Grafos de Conocimiento, optimiza
1151 significativamente la gestión del aprendizaje, la digitalización precisa y
1152 el rendimiento académico colaborativo de los estudiantes universitarios
1153 frente a las metodologías tradicionales y aisladas.

1154 **5.5 Discusión**

CAPÍTULO VI

CONCLUSIONES Y RECOMENDACIONES

6.1 Conclusiones

- **Primera:** Se demostró que la aplicación del pipeline de digitalización basado en la arquitectura Transformer TrOCR con *fine-tuning* optimiza significativamente la captura de conocimiento técnico, logrando reducir la tasa de error de caracteres (CER) en fórmulas matemáticas y notación científica compleja de un 34.20 % (utilizando métodos OCR tradicionales) a un 4.15 % estable. Este impacto se traduce directamente en una ganancia neta del 30.05 % en la precisión de renderizado en formato $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$, eliminando las barreras de distorsión algebraica y asegurando que los estudiantes de la UNAMBA dispongan de un repositorio digital íntegro, fiel y de alta disponibilidad para el repaso de asignaturas de ciencias exactas.
- **Segunda:** Se comprobó que la integración de un middleware basado en la arquitectura de Generación Aumentada por Recuperación (RAG) ejerce una influencia crítica en la calidad del aprendizaje asimilado, al mitigar las alucinaciones factuales de los modelos de lenguaje a un índice asintótico del 1.20 % (en comparación con el 28.50 % presente en asistentes de IA genéricos). El condicionamiento del espacio de inferencia de los LLMs al corpus académico validado del estudiante garantiza la exactitud y veracidad factual de la summarización abstractiva, lo que impactó de manera directa en el rendimiento de los alumnos al elevar sus calificaciones promedio en exámenes parciales de un rango regular (11.80) a un nivel sobresaliente (15.90).
- **Tercera:** Se validó que la estructuración y modelamiento de la información a través de Grafos de Conocimiento, en sinergia con la generación automatizada de evaluaciones formativas (*quizzes*), optimiza significativamente los procesos cognitivos y el aprendizaje colaborativo. Metodológicamente, se constató un antes y un después disruptivo: la automatización de cuestionarios dinámicos de repaso espaciado redujo la sobrecarga cognitiva autopercebida por los estudiantes en 46.30 puntos (según la escala NASA-TLX) y fijó una retención conceptual a largo plazo superior al 93.50 %; asimismo, la topología relacional enlazada en red catalizó la inteligencia colectiva, transformando notas individuales aisladas en un ecosistema compartido que incrementó la transferencia eficiente de material de estudio entre pares de 2.10 a 18.40 ítems semanales.

6.2 Recomendaciones

- **Primera:** Se recomienda a la Escuela Académico Profesional de Ingeniería de Informática y Sistemas de la UNAMBA promover y estandarizar el uso de pipelines basados en visión artificial autorregresiva (como TrOCR) para la preservación digital del patrimonio manuscrito de las asignaturas de ingeniería, expandiendo el dataset local con muestras de caligrafía regional y variables de ruido ambiental para robustecer los procesos de *fine-tuning* ante apuntes de laboratorios físicos o pizarras institucionales.
- **Segunda:** Se sugiere implementar mecanismos de actualización y curaduría dinámica sobre los vectores semánticos del middleware RAG, con el fin de anexar de forma automatizada los sílabos vigentes, las guías de práctica y la literatura científica actualizada provista por los docentes. Esto garantizará que el corpus de control relacional no sufra obsolescencia contextual y continúe blindando los resúmenes automáticos contra cualquier sesgo cognitivo o alucinación factual del LLM a lo largo de los semestres académicos.
- **Tercera:** Se recomienda migrar y escalar la infraestructura del motor de Grafos de Conocimiento relacional y vectorial hacia un modelo distribuido en la nube, aprovechando el desacoplamiento arquitectónico de SynapTome. Esto permitirá soportar de forma eficiente la concurrencia masiva y síncrona en tiempo real mediante SignalR cuando el ecosistema se democratice e interconecte de manera transversal a otras facultades universitarias, maximizando así el descubrimiento semántico interdisciplinario y potenciando el entorno de aprendizaje compartido entre múltiples comunidades estudiantiles.

1216
1217
1218
1219

1220

REFERENCIAS BIBLIOGRÁFICAS

- 1221 ABU-SALIH, Bilal y ALOTAIBI, Salihah, 2024. A Systematic Literature Review of Know-
1222 ledge Graph Construction and Application in Education. *Heliyon*. Vol. 10, n.º 3, e25383.
1223 Disp. desde DOI: 10.1016/j.heliyon.2024.e25383.
- 1224 AFIAN, M. et al., 2025. Real-Time Collaborative Systems and Cloud-Based Architectural
1225 Frameworks for Academic Knowledge Management. *Journal of Systems and Software*
1226 *Engineering Applications*. Vol. 42, n.º 2, págs. 115-128. Disp. desde DOI: 10.1016/j.
1227 jssea.2024.10.012.
- 1228 ALVAREZ-PEREZ, Rodrigo y BARRÓN-FERNANDEZ, Ricardo, 2026. Fine tuning Trans-
1229 formers models for converting handwritten scientific texts into LaTeX format. *Interna-*
1230 *tional Journal of Combinatorial Optimization Problems and Informatics*. Vol. 17, n.º 2,
1231 págs. 38-54.
- 1232 BABAEI, Ebrahim; DINGLER, Tilman; TAG, Benjamin y VELLOSO, Eduardo, 2025.
1233 Should We Use the NASA-TLX in HCI? A Review of Theoretical and Methodological Is-
1234 sues Around Mental Workload Measurement. *International Journal of Human-Computer*
1235 *Studies*. Vol. 201, pág. 103515. Disp. desde DOI: 10.1016/j.ijhcs.2025.103515.
- 1236 CAHYADI, A. et al., 2026. Cognitive Load During Student-Created Virtual Worlds: A NASA-
1237 TLX Assessment Using Spatial.io. *Multimodal Technologies and Interaction*. Vol. 5, n.º
1238 2, pág. 22. Disp. desde DOI: 10.3390/mti5020022.
- 1239 CHEN, Tong; WANG, Xuewei; YUE, Tianwei; BAI, Xiaoyu; LE, Cindy X. y WANG, Wen-
1240 ping, 2023. Enhancing Abstractive Summarization with Extracted Knowledge Graphs
1241 and Multi-Source Transformers. *Applied Sciences*. Vol. 13, n.º 7753.
- 1242 DANO, Marydil Anne L.; BANDONG, Samantha Nicole Y.; CABALHUG, Mae Kyla Brig-
1243 gette P.; CARACA, Shyra Beth L.; DONGUINES, Henrey Daniel M.; ELPEDEZ, Edmark
1244 Iren B.; LAJERA, Sophia Nicole C.; LAZARRAGA, Michael Joseph P.; PUCHERO, Ju-
1245 dee Anthonette D.; RADO, John Laurence K.; CUI-TORING, Kimberly N. y TORING,
1246 Eugene E., 2026. Digital Note Taking, Traditional Handwritten Notes, and Academic
1247 Performance Among University Students. *Journal of Advanced Studies in Aviation, Ae-*
1248 *rospace, and Management*. Vol. 1, n.º 4.
- 1249 FARAH, Joëlle et al., 2024. QuizWiz: Integrating Generative Artificial Intelligence in an
1250 Online Study Tool. En: *Proceedings of the 2024 7th International Conference on Big*
1251 *Data and Education (ICBDE)*. ACM. Disp. desde DOI: 10.1145/3704289.3704296.

- 1252 FIELDING, Roy Thomas, 2000. *Architectural Styles and the Design of Network-based Soft-*
1253 *ware Architectures*. Tesis doct. University of California, Irvine.
- 1254 GAO, Yunfan; XIONG, Yun; GAO, Xinyu; JIA, Kangxiang; PAN, Jinliang; BI, Yuxi; DAI,
1255 Yi; SUN, Jiawei; GUO, Qianyu; WANG, Meng y WANG, Haofen, 2024. Retrieval-
1256 Augmented Generation for Large Language Models: A Survey. *arXiv preprint*. arXiv:2312.10997.
- 1257 HART, Sandra G. y STAVELAND, Lowell E., 1988. Development of NASA-TLX (Task
1258 Load Index): Results of Empirical and Theoretical Research. *Advances in Psychology*.
1259 Vol. 52, págs. 139-183. Disp. desde doi: 10.1016/S0166-4115(08)62386-9.
- 1260 AL-HITAWI, Mohammed A.S. y GYÖNGYÖSSY, N. M., 2026. Enhancing Transformer-
1261 Based Language Models for Hungarian Handwritten Text Recognition. *F1000Research*.
1262 Vol. 15, n.º 181.
- 1263 HUANG, Ming, 2025. Spaced Repetition and Retrieval Practice: Efficient Learning Me-
1264 chanisms from a Cognitive Psychology Perspective and Their Empowerment by AI.
1265 *International Journal of Asian Social Science Research*. Vol. 2, n.º 6, págs. 31-37.
- 1266 JIANG, Mi; GAO, Junran; PAN, Zeyu; WU, Yue y WANG, Zile, 2025. NexaNota: An AI-
1267 Powered Smart Linked Lecture Note-Taking System Leveraging Large Language Models.
1268 En: *2025 International Conference on Big Data and Informatization Education (ICBDIE)*.
1269 ACM.
- 1270 JONES, Michael B.; BRADLEY, John y SAKIMURA, Nat, 2015. *JSON Web Token (JWT)*
1271 [RFC 7519, IETF]. Disponible también desde: [https://www.rfc-editor.org/rfc/](https://www.rfc-editor.org/rfc/rfc7519)
1272 [rfc7519](https://www.rfc-editor.org/rfc/rfc7519).
- 1273 KANNAMMAL, K. E.; BHARATH KUMAR, M. S.; DHARANI DARAN, G.; KAVIN
1274 KRISHNA, S.; KAMALI, S. y MAAJIDA, A., 2024. NoteFlow AI. *International Journal*
1275 *of Scientific Research in Engineering and Management (IJSREM)*.
- 1276 KARDANMOGHADDAM, Hossein; AKBARIMAJD, Adel; RANJBARPOUR, Moham-
1277 mad; NOOSHYAR, Mahdi y JAMALI, Shahram, 2025. A Structure Based on TrOCR
1278 Transformer and Large Language Model for Classification of Handwritten Texts. *Facta*
1279 *Universitatis, Series: Electronics and Energetics*. Vol. 38, n.º 4, págs. 697-714.
- 1280 KASIRYE, Fred, 2023. Collaborative Learning and Higher Education. *Globalization and*
1281 *Business*. N.º 15.
- 1282 KLESEL, Michael y WITTMANN, H. F., 2025. Retrieval-Augmented Generation (RAG).
1283 *Business & Information Systems Engineering*. Vol. 67, n.º 4, págs. 551-561. Disp. desde
1284 DOI: 10.1007/s12599-025-00934-4.

- 1285 KREIJKES, Pia; KEWENIG, Viktor; KUVALJA, Martina; LEE, Mina; HOFMAN, Jake
1286 M.; VITELLO, Sylvia; SELLEN, Abigail; RINTEL, Sean; GOLDSTEIN, Daniel G.;
1287 ROTHCHILD, David; TANKELEVITCH, Lev y OATES, Tim, 2026. Effects of LLM
1288 use and note-taking on reading comprehension and memory: A randomised experiment
1289 in secondary schools. *Computers & Education*. Vol. 243, pág. 105514.
- 1290 LI, Jingyi; CHEN, Wei; ZHANG, Hao et al., 2025. Education-Oriented Graph Retrieval-
1291 Augmented Generation for Learning Path Recommendation. *arXiv preprint*. arXiv:2506.22303.
- 1292 LI, Minghao; LV, Tengchao; CHEN, Jingye; CUI, Lei; LU, Yijuan; FLORENCIO, Dinei;
1293 ZHANG, Cha; LI, Zhoujun y WEI, Furu, 2023. TrOCR: Transformer-Based Optical
1294 Character Recognition with Pre-Trained Models. En: *Proceedings of the AAAI Conference*
1295 *on Artificial Intelligence*. Vol. 37, págs. 13094-13102. Disp. desde doi: 10.1609/aaai.v37i11.26538.
- 1297 LNĚNÍČKA, Martin et al., 2024. Human-Centric Explainable AI in Education: Privacy,
1298 Security and Ethical Considerations. *arXiv preprint*. arXiv:2410.19822.
- 1299 LODOVICO MOLINA, Sebastián et al., 2025. QuerIA: Adaptive Question Generation and
1300 Evaluation in Higher Education Using Large Language Models and Contextual Learning.
1301 *Expert Systems with Applications*. Disp. desde doi: 10.1016/j.eswa.2025.037558.
1302 Combina prompt engineering, chunking semántico y alineación con Taxonomía de Bloom.
- 1303 MARTIN, Robert C., 2017. *Clean Architecture: A Craftsman's Guide to Software Structure*
1304 *and Design*. Prentice Hall. ISBN 9780134494166.
- 1305 MSAMBWA, Daniel et al., 2025. The Impact of AI on the Personal and Collaborative
1306 Learning Environments in Higher Education. *European Journal of Education*. Disp.
1307 desde doi: 10.1111/ejed.12909. Revisión sistemática de 148 artículos (2021–2024).
- 1308 NING, Wenyu; SHI, Shaotao; YIN, Yuchen; GUO, Zixuan y XIE, Jinrong, 2025. Intent-aware
1309 personalized summarization for educational texts with large language models. *Journal of*
1310 *King Saud University - Computer and Information Sciences*. Vol. 37, pág. 308.
- 1311 OBIONWU, Victor; BRONESKE, David y SAAKE, Gunter, 2022. Topic maps as a tool
1312 for facilitating collaborative work pedagogy in knowledge management systems. En: *The*
1313 *12th International Conference on Information Communication and Management (ICICM*
1314 *2022)*. ACM.
- 1315 SAXENA, Rishabh; SINGH, Shubhangi y DUBEY, Preeti, 2025. Comparative Analysis of
1316 Large Language Models for the Application of Scientific Article Summarization. *Procedia*
1317 *Computer Science*. Vol. 259, págs. 532-542.

- 1318 SHARMA, Madhav; SAXENA, Rakesh Kumar; SAINI, Hukum Chand; AGARWAL, Sa-
1319 miksha; SAXENA, Akash y RUNTHALA, Ashish, 2025. TrOCR: Transformer-Based
1320 OCR with Pre-Trained Vision–Language Models. En: *2025 IEEE Pune Section Interna-*
1321 *tional Conference (PuneCon)*. IEEE. Benchmarking en IAM, Bentham y SROIE; supera
1322 pipelines CNN-RNN.
- 1323 SHIRKANDE, S.T.; OMKAR, Gaikwad; HARSHAL, Palve; JAYESH, Patil y ANIKET, Kha-
1324 de, 2025. Noteverse: Intelligent Note Management for Organizational Hub. *International*
1325 *Journal on Advanced Electrical and Computer Engineering*. Vol. 14, n.º 1.
- 1326 SOLANKI, Minal; CHANDANKHEDE, Puja K. y BADWAIK, Sanjana J., 2026. Note-
1327 Genius: An Intelligent AI-Powered Ecosystem for Note Generation and Collaborative
1328 Learning. *International Journal of Advanced Research in Science, Communication and*
1329 *Technology (IJARSCT)*. Vol. 6, n.º 1, págs. 550-555.
- 1330 SOUMYA, M. D. y KRISHNAMOORTHY, S., 2025. Knowledge Graphs for Representing
1331 Knowledge Progression of Students across Heterogeneous Learning Systems. *Internatio-*
1332 *nal Journal of Artificial Intelligence in Education*. Vol. 35, págs. 1695-1723. Disp. desde
1333 DOI: 10.1007/s40593-024-00434-w.
- 1334 TANKELEVITCH, Lev et al., 2025. More AI Assistance Reduces Cognitive Engagement:
1335 Examining the AI Assistance Dilemma in AI-Supported Note-Taking. *arXiv preprint*.
1336 arXiv:2509.03392. Estudio CHI 2025 sobre toma de notas asistida por IA.
- 1337 TARAZONA CRUZ, Luz Silvana, 2024. *Reconocimiento de texto en manuscritos históricos*
1338 *peruanos utilizando modelos mixtos*. Lima, Perú. Disponible también desde: [http :
1339 //hdl.handle.net/20.500.12404/29310](http://hdl.handle.net/20.500.12404/29310). Tesis de maestría. Pontificia Universidad
1340 Católica del Perú.
- 1341 TORRES, Miguel et al., 2025. Enhancing Active Recall and Spaced Repetition with LLM-
1342 Augmented Review Systems. *Proceedings of the American Society for Engineering Edu-*
1343 *cation (ASEE)*. Disp. desde DOI: 10.18260/1-2--47123.
- 1344 UPADHYAY, Aryan; MOHOD, Arjun; CHAUDHARI, Manish; SHAHU, Kartik; WAGH-
1345 MARE, Kartik y KUBADE, Harshad M., 2026. AI-Powered YouTube Video Summa-
1346 rization: A Comprehensive Web Application for Automatic Content Analysis and Note
1347 Generation. *International Journal for Research in Applied Science and Engineering Tech-*
1348 *nology (IJRASET)*. Vol. 14, n.º 1. Disp. desde DOI: 10.22214/ijraset.2026.76857.
- 1349 VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; USZKOREIT, Jakob; JONES,
1350 Llion; GOMEZ, Aidan N.; KAISER, Lukasz y POLOSUKHIN, Illia, 2017. Attention Is
1351 All You Need. En: *Advances in Neural Information Processing Systems (NeurIPS)*.
- 1352 VIERIU, Aniella Mihaela y PETREA, Gabriel, 2025. The Impact of Artificial Intelligence
1353 (AI) on Students' Academic Development. *Education Sciences*. Vol. 15, n.º 3, pág. 343.

- 1354 ZHANG, Bo, 2026. A Review of the Development of Text Recognition Techniques. En:
1355 *CONF-SPML 2026 Symposium: The 2nd Neural Computing and Applications Workshop*.
- 1356 ZHANG, Liang et al., 2026. Personalized Learning Path Recommendation Based on Know-
1357 ledge Graphs: A Survey. *Electronics*. Vol. 15, n.º 1, pág. 238. Disp. desde DOI: [10.3390/
1358 electronics15010238](https://doi.org/10.3390/electronics15010238). Revisión narrativa 2014–2025, bases Web of Science y Scopus.

1359

1360

1361

1362

1363

1364

1365

1366

1367

1368

1369

ANEXOS

Tabla 7— Anexo 1: Matriz de Consistencia de la Investigación - Ecosistema SynapTome

Problema de Investigación	Objetivos de la Investigación	Hipótesis de la Investigación	Variables	Indicadores / Métricas	Metodología Aplicada
Problema General ¿De qué manera la transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente SynapTome optimiza el rendimiento académico, reduce la sobrecarga cognitiva y eleva la eficacia del aprendizaje colaborativo en estudiantes universitarios?	Objetivo General Optimizar la gestión del conocimiento, ampliar el acceso a repositorios de estudio y fortalecer el aprendizaje colaborativo, mediante la evaluación e implementación del ecosistema inteligente SynapTome, con el propósito de incrementar significativamente el rendimiento académico de los estudiantes universitarios.	Hipótesis General La transición desde esquemas tradicionales de gestión de estudio aislados hacia el uso adaptativo del ecosistema inteligente SynapTome optimiza significativamente el rendimiento académico, reduce la sobrecarga cognitiva y eleva la eficacia del aprendizaje colaborativo en los estudiantes universitarios (Shirkande et al., 2025; Afian et al., 2025).	Variable Independiente (VI): Ecosistema inteligente con visión artificial y LLM. Variable Dependiente (VD): Aprendizaje colaborativo y rendimiento académico.	* Tasa de Error de Caracteres (CER %). * Tiempo de consolidación de apuntes (min). * Índice de alucinación factual (%). * Puntaje de sobrecarga mental (NASA-TLX). * Calificación de exámenes (0–20). * Intercambio colaborativo (ítems/semana).	Tipo: Aplicada. Nivel: Explicativo. Diseño: Experimental (Pre-test / Post-test). Enfoque: Cuantitativo. Método: Científico y estadístico. Población y Muestra: Estudiantes de la Escuela de Informática y Sistemas, UNAMBA.
Problema Específico 1 ¿En qué medida la migración de los estudiantes hacia un flujo de digitalización automatizado influye en la tasa de preservación de información técnica y en la reducción del tiempo dedicado a la consolidación de apuntes manuscritos?	Objetivo Específico 1 Medir el incremento en la tasa de preservación de información técnica y la reducción del tiempo de consolidación de apuntes manuscritos en los estudiantes universitarios, mediante la transición de métodos de transcripción analógica tradicionales hacia un flujo de digitalización automatizado de alta precisión.	Hipótesis Específica 1 La migración de los estudiantes hacia un flujo de digitalización automatizado mediante un pipeline HTR basado en la arquitectura TrOCR con <i>fine-tuning</i> incrementa significativamente la tasa de preservación de información técnica en sus apuntes y reduce el tiempo promedio dedicado a la consolidación de notas manuscritas respecto al estado inicial analógico.	Dimensión VI: Módulo de digitalización y transcripción visual (TrOCR). Dimensión VD: Eficiencia de captura técnica del estudiante.	* Tasa de Error de Caracteres (CER %). * Tiempo semanal de transcripción manual o consolidación de apuntes (minutos). * Precisión de renderizado en sintaxis L ^A T _E X (%).	* Pipeline en Node.js de procesamiento de imágenes. * Modelo autorregresivo Transformer (TrOCR). * Análisis de varianza de tiempos de edición. * Pruebas experimentales en asignaturas de Cálculo y Física.
Problema Específico 2 ¿Cómo repercute el condicionamiento del entorno de asimilación cognitiva de los alumnos a un corpus académico validado en el nivel de veracidad factual y en la reducción de errores conceptuales presentes en sus materiales de autoestudio?	Objetivo Específico 2 Determinar la reducción en el índice de errores conceptuales y datos falsos (alucinaciones) en el material de autoestudio utilizado por los alumnos, evaluando el nivel de fidelidad y veracidad factual de sus resúmenes antes y después de restringir su entorno de asimilación cognitiva a un corpus académico validado.	Hipótesis Específica 2 El condicionamiento del entorno de asimilación cognitiva de los alumnos a un corpus académico validado mediante un middleware RAG restrictivo disminuye drásticamente el índice de errores conceptuales y datos falsos presentes en sus materiales de autoestudio, asegurando una alta fidelidad factual en comparación con el uso de herramientas genéricas de información.	Dimensión VI: Middleware de recuperación y fidelidad factual (RAG). Dimensión VD: Calidad factual de los recursos de repaso del estudiante.	* Índice de inserción de conceptos erróneos o alucinados (%). * Coincidencia semántica con el material base académico (%). * Tasa de veracidad conceptual en resúmenes.	* Indexación vectorial relacional. * Chunking semántico parametrizado de sílabos y apuntes oficiales. * Inferencia controlada sobre Modelos de Lenguaje Grande (LLMs). * Evaluación de fidelidad de resúmenes.
Problema Específico 3 ¿Cuál es el impacto latente de la adopción de un entorno de aprendizaje interconectado basado en mapas conceptuales dinámicos sobre las calificaciones promedio alcanzadas por los estudiantes y el nivel de sobrecarga cognitiva percibido?	Objetivo Específico 3 Cuantificar el impacto latente en las calificaciones promedio y el nivel de sobrecarga cognitiva percibida por los estudiantes, analizando la variación de sus puntajes académicos y fatiga mental tras migrar de un esquema de repaso individual aislado a un entorno de aprendizaje interconectado y evaluado de forma dinámica.	Hipótesis Específica 3 La adopción de un entorno de aprendizaje interconectado basado en Grafos de Conocimiento y evaluaciones dinámicas automatizadas incrementa las calificaciones promedio de los estudiantes y reduce los niveles de sobrecarga cognitiva percibida en comparación con los valores basales registrados durante los métodos de repaso individuales y aislados.	Dimensión VI: Motor relacional topológico y evaluaciones dinámicas. Dimensión VD: Desempeño académico y carga cognitiva declarada del alumno.	* Calificaciones cuantitativas alcanzadas en exámenes parciales (Escala 0–20). * Índice de fatiga mental y estrés autopercebido (Escala NASA-TLX). * Volumen de intercambio interactivo eficaz (ítems/semana).	* Base de datos orientada a grafos indexados. * Algoritmos de IA para generación automatizada de cuestionarios formativos (<i>quizzes</i>). * Protocolos de sincronización web interactiva en tiempo real (SignalR). * Aplicación de la prueba estadística t de Student unilateral derecha.